

密 级： 公开

加密论文编号：

论文题目： 基于深度学习的材料逆向生成

学 号： [待填]

研 究 生： [待填]

专 业 名 称： 计算机技术

2026 年 XX 月

基于深度学习的材料逆向生成

Deep Learning-Based Inverse Materials Design

研究生: [待填]

指导教师: [待填]

北京科技大学 [待填学院]

北京 100083, 中国

Master Degree Candidate: [To be filled]

Supervisor: [To be filled]

[College to be filled]

University of Science and Technology Beijing

30 Xueyuan Road, Haidian District

Beijing 100083, P.R.CHINA

中图分类号

学校代码 10008

U D C :

密级 : 公开

北京科技大学硕士学位论文

论文题目: 基于深度学习的材料逆向生成

研究生: [待填]

指 导 教 师: 单位: 职称:

指 导 小 组 成 员: 单位: 职称:

单位: 职称:

论文提交日期: 2026 年 XX 月

学位授予单位: 北 京 科 技 大 学

摘 要

材料逆向设计旨在根据目标性能或约束条件反推出满足要求的候选晶体结构。生成式深度学习为在大规模结构空间中直接产生候选提供了新的技术路径，但条件属性控制精度有限，且满足属性条件的结构仍可能存在局部几何或代理受力问题。本文以冻结的 MatterGen 作为基础生成模型，围绕推理阶段的条件属性控制和局部结构代理物理一致性开展研究，不重新训练 MatterGen 主干权重，也不改变其三字段生成定义。

据此，本文以“冻结材料生成模型的可信推理增强”为统一主线；“可信”特指推理预算、回退路径及代理证据边界可审计，不表示结构已通过 DFT 或实验物理验证。

针对冻结生成模型如何利用有限额外推理计算、又避免不利候选破坏参考输出的问题，本文提出预算约束验证选择推理方法。该方法保持 MatterGen 参数冻结，保存固定 CFG=2.0 的精确 C0 参考轨迹与共享采样前缀，按预定预算扩展候选后缀，并通过终点属性误差和代理质量约束选择输出；无合格候选时回退到 C0。Fixed-K2 是该框架的固定双候选实例。在 128 个全新配对种子组成的 C1-128 确认实验中，其 Property MAE 从 0.034796 降至 0.026332，相对降低 24.32%，通过预定义代理质量护栏，MatterGen 得分调用约为 C0 的 2.2 倍。另一个独立的 128 种子对照中，独立 Best-of-2 的 Property MAE 为 0.028097，Fixed-K2 为 0.029506；两者的直接配对差异区间跨零，且预算并不完全相同。该结果表明额外采样计算本身具有竞争力，本文不主张 Fixed-K2 优于一般 Best-of-N，而关注参考保持、约束选择与可回退的推理机制。学习型 Linear-K2 分配亦未得到独立支持。

针对属性满足但局部结构仍可能具有较高代理受力的问题，本文提出基于阶段可靠性校准的后期神经力场引导扩散方法（Reliability-Calibrated Late-stage Neural Force-Guided Diffusion, RC-NFGD）。该方法依据预测干净结构在扩散后期的阶段可靠性构造介入窗口，调用 MatterSim 估计原子力，经笛卡尔坐标到周期分数坐标的映射后，将力反馈注入 position predictor，并实施有界位置修正和异常安全回退。在

Formal256 正式实验中, MatterSim 评估的最大原子力、平均原子力和 RMSD 分别降低 29.81%、29.72% 和 14.17%; 未参与在线引导的 CHGNet 独立机器学习原子间势评估中, 最大原子力均值降低 14.36%。与此同时, RC-NFGD 的 Property MAE 由 0.009757 增至 0.009868, 误差约恶化 1.14%, 表明代理受力改善并未带来目标属性误差的同步改善。

补充性证据进一步限定方法边界: 历史 A6 同组 32 对结构的属性—受力 Pareto 分析表明, RC-NFGD 与 POST 的方法均值呈不同折中, 但 POST 的 MatterSim MaxF 更低, 属性差异的配对区间跨零。另一个全新 32 对种子的力反馈注入阶段消融中, C0、Early、Middle、Late 的 MaxF 均值分别为 0.18986、0.16860、0.14072、0.13864 eV/Å; 原始 Late 相对 C0 的配对改善得到支持, 但与 Early、Middle 的直接比较区间均跨零, 且各阶段力调用预算不同, 不能断言后期注入普遍最优。

综上, 本文形成两条独立的冻结 MatterGen 推理增强路线: 预算约束验证选择面向代理属性控制, RC-NFGD 面向代理局部结构一致性。预算扩展实验显示, 在另一个独立 cohort 中, K=0/1/2/3/4 的 Property MAE 分别为 0.035141/0.031636/0.028454/0.028419/0.024669, 说明 K=2 是既有成本折中实例而非最优搜索宽度。两条路线尚无已验证的联合增益; 在线力引导也未全面优于等预算生成后处理。物理一致性证据仍来自 MatterSim 和 CHGNet 等机器学习原子间势代理, 尚无 DFT 验证。结论因此限定于所用模型、任务、预算和代理协议。

关键词: 材料逆向设计; 晶体结构生成; 扩散模型; 预算约束推理; 神经网络原子间势

Deep Learning-Based Inverse Materials Design

ABSTRACT

Inverse materials design aims to infer candidate crystal structures from target properties or structural constraints. Deep generative models provide a way to propose candidates directly in a large structural space, yet conditional property control can remain inaccurate, and a structure that satisfies a target property may still exhibit poor local geometry or large surrogate forces. This thesis uses frozen MatterGen as the foundation generative model and studies two inference-time problems: conditional property control and local structural consistency as measured by surrogate physical metrics. The MatterGen backbone and its three-field generation definition are kept unchanged.

Accordingly, the unifying theme is trustworthy inference-time enhancement of frozen material generative models. Here, trustworthy means auditable compute budgets, fallback paths, and surrogate-evidence boundaries; it does not imply DFT- or experimentally verified physical stability.

To study how a frozen generator can use limited additional inference compute without losing a reproducible reference output, this thesis proposes a budget-constrained verifier-guided inference framework. It preserves the exact CFG=2.0 C0 trajectory and a shared prefix, expands a preregistered set of candidate suffixes, and uses terminal property error and surrogate-quality constraints for selection, falling back to C0 when no candidate qualifies. Fixed-K2 is a fixed-width instance. On 128 fresh paired C1 seeds, it reduced Property MAE from 0.034796 to 0.026332 (24.32%) while passing predefined surrogate-quality guardrails, at approximately 2.2 times the C0 generator score-call budget. In a separate 128-seed comparison, Independent Best-of-2 and Fixed-K2 achieved MAE values of 0.028097 and 0.029506, respectively; their direct paired confidence interval spans zero, and their compute and terminal-candidate budgets differ. Additional sampling itself is therefore competitive. This thesis does not claim that Fixed-K2 outperforms general Best-of-N sampling; its focus is reference preservation, constraint-aware se-

lection, and fallback. Learned Linear-K2 allocation showed no independently supported added value.

To address the possibility that property-satisfying structures still have large local surrogate forces, this thesis proposes Reliability-Calibrated Late-stage Neural Force-Guided Diffusion (RC-NFGD). The method identifies an intervention window from the stage-wise reliability of predicted clean structures, evaluates atomic forces with MatterSim in the late diffusion stage, maps Cartesian forces to periodic fractional coordinates, injects the feedback into the position predictor, and applies bounded position correction with anomalous-path fallback. On Formal256, RC-NFGD reduced the MatterSim-evaluated maximum atomic force, mean atomic force, and RMSD by 29.81%, 29.72%, and 14.17%, respectively. In an independent CHGNet machine-learning interatomic-potential evaluation that was not used for on-line guidance, the mean maximum atomic force decreased by 14.36%. However, Property MAE increased from 0.009757 to 0.009868, corresponding to an approximately 1.14% deterioration; thus, improved surrogate force and structural metrics did not translate into simultaneous improvement in target-property error.

Supplementary analyses delimit the physical-feedback claim. On the historical paired A6 cohort ($n = 32$), the property–force Pareto analysis shows a descriptive trade-off between RC-NFGD and post-generation optimization (POST); POST has lower MatterSim MaxF, while the paired property-error interval spans zero. In a separate fresh 32-pair timing ablation, mean MaxF values for C0, Early, Middle, and the original Late intervention are 0.18986, 0.16860, 0.14072, and 0.13864 eV/Å. Late improves on its paired C0 baseline, but direct Late–Early and Late–Middle intervals span zero, and force-call budgets differ. These results do not establish a universally optimal injection stage.

Overall, the thesis develops two independent inference-time enhancement routes for frozen MatterGen: budget-constrained verifier-guided selection for surrogate property control, and RC-NFGD for surrogate local structural consistency. In a separate budget-scaling cohort, Property MAE at

widths $K=0/1/2/3/4$ was 0.035141/0.031636/0.028454/0.028419/0.024669; $K=2$ is the previously validated cost trade-off, not the best-performing width. The results do not establish joint synergy, nor does online force guidance dominate all equal-budget post-generation processing. Physical-consistency evidence remains limited to machine-learning interatomic-potential surrogates such as MatterSim and CHGNet; no DFT validation has been performed. Conclusions are restricted to the evaluated model, tasks, budgets, and surrogate protocols.

Key Words: inverse materials design; crystal structure generation; diffusion models; budget-constrained inference; machine-learning interatomic potentials

目 录

摘要	I
ABSTRACT	III
插图和表格清单	XIII
主要符号与缩略语清单	XVII
1 绪论	1
1.1 研究背景与意义	1
1.2 国内外研究现状	2
1.2.1 材料逆向设计与生成式材料设计	2
1.2.2 晶体材料生成模型的发展	3
1.2.3 扩散模型在晶体生成中的应用	5
1.2.4 条件属性控制与引导生成	5
1.2.5 神经网络原子间势与生成结构优化	6
1.2.6 现有研究的主要不足	6
1.3 本文研究内容	7
1.4 本文主要创新点	9
1.4.1 面向冻结扩散生成模型的预算约束验证选择推理增强方 法	9
1.4.2 基于阶段可靠性校准的后期神经力场引导扩散方法	9
1.5 技术路线	10
1.6 论文组织结构	11
1.7 本章小结	11
2 相关理论与关键技术	13
2.1 材料逆向设计与晶体生成问题	13
2.2 晶体结构表示与周期性	14
2.2.1 晶体基本表示	14
2.2.2 晶胞、分数坐标与周期邻域	15
2.2.3 结构等价性与本文所需边界	15
2.3 扩散生成模型基础	15
2.3.1 前向扩散过程	15
2.3.2 反向生成过程	16
2.3.3 Score-based 建模	17
2.3.4 预测干净结构	17

2.4 条件扩散与分类器无关引导	18
2.4.1 条件生成	18
2.4.2 分类器无关引导	18
2.4.3 条件—无条件预测差异	19
2.5 MatterGen 晶体生成模型	19
2.5.1 总体框架	19
2.5.2 三字段联合生成	20
2.5.3 GemNetT 去噪网络	21
2.5.4 条件属性控制与采样	21
2.6 神经网络原子间势与原子力	21
2.6.1 势能面与局部结构	21
2.6.2 力相关指标	22
2.6.3 神经网络原子间势	22
2.7 MatterSim 与 CHGNet	22
2.7.1 MatterSim	22
2.7.2 CHGNet	23
2.7.3 本文中的角色区别	23
2.8 评价指标与统计分析	24
2.8.1 属性误差	24
2.8.2 稳定性、有效性与分布指标	24
2.8.3 原子力与结构偏移指标	25
2.8.4 配对统计与 Bootstrap	26
2.9 本章小结	27
3 面向冻结扩散生成模型的预算约束验证选择推理增强方法	29
3.1 冻结扩散模型的推理预算问题	29
3.1.1 冻结 MatterGen 与参考采样	29
3.1.2 研究假设与评价目标	30
3.2 单轨迹控制探索及其失败边界	30
3.2.1 字段残差与共享控制量	30
3.2.2 V1 实验结果与稳定性问题	31
3.2.3 反事实 Oracle 与引导优化空间	32
3.2.4 在线自适应引导不稳定性的机制分析	33
3.3 预算约束验证选择推理框架	36
3.3.1 状态、动作与预算接口	36
3.3.2 精确参考保留与共享前缀	37

3.3.3 有限候选后缀与 Fixed-K2 策略	38
3.3.4 终点验证器与参考回退	38
3.3.5 算法描述	39
3.4 Fixed-K2 固定预算实例与独立确认	39
3.4.1 分支兼容 Oracle 与候选预算分析	40
3.4.2 Fixed-K2 的独立确认结果	41
3.4.3 学习型 Linear-K2 分配器的负消融	43
3.5 推理预算与候选来源分析	45
3.5.1 独立 Best-of-2 与共享前缀实例	45
3.5.2 $K=0-4$ 固定候选顺序的预算扩展	47
3.6 局限性与本章小结	48
3.6.1 证据解释	48
3.6.2 局限性	49
3.6.3 本章小结	50
4 面向冻结材料扩散模型的神经力场反馈引导方法	51
4.1 问题定义与研究动机	51
4.1.1 条件扩散生成中的局部结构问题	51
4.1.2 直接力引导的困难	52
4.1.3 研究假设与验证原则	52
4.2 后期结构可靠性分析	53
4.2.1 诊断协议	53
4.2.2 阶段相关性结果	53
4.3 RC-NFGD 方法设计	54
4.3.1 预测干净结构的解析恢复	54
4.3.2 神经力场原子力估计	55
4.3.3 周期坐标与力方向映射	55
4.3.4 有界位置修正与安全回退	56
4.3.5 生成过程中的后期力引导	56
4.4 阶段可靠性校准与方法冻结	57
4.5 小规模验证与方法冻结	59
4.5.1 P0 可行性验证	59
4.5.2 Formal32 独立复现	59
4.6 Formal256 正式实验	60
4.6.1 实验设计与主结果	60
4.6.2 效应一致性、尾部与质量护栏	62
4.6.3 计算开销	63

4.7	CHGNet 独立代理评估	63
4.7.1	跨神经势评估动机与结果	63
4.7.2	尾部结果的限制	64
4.8	消融实验与边界分析	65
4.8.1	力方向消融	65
4.8.2	有界位置修正消融	65
4.8.3	在线引导与等预算生成后修正	66
4.8.4	与 Adaptive CFG 的兼容性	66
4.9	属性—代理受力的 Pareto 权衡	66
4.10	力反馈注入阶段的影响 (Influence of Force Feedback Injection Stage)	67
4.11	方法讨论与局限	69
4.11.1	方法贡献与适用范围	69
4.11.2	局限性	70
4.12	本章小结	71
5	实验结果与综合分析	73
5.1	实验设置与评价协议	73
5.1.1	证据层级与实验角色	73
5.1.2	指标与统计口径	75
5.1.3	代理评价边界	76
5.2	条件属性生成结果的综合分析	76
5.2.1	C1-128 主结果	76
5.2.2	属性收益与质量护栏的关系	78
5.2.3	结果的科学含义	78
5.2.4	独立采样对照与预算扩展的新增边界	78
5.3	参考保持与候选分配的证据边界	79
5.3.1	从在线控制失败到分支上界	79
5.3.2	Phase B 学习型分配器	80
5.3.3	C1 中的直接检验	80
5.4	RC-NFGD 的物理一致性改善	80
5.4.1	Formal256 主结果	80
5.4.2	跨 cohort 可复现性	82
5.4.3	条件属性与结构指标的权衡	83
5.5	MatterSim 与 CHGNet 跨代理对比	83
5.6	消融结果与机制分析	85
5.6.1	真实力方向的作用	87

5.6.2 有界位置修正的保守角色	87
5.6.3 在线引导与生成后修正	87
5.6.4 属性—受力权衡与注入阶段的补充证据	88
5.6.5 复杂模型不必然优于冻结简单策略	88
5.7 计算代价与工程可行性	88
5.8 两项创新的关系与联合实验结论	90
5.9 适用范围、威胁与局限性	91
5.9.1 内部有效性	91
5.9.2 外部有效性与应用边界	91
5.9.3 结论强度与未解决问题	92
5.9.4 对研究问题的逐项回答	94
5.10 本章小结	95
6 总结与展望	97
6.1 全文工作总结	97
6.2 主要研究成果	98
6.2.1 条件属性生成方面的研究成果	98
6.2.2 局部结构物理一致性方面的研究成果	99
6.2.3 两项成果的关系与总体回答	99
6.3 研究局限	100
6.4 未来工作展望	101
6.4.1 以配对 DFT 单点力验证代理结论	101
6.4.2 研究更可靠的候选分配与更低成本分支	101
6.4.3 扩展属性、材料体系和生成模型	101
6.4.4 发展多物理量反馈和在线—后处理组合	102
6.4.5 面向实验可验证性的候选筛选	102
6.5 本章小结	102
参考文献	103
致谢	105
作者简历及在学研究成果	107
独创性说明	109
关于论文使用授权的说明	111
学位论文数据集	113

插图和表格清单

1-1	本文总体技术路线	10
2-1	晶体结构的晶胞、分数坐标与周期映射示意图	16
2-2	扩散模型前向加噪与反向生成示意图	17
2-3	条件与无条件得分构成 CFG 的示意图	19
2-4	MatterGen 三字段条件生成总体流程	20
2-5	神经势的结构—能量—原子力关系示意图	23
3-1	创新点 1 的证据演化：方框表示各阶段冻结结论，而非单 调性能曲线	33
3-2	预算约束验证选择的 Fixed-K2 实例：共享前缀后保存采 样状态与随机状态，扩展精确 C0 和两个固定后缀，由冻 结终点验证器选择或回退。预算数字仅为 MatterGen score 调用与终点评价次数；机制示意不构成性能证据。	37
3-3	C1-128 中 C0、Fixed-K2、Linear-K2 与 Random-K2 的 Prop- erty MAE	42
3-4	Fixed-K2 与 C0 的逐样本属性误差	42
3-5	Fixed-K2 相对 C0 的 20 000 次配对自助法增益分布	42
3-6	C1-128 的代理质量护栏结果	43
3-7	C0、Fixed-K2 及 Phase B 数据构建的计算量比较	44
3-8	独立 Best-of-2 与 Fixed-K2 的候选来源及生成预算示意。 二者共享 SAFE-A 终点规则，但前者为两个完整独立采样 (4000 次 score 调用、2 个终点)，后者共享前缀并展开两个 后缀 (4400 次、3 个终点)。该图只描述机制与非等预算， 不暗示任一方法性能更优。	45
3-9	独立 Best-of-2 与 Fixed-K2 的代理 Property MAE 对照：点 为同一新 cohort 的方法均值，误差棒为 20 000 次种子自 助法均值 95% 区间；直接配对差异见正文。预算标签仅计 MatterGen score 调用，三方法分别为 1.0、2.0 和 2.2 倍 C0。	46

3-10	K=0–4 的 MatterGen score 预算与选中代理 Property MAE。 五点来自同一独立新 cohort 的 128 个配对种子；误差棒为 20 000 次种子自助法方法均值 95% 区间，而非相邻 K 的 配对增益区间。连线仅连接离散预算，不表示拟合的扩展 定律；终点验证器调用与端到端时间未包含在横轴中。 . . .	48
4-1	RC-NFGD 在线引导流程	52
4-2	Formal256 主要代理结构指标	61
4-3	Formal256 配对改善分布	62
4-4	P0、Formal32 与 Formal256 效应方向一致性	62
4-5	RC-NFGD 在 Formal256 上的质量护栏	63
4-6	MatterSim 与 CHGNet 的逐样本改善比较	64
4-7	历史 A6 同组 32 对结构的 Property MAE–MatterSim MaxF 方法均值及种子自助法 95% 区间。虚线仅连接方法均值的 描述性非支配点，不表示统计显著性或跨 cohort 前沿； POST 的终态代理力更低。	68
4-8	Timing Ablation 的配对 MatterSim MaxF 差（候选减 C0）， 点为 32 对种子的均值差，横线为 20 000 次配对百分位自 助法 95% 区间。负值表示较低代理力；Early 和 Middle 区 间跨零。各臂力调用预算不同，不构成等预算时机最优证 据。	69
5-1	C1-128 四种方法的 Property MAE	77
5-2	创新点 1 从在线自适应探索到最终确认的证据演进	79
5-3	Formal256 配对改善分布	82
5-4	P0、Formal32 与 Formal256 的 MaxF 效应一致性	82
5-5	MatterSim 与 CHGNet 的逐样本改善比较	84
5-6	C0、Fixed-K2 与 Phase B 数据构建的计算量比较	90
1-1	代表性晶体生成方法对比	4
1-2	本文研究问题与技术路线	8
2-1	本文主要符号	14
2-2	MatterGen 三类生成字段	20

2-3	MatterSim 与 CHGNet 在本文中的角色	24
2-4	本文主要评价指标	25
3-1	在线自适应 CFG 探索与机制实验汇总	33
3-2	Stage-Calibrated CFG 的 Fresh P0 结果	35
3-3	分支兼容候选策略	38
3-4	分支兼容 Oracle 的测试集结果	40
3-5	C1-128 最终确认结果	41
3-6	独立 Best-of-2 对照的生成预算与代理结果 (全新配对种子, $n = 128$)	46
3-7	固定候选顺序下的预算扩展结果 (独立新 cohort, $n = 128$)	47
4-1	后期预测干净结构的阶段可靠性诊断	54
4-2	RC-NFGD 冻结配置	58
4-3	P0 与 Formal32 的效应复现	59
4-4	Formal256 主结果 (相对变化和 CI 均按 C0-RC-NFGD 的有利方向定义)	60
4-5	CHGNet 在 Formal256 上的独立代理评估	64
4-6	力方向消融 ($n = 32$)	65
4-7	历史 A6 配对 cohort 的属性—代理受力权衡 ($n = 32$, 均值 $\pm$ 样本标准差)	67
4-8	力反馈注入阶段消融: 32 对新种子的均值 $\pm$ 样本标准差; 耗时为端到端 wall time	67
4-9	Timing Ablation 的次要代理质量指标 ($n = 32$; 力和 E-hull 为均值 $\pm$ 样本标准差)	68
5-1	关键实验、样本规模与证据类型	74
5-2	创新点 1 C1-128 最终确认结果	77
5-3	RC-NFGD Formal256 正式结果	81
5-4	Formal256 的 MatterSim 与 CHGNet 跨代理结果	84
5-5	关键消融、机制证据与解释边界	86
5-6	计算代价与部署条件	89
5-7	最终 Claim-Evidence 对照	92

主要符号与缩略语清单

CFG	classifier-free guidance, 分类器无关引导
C0	固定 CFG=2.0 的参考基线轨迹
Fixed-K2	参考轨迹保留的固定双候选策略
RC-NFGD	Reliability-Calibrated Late-stage Neural Force-Guided Diffusion (阶段可靠性校准的后期神经力引导扩散)
MLIP	machine-learning interatomic potential, 机器学习原子间势
DFT	density functional theory, 密度泛函理论

1 绪论

1.1 研究背景与意义

材料的组成、晶体结构与物性之间存在复杂的耦合关系。传统材料发现通常从经验规则、实验试错或给定结构的计算筛选出发：研究者先提出组成和结构，再通过实验表征或第一性原理计算判断其性质。这类流程能够提供可靠的物理依据，但候选空间随着元素种类、计量比、原子排布和晶胞自由度增加而迅速扩大。对每一个候选结构进行高精度电子结构计算，又会带来显著的计算成本。因此，如何在保证结构表示和评价可追溯的前提下减少无效候选，是计算材料设计中的重要问题。

机器学习推动了材料信息学从“结构到性质”的正向预测发展。给定组成、原子坐标和晶胞，模型可以近似预测形成能、能量高于凸包值、带隙、磁性或力学性质，从而加速高通量筛选。正向预测仍然需要一个已经给定的结构；当目标是寻找满足某种性质约束的新材料时，研究者还需要解决“从目标到结构”的逆向设计问题。逆向设计并不是正向函数的简单求逆，因为多个结构可能具有相近性质，模型误差和计算层级也会影响目标定义。生成式模型因此成为一种重要的候选产生机制：它从已知晶体分布中学习结构规律，再根据随机变量、组成或性质条件提出新的结构样本 [1-3]。

晶体生成比一般的图像或文本生成具有更强的结构约束。一个候选晶体至少需要同时确定原子种类、周期分数坐标和晶胞；原子数和元素组合属于离散变量，坐标和晶胞参数属于连续变量；原子排序、整体平移、旋转以及周期复制还会造成表示等价。生成结果即使形式上可转换为结构文件，也可能存在过短原子间距、无效晶胞、异常能量或局部受力过大等问题。因而，材料逆向生成不能只以样本数量或形式新颖性作为目标，还必须同时考虑条件符合度、结构有效性、稳定性代理和局部几何一致性。

扩散模型为上述问题提供了一个适合多变量逐步生成的框架。相关方法可以在周期晶体图上建模坐标和晶胞，也可以进一步将元素种类纳入联合扩散。CDVAE 将变分表示与结构去噪结合，DiffCSP 在周期 $E(3)$ 等变网络中联合生成晶格和原子坐标，MatterGen 则将原子种类、位置和晶胞作为相互耦合的字段，并支持面向化学体系、对称性和标量性质的条件生成 [2-4, 8]。这些模型提高了候选生成的自动化程度，但推理过程仍然存在两个与本文直接相关的问题。

第一个问题是冻结模型的推理预算与条件属性控制。分类器无关引导通过条件得分与无条件得分的差异增强目标条件，是扩散模型中常用的推理阶段机制 [11-13]。固定引导强度具有实现简单、额外训练成本低的优点，但不同样本、不同扩散阶段和不同字段的条件响应可能并不相同。对所有样本采用同一强度，可

能无法充分利用少量有利的条件偏离；直接根据中间残差在线调整，又可能把不稳定信号放大到结构质量。因此本文的问题并非仅是如何调节 CFG，而是冻结 MatterGen 后如何分配额外推理计算：独立重复采样与共享前缀候选扩展分别提供何种收益，如何在终点评价可能有偏时限制接受风险，并保留一条可精确恢复的参考输出。本文在有限预算内展开候选，依据终点代理约束作出选择，同时设置独立 Best-of-2 作为强对照。

第二个问题是局部结构物理一致性。机器学习原子间势可以低成本估计能量、力和应力，已广泛用于结构筛选、松弛和材料搜索 [14–19]；但在许多生成流程中，神经势主要用于生成完成后的评价或优化。若在扩散过程早期直接对高噪声状态计算力，力的排序和方向可能不可靠；若完全等到终态再处理，又无法研究外部物理反馈如何影响生成轨迹。本文围绕这一时间接口，先校准预测干净结构在后期阶段的可靠性，再研究神经势原子力进入逆扩散位置更新的方式。

本文以 MatterGen 作为冻结的基础生成模型，研究对象是其推理阶段的条件引导与神经力场反馈，而不是重新提出或重新训练 MatterGen。两个研究问题分别对应预算约束的代理属性控制和物理反馈驱动的代理局部结构一致性，评价时使用配对种子、预注册指标以及 MatterSim 和 CHGNet 代理模型，并明确保留无 DFT 验证这一证据边界。这样的研究具有两方面意义：在方法层面，考察生成模型内部得分、终点评价和外部物理代理之间如何形成可审计的推理接口；在应用层面，为不同目标优先级下的候选生成和局部结构筛选提供可复现的实验依据。

本文将上述两条路线统一表述为“冻结材料生成模型的可信推理增强”：可信在此指推理预算、代理选择、回退路径及证据边界可明确核算和审计，不指已经获得 DFT 级物理真实性保证。预算控制回答额外计算如何使用，神经力反馈回答外部物理代理如何介入；两者独立验证，不构成已确认的联合方法。

从计算机专业硕士论文的角度看，本文关注的不是单一模型在某个数据集上的分数，而是一个包含状态管理、推理控制和证据审计的生成系统。参考轨迹需要同时保存采样器状态与随机数状态，候选选择需要把计算预算写入算法定义，神经力反馈需要处理坐标系、时间阶段和异常路径，最终结论还要通过匹配种子和跨代理评价检验。这些环节把生成模型、图神经网络、数值采样和实验设计连接起来，形成可实现、可复现和可分析的计算机技术问题。

1.2 国内外研究现状

1.2.1 材料逆向设计与生成式材料设计

材料逆向设计通常将目标性质、组成范围或结构约束作为输入，输出一个或多个候选材料。早期方法常将生成建模与潜空间优化结合，在连续潜变量中寻找具有较低形成能或目标属性的结构。CrystalGAN 将生成对抗网络用于晶体结构

学习, 并通过潜空间或生成结果筛选探索新的化学组合 [1]; 后续的可逆晶体表示工作则将结构编码为可生成的字符串或图结构, 使性质条件可以与序列模型结合 [6]。这些方法说明, 表示方式会直接影响模型能否恢复有效晶胞、周期邻接和元素关系。

另一条路线是高通量预测与搜索。GNoME 通过大规模图模型和主动学习流程扩展稳定晶体候选, 再使用更高成本的计算和实验流程进行后续筛选 [14]。这类工作展示了机器学习在扩大候选覆盖范围方面的能力, 同时也说明“预测稳定”与“可以合成、具有目标功能”之间仍需多层验证。生成模型的作用更接近提出结构候选和改善搜索起点, 不能替代第一性原理、实验表征或工艺验证。

随着逆向设计任务从单一组成搜索扩展到复杂目标属性, 研究重点逐渐转向可控生成。条件变分模型可以把组成、压力或材料属性输入解码器; 扩散模型可以通过条件得分、结构约束或外部预测器改变采样分布; 自回归模型则可以直接以 CIF 或结构字符串为序列进行生成。近期综述把表示、生成架构和属性约束视为生成式材料设计的三个核心环节, 并指出数据兼容性、计算资源和有效生成率仍然是共性挑战 [21]。本文选取 MatterGen 作为实验基础, 正是因为它在同一扩散框架中联合处理元素、位置和晶胞, 并支持属性条件。

1.2.2 晶体材料生成模型的发展

晶体生成模型的发展可以按生成表示和建模方式粗略分为三类。第一类以体素、图或潜变量为基础, 利用 VAE、GAN 或其他潜空间模型学习结构分布。CrystalGAN 代表了较早将 GAN 用于晶体结构生成的尝试 [1]; CDVAE 则将周期图编码器、属性预测器和扩散解码器结合起来, 在结构重建、有效生成和属性优化任务上进行统一评估 [2]。这些工作把周期边界和几何对称性纳入模型设计, 但对变原子数、复杂晶胞和跨化学体系生成的处理方式仍各不相同。

第二类是等变扩散模型。DiffCSP 使用周期 $E(3)$ 等变去噪网络, 并在分数坐标中联合更新晶格和原子位置, 主要面向给定组成的晶体结构预测, 也扩展到从头晶体生成 [3]。DiffCSP++ 进一步把空间群约束转化为晶格对数空间和 Wyckoff 位置约束, 支持具有空间群条件的可控生成 [4]。UniMat 采用可扩展的材料生成扩散框架, 面向更大规模和更复杂的化学系统, 研究了条件生成与稳定候选发现 [5]。这些方法体现了周期性、旋转等变性和晶胞生成在晶体扩散中的核心地位。

第三类是序列和语言模型。SLICES 将晶体拓扑与组成编码为可逆字符串, 并用循环神经网络生成满足目标性质的候选结构 [6]。CrystaLLM 直接对标准化 CIF 文本进行自回归建模, 并根据组成或空间群提示生成结构文件 [7]。序列模型便于使用成熟的语言建模和搜索算法, 但生成结果需要经过 CIF 解析、周期结构重建和物理评价; 文本合法并不自动意味着晶体几何有效。

MatterGen 位于上述发展线索的交汇处。它采用面向无机晶体的联合扩散框

架，对原子种类、周期坐标和晶胞进行字段特定的噪声建模，并通过条件适配支持属性引导 [8]。与主要接受固定组成的 CSP 方法相比，MatterGen 更适合作为本文的基础生成器；与只在终点进行结构优化的流程相比，它为研究采样期间的推理接口提供了完整的反向轨迹。本文的工作建立在这个基础模型之上，不改变其权重和基本字段定义。

表 1-1: 代表性晶体生成方法对比
Tab. 1-1: Comparison of Representative Crystal Generation Methods

方法	主要范式	组成处理	位置与晶胞	条件控制	生成期物理反馈
CrystalGAN [1]	GAN	潜空间或生成约束	结构表示相关	潜空间/后处理	无在线力反馈
CDVAE [2]	VAE+ 扩散	潜变量预测	周期坐标与晶胞	属性优化	结构稳定先验
DiffCSP [3]	周期等变扩散	通常给定组成	联合生成晶格与坐标	组成或任务条件	无在线力反馈
DiffCSP++ [4]	约束扩散	给定或受约束	空间群与 Wyckoff 约束	空间群条件	结构约束
UniMat [5]	可扩展扩散	条件生成	晶体结构	组成/数据条件	无在线力反馈
SLICES [6]	自回归字符串	字符串编码	解码后重建	目标属性	后续松弛
CrystaLLM [7]	CIF 自回归模型	提示或给定	CIF 文本	组成/空间群提示	后处理评价
MatterGen [8]	三字段联合扩散	联合生成	位置与晶胞联合生成	化学、对称性、标量属性	本文冻结基线
SCIGEN [9]	结构约束扩散	约束生成	几何图案条件	蜂窝、kagome 等结构	结构先验
PODGen [10]	预测器引导 MCMC	通用生成器	生成结构	多属性预测器	预测器引导采样

表 1-1 用于定位技术路线，不用于直接比较不同论文的数值结果。各方法使用的数据集、结构表示、训练规模和评价协议不同；本文只提取与研究问题有关的生成对象、条件接口和物理反馈方式。

1.2.3 扩散模型在晶体生成中的应用

扩散模型的优势在于可以把复杂结构分布分解为多个噪声阶段的去噪任务。对晶体而言，噪声过程不能简单复制图像领域的各向同性高斯扰动：分数坐标具有周期性，晶胞属于矩阵变量，原子种类属于离散类别，三者还通过局部邻域耦合。CDVAE 通过结构扩散解码器处理周期材料；DiffCSP 使用周期等变网络；MatterGen 则进一步将原子类型加入三字段联合生成 [2, 3, 8]。

条件方式也呈现多样化。DiffCSP++ 把空间群约束纳入扩散过程，SCIGEN 在扩散步骤中注入蜂窝、kagome 等几何结构先验，以产生具有特定结构图案的候选 [4, 9]。这些方法表明，条件可以作用于组成、对称性、几何结构或属性目标，而不一定只由网络输入端的标签完成。对本文而言，这些工作提供了一个重要背景：推理时改变采样轨迹已经成为材料生成的重要研究方向，但不同方法的约束对象、计算预算和安全判据并不相同。

2025—2026 年的工作进一步关注目标导向生成。MatterGen 展示了面向多种化学和标量条件的基础生成能力 [8]；PODGen 把多个性质预测器与生成模型结合，通过 MCMC 采样调整生成分布，并用于拓扑材料的目标搜索 [10]。SCIGEN 和 PODGen 都说明外部约束或预测模型可以在生成过程中改变候选分布，但它们与本文的研究接口不同：本文在冻结的 MatterGen 上保存精确 C0 参考轨迹，在有限候选预算下进行终点接受与回退；另一路则把经阶段校准的神经势原子力注入后期 position predictor。本文据此把贡献限定为两个具体的推理阶段方法，而不把一般的条件生成或约束采样重新命名为本文创新。

1.2.4 条件属性控制与引导生成

条件生成的目标是让样本分布同时满足结构先验和目标属性。常见实现包括在训练阶段把条件嵌入输入生成器、使用外部分类器或预测器提供梯度、采用分类器无关引导，以及在生成后进行候选筛选。分类器无关引导以同一网络产生条件和空条件预测，再按引导强度组合两者 [13]。它避免了单独训练分类器的接口成本，因此适合 MatterGen 这类已有条件适配模块的模型。

固定 CFG 强度的优点是规则清楚、运行成本可预测、容易进行配对比较。其局限在于，条件得分差异会随样本、字段和噪声阶段变化；一个适合某个阶段的强度不一定适合另一个阶段。PODGen 从外部预测器和 MCMC 角度调整采样分布，SCIGEN 则从结构约束角度改变去噪轨迹 [9, 10]。这些方向与本文关注的问题相近，但并不直接回答“在冻结 MatterGen 中，如何以有限额外预算保留一条可精确恢复的 C0 参考轨迹，并对候选终点实施安全回退”。

本文前期对多字段残差驱动的在线 Adaptive CFG 进行了机制分析。结果显示，反事实候选中存在可利用的属性改善空间，但简单在线控制在新样本上缺乏

稳定复现；学习型 Linear-K2 也没有在相同预算下确认优于固定策略。因此，最终问题被重新表述为参考保留、有限分支和终点验证，而不是把 Adaptive CFG 作为最终创新名称。这一表述与文献中的条件采样研究相容，同时避免把探索性控制器的失败过程包装成已验证方法。

1.2.5 神经网络原子间势与生成结构优化

神经网络原子间势 (MLIP) 学习结构与能量、力或应力之间的映射，以较低推理成本近似某一计算层级。M3GNet 采用包含三体相互作用的图网络，在较广元素范围内预测材料能量和力 [15]；NequIP 通过 $E(3)$ 等变特征提高数据效率和几何一致性 [16]；MACE 将高阶等变消息传递与原子簇展开结合，用于快速力场建模 [17]。CHGNet 在晶体图中引入电荷和磁矩相关信息，提供能量、力、应力和磁矩等预测 [18]；MatterSim 则面向广元素、温度和压力范围，原生输出能量、原子力和应力 [19]。

在材料发现流程中，MLIP 通常承担三个角色。第一，用于在大规模候选中快速估计能量或稳定性，减少昂贵计算调用；第二，作为结构松弛器，把生成候选推向当前代理势下的局部低能区域；第三，作为独立或交叉评价器，比较不同生成方法的局部受力、能量和结构偏移。GNoME 的工作也体现了机器学习势与大规模结构搜索、稳定性筛选结合的价值 [14]。但是，代理力较小只说明结构在所用势面上的局部一阶残差较小，不能直接等价于热力学稳定、实验可合成或 DFT 结论。

现有生成—评价流程多在终点调用 MLIP，或者把 MLIP 用作生成后的连续松弛器。相邻领域已经出现将力信息用于扩散采样的研究，例如 ConfDiff 将力引导思想用于蛋白质构象生成 [20]；这说明“外部物理方向进入扩散轨迹”具有一般方法背景，但蛋白质构象、无机晶体周期坐标和 MatterGen 三字段采样并不是同一问题。对无机晶体而言，神经势面对的是周期晶胞、分数坐标和元素组合，过早使用含噪结构进行力评价还可能引入不可靠反馈。

因此，本文第二条研究路线关注一个更窄的接口：先用预测干净结构与最终 MaxF 的阶段排序相关性确定可用的后期窗口，再将 MatterSim 笛卡尔力映射为周期分数坐标修正，并通过 predictor 的实际 score 系数注入位置更新。CHGNet 不参与在线反馈，用作跨势独立代理评估器。研究目标是检验生成期代理局部结构一致性是否改善，证据边界仍限定于冻结 MLIP 代理，且 `DFT_VERIFIED=false`。

1.2.6 现有研究的主要不足

综合上述研究，可以把与本文相关的不足归纳为两个相互独立的问题。

第一，冻结晶体生成模型仍可通过增加推理计算改善候选结果，但预算使用方式需要可核算。独立重复采样与共享前缀扩展均可形成候选集合；后者若要构

成有意义的方法，应明确状态恢复、候选数量、终点评价与参考回退，而不能仅把多采样产生的收益归因于某一脉冲策略。对冻结 MatterGen 而言，需要在与独立 Best-of-N 的对照中如实报告得分调用、验证器调用和代理偏差。

第二，神经势已经能够快速评价和松弛晶体，但生成模型与神经力场之间的在线接口仍有阶段可靠性和坐标变换问题。含噪结构不一定适合直接计算原子力；笛卡尔力也不能未经变换直接加到分数坐标上；没有幅度控制和异常回退时，外部反馈可能破坏周期几何或属性条件。因而需要在后期可靠窗口内进行有限、可审计的力反馈实验。

本文不把上述不足写成对全部现有方法的否定，也不声称两个方法在文献中没有任何相近思想。研究对象限定在当前实验接口：冻结 MatterGen 上的预算约束验证选择与参考回退，以及阶段可靠性校准的后期神经力场反馈。后续章节将分别给出两条路线的实现、确认实验和证据边界。

为了使研究问题可被计算机实验检验，本文进一步把“改进”拆成可观察的接口行为。属性路线要求候选必须从同一保存状态继续运行，候选数量和 score 调用量在实验前冻结，终点选择必须记录接受或回退原因；局部结构路线要求每次神经势调用对应明确的扩散阶段，力向量经坐标映射和幅度限制后才能进入位置更新，并保留异常时的原始 score。这样的定义把方法差异落实为状态、预算、坐标和分支决策，便于在相同种子下复现，而不是只依赖一次生成结果的事后解释。

在证据解释上，本文把代理模型当作有适用范围的计算工具。Property MAE、E-hull、Stable、Validity、MaxF、Mean Force 和 RMSD 分别描述条件误差、能量相对位置、几何与评价可用性以及局部受力或松弛偏移；它们不能被压缩成未经注册的综合分数。配对差异、置信区间、胜平负和跨代理方向共同决定结论强度，任何外部任务、不同 checkpoint 或真实实验结论都需要重新建立数据和验证流程。

1.3 本文研究内容

本文围绕无机晶体逆向生成中的条件属性控制和代理局部结构一致性开展研究，基础模型采用冻结的 MatterGen，研究阶段不重新训练主干权重。全文研究内容分为三个层次。

第一，分析 MatterGen 条件生成的推理机制。本文从固定 CFG 出发，拆分原子种类、位置和晶胞三个字段的条件—无条件得分残差，考察不同阶段、不同字段和不同样本的引导差异；随后通过反事实 Oracle、风险校准和字段归因实验判断潜在的候选改善空间及在线控制风险。这部分工作的作用是确定问题结构，为最终方法选择提供机制证据，不把探索性 Adaptive CFG 当作最终贡献。

第二，提出面向冻结 MatterGen 的预算约束验证选择推理框架。框架定义参考轨迹状态、有限候选后缀、生成预算、终点验证器与参考回退；Fixed-K2 是在共享前缀后固定扩展 GPulse 和 PPulse 的已确认实例。其 C1-128 结果与独立

Best-of-2 对照分属不同全新 cohort，不能混合绝对均值。独立 Best-of-2 数值上更低、直接配对差异区间跨零，说明额外计算本身有竞争力，不能声称 Fixed-K2 超越一般 Best-of-N。学习型 Linear-K2 作为负结果保留，当前样本级候选分配没有得到独立支持。

第三，提出基于阶段可靠性校准的后期神经力场引导扩散方法 RC-NFGD。该方法先比较多个扩散阶段的预测干净结构 MaxF 与最终结构 MaxF 的排序一致性，冻结后期介入窗口；然后调用 MatterSim 计算原子力，将去平移、归一化和有界的笛卡尔力位移转换为分数坐标修正，并补偿 position predictor 的 score 系数。原子类型、晶胞和 corrector 保持 MatterGen 原有更新，异常情况执行安全回退；Formal256 使用 CHGNet 作为未参与在线力反馈的独立代理评估器。

上述研究内容对应两类不同目标。预算约束验证选择通过 Fixed-K2 实例在原始 C1-128 上改善代理目标属性误差，代价是约 2.2 倍 MatterGen score 调用；新的独立 Best-of-2 与 K=0-4 扩展实验分别检验多采样竞争性及预算—性能关系，而非重新定义 C1 结论。RC-NFGD 主要改善神经势代理下的局部受力和松弛位移，Property MAE 存在轻微代价。两者都通过配对种子和冻结指标进行评价，但当前联合兼容实验未支持协同增益，因此论文分别报告两项创新。

表 1-2: 本文研究问题与技术路线

Tab. 1-2: Research Questions and Technical Route of This Thesis

研究问题	现有技术限制	本文研究方向	对应章节
冻结模型的推理预算与属性控制	多采样收益和候选策略收益易混淆；直接在线调整存在风险	参考轨迹、预算约束候选扩展、验证选择及独立 Best-of-2 对照	第 3 章
局部结构一致性	生成模型缺少显式局部力反馈，早期力信号可靠性不足	阶段可靠性校准、后期 MatterSim 力反馈和周期坐标映射	第 4 章
统一证据解释	代理模型、配对随机性和不同目标可能混淆	冻结协议、配对统计、CHGNet 交叉评价和边界审计	第 5 章

1.4 本文主要创新点

1.4.1 面向冻结扩散生成模型的预算约束验证选择推理增强方法

针对冻结生成模型的额外推理计算如何得到可审计利用的问题，本文提出预算约束验证选择推理框架（Budget-Constrained Verifier-Guided Inference Framework）。框架将采样状态与随机数状态、候选后缀、终点代理验证器及回退输出纳入同一预算接口；它不是重新训练的生成模型，也不是新的 CFG 调度公式。固定双候选 Fixed-K2 是该框架的一个实例：保留完整 C0 状态，在共享前缀后扩展 GPulse 和 PPulse，并仅接受属性严格改善且通过冻结代理质量条件的终点。

在 C1-128 完全独立配对种子上，Fixed-K2 将代理 Property MAE 从 0.034796 降至 0.026332，相对改善 24.32%，并通过预注册的 E-hull、Stable、NUS 和 Validity 代理护栏，部署计算量约为 C0 的 2.2 倍。新增独立 Best-of-2 对照的均值为 0.028097，Fixed-K2 为 0.029506，差异区间跨零且两者预算不等，因此不能宣称共享前缀分支优于独立 Best-of-N。另一个独立预算实验显示 K=2 不是最低误差点。Linear-K2 在 Phase B 和 C1 中均未确认优于 Fixed-K2。因此本创新点的正式表述是可核算、可回退的推理框架及其固定预算实例，而不是最优搜索算法、学习型分配或稳定有效的 Adaptive CFG。

1.4.2 基于阶段可靠性校准的后期神经力场引导扩散方法

针对属性条件满足但生成结构仍可能具有较高代理受力的问题，本文提出基于阶段可靠性校准的后期神经力场引导扩散方法（Reliability-Calibrated Late-stage Neural Force-Guided Diffusion, RC-NFGD）。方法先用预测干净结构与终态 MaxF 的排序相关性冻结后期介入窗口，再将 MatterSim 原子力经周期坐标映射为仅作用于 position predictor 的得分修正，并使用有界位置修正和异常安全回退。

Formal256 上，RC-NFGD 使 MatterSim MaxF、Mean Force 和松弛 RMSD 分别降低 29.81%、29.72% 和 14.17%；CHGNet 独立代理评估器给出方向一致但较弱的均值力改善。与此同时，Property MAE 轻微恶化 1.14%，部分 CHGNet 尾部指标呈混合结果，等预算生成后 POST 在同一 MatterSim 指标上更低，且本研究没有执行 DFT。因此，本创新点应表述为得到确认的在线代理力反馈方法，不能扩展为真实热力学稳定性、已经完成 DFT 检验或所有替代方法中的最优方案。

两项创新分别针对推理预算下的条件属性控制和物理反馈下的代理局部结构一致性，构成同一冻结生成模型上的两类独立推理机制。当前联合兼容实验状态为 JOINT_SYNERGY=NOT_SUPPORTED，论文不把二者写成已验证的联合模型。




图 1-1: 本文总体技术路线

Fig. 1-1: Overall Technical Route of This Thesis

补充的历史 A6 Pareto 分析把 RC-NFGD 与 POST 放在同一属性—代理力平面，明确 POST 的同势终态 MaxF 更低且属性差异不确定。全新 32 对种子的 Early/Middle/Late 注入阶段消融表明，原始 Late 相对同 cohort C0 改善 MaxF，但 Late 与另外两个阶段的直接区间跨零，各阶段力调用次数也不相等。因此本文贡献的是可审计的生成期神经力反馈接口及其冻结验证，不是最优注入时机或对所有后处理方案的优势。

1.5 技术路线

本文技术路线以冻结 MatterGen 为共同起点，从条件属性控制和局部结构物理反馈两条独立路线展开。首先统一使用 C0 进行配对采样和基线评价，然后对两个问题分别进行机制分析、方法冻结和确认性实验。最终使用 MatterSim、CHGNet 及统一的 Property MAE、E-hull、Stable、Validity、Novel、Unique、NUS、MaxF、Mean Force 和 RMSD 指标进行综合分析。

图 1-1 用两条并行路线表示这一过程。上方路线从单轨迹在线控制的局限转向预算约束验证选择，Fixed-K2 只是共享前缀、双候选与终点回退的固定预算实例；独立 Best-of-2 和预算扩展实验属于该路线的边界检验。下方路线分析预测干净结构的阶段可靠性，经过周期坐标映射、有界位置修正和安全回退后形成 RC-NFGD。两条路线共享基础模型、配对统计和代理评价框架，但研究目标、额外计算成本和主要结论分别冻结。统一评价阶段同时保留代理模型边界、负消融结果和未验证的联合协同状态。

1.6 论文组织结构

第 1 章为绪论，介绍材料逆向生成的研究背景、代表性研究路线、现有问题、本文研究内容、两个创新点、技术路线和论文结构。

第 2 章为相关理论与关键技术，统一说明晶体的原子种类—周期分数坐标—晶胞表示、扩散生成、score 和 CFG，介绍 MatterGen 的三字段联合生成、GemNetT 去噪网络、神经网络原子间势、MatterSim 和 CHGNet，并定义后续章节使用的评价指标和配对统计方法。

第 3 章研究面向冻结扩散生成模型的预算约束验证选择推理方法。该章先定义推理预算问题、保留在线 Adaptive CFG 的失败诊断，再给出参考状态、候选扩展、终点验证与回退算法；随后报告 Fixed-K2 的 C1-128 确认、Linear-K2 负结果、独立 Best-of-2 对照及 K=0-4 预算扩展。

第 4 章研究基于阶段可靠性校准的后期神经力场引导扩散方法 RC-NFGD。该章介绍预测干净结构的阶段诊断、MatterSim 力计算、笛卡尔—分数坐标映射、position predictor 注入、有界修正和安全回退，并通过 P0、Formal32、Formal256 和 CHGNet 交叉代理评价检验方法。

第 5 章在统一的冻结证据体系下综合比较两项创新，讨论属性精度、代理局部结构一致性、计算代价、跨代理方向、负消融、POST 竞争基线及联合兼容性，明确当前结论的适用范围和未解决问题。

第 6 章总结全文工作，归纳两个创新点的主要结论、代理评价和计算成本边界，并展望跨属性、跨模型、DFT/实验验证及经重新预注册的联合方法研究。

1.7 本章小结

本章从材料搜索空间和逆向设计需求出发，回顾了晶体生成模型、扩散生成、条件属性控制和神经网络原子间势的发展。现有工作已经能够处理周期晶体表示、组成或空间群条件以及面向性质的候选生成，但在冻结生成模型中如何以受控预算进行安全的推理时选择，以及如何在可靠后期把神经势力反馈接入周期扩散轨迹，仍具有明确的研究价值。

围绕这两个问题，本文以 MatterGen 为冻结基础模型，分别提出预算约束验证选择推理框架及其 Fixed-K2 实例，以及 RC-NFGD。前者面向代理属性控制，后者面向代理局部结构一致性；两者独立评价，联合协同不作结论。第 2 章将进一步介绍本文涉及的晶体表示、扩散生成、条件引导和神经网络原子间势等理论基础。

2 相关理论与关键技术

本章围绕第 3 章和第 4 章实际使用的理论与技术建立统一基础。首先说明材料逆向设计中的晶体生成任务及其周期表示；随后介绍扩散生成、时间相关 score、预测干净结构和分类器无关引导；在此基础上说明 MatterGen 的三字段联合生成框架；最后给出神经网络原子间势、MatterSim、CHGNet 以及本文评价指标与配对统计的定义。MatterGen 是本文采用的基础生成模型，而不是本文提出的模型；本文的研究对象是在冻结 MatterGen 权重基础上的推理阶段条件引导与后期神经力场反馈。还需预先强调，本文未将密度泛函理论（density functional theory, DFT）作为正式实验评价环节，后续物理与属性结果主要来自冻结的机器学习代理模型，即 `DFT_VERIFIED=false`。

2.1 材料逆向设计与晶体生成问题

材料性质预测通常研究“结构到性质”的正向映射：给定元素组成、原子排布和晶胞，预测能量、力、磁性或力学性质。材料逆向设计则从目标约束出发，寻找可能满足约束的候选晶体，即从“目标性质”反推“候选结构”。正向问题在一个给定结构上产生性质估计，逆向问题却往往对应多个可能解；不同组成和几何结构可能具有相近性质，同一结构的性质还会受计算层级、磁序和松弛状态影响。因此，逆向设计不是对正向模型的简单代数求逆，而是在巨大结构空间中进行受约束生成与筛选。

晶体生成空间同时包含离散变量和连续变量。原子种类属于离散类别；周期分数坐标和晶胞参数属于连续变量；原子数、元素组合及其计量比又产生组合复杂性。与此同时，晶体必须满足周期边界，等价晶胞或整数晶格平移可以表示同一个无限周期结构。生成模型因而不仅要给出“有哪些元素”，还要联合给出“原子位于晶胞中的何处”和“晶胞本身是什么形状与尺度”。在属性条件存在时，模型还需使所生成分布向目标性质偏移，同时避免几何无效、代理能量过高或局部受力过大。

本文将一个含 N 个原子的晶体写为

$$\mathcal{C} = (a, f, H), \quad (2-1)$$

其中， a 表示原子种类， $f \in [0, 1)^{N \times 3}$ 表示分数坐标， $H \in \mathbb{R}^{3 \times 3}$ 表示晶胞矩阵。它们分别对应代码中的 `atomic_numbers`、`pos` 和 `cell`。后续章节分别从两个方面改进冻结生成过程：第 3 章研究属性条件引导，第 4 章研究生成后期的代理原子力反馈。两者都建立在上述离散—连续耦合表示上。

2.2 晶体结构表示与周期性

2.2.1 晶体基本表示

有限分子可以直接用一组笛卡尔坐标描述，而理想晶体通过晶胞在三维空间中的平移重复表示。晶胞矩阵 H 的三行按照本文实现约定存放三个晶格基向量，原子种类 a_i 和分数坐标 f_i 则描述第 i 个晶胞内原子。分数坐标是相对于晶格基的无量纲系数；在本文统一采用的行向量约定下，分数坐标到笛卡尔坐标的关系为

$$r_i = f_i H, \quad (2-2)$$

其中 $r_i \in \mathbb{R}^3$ 的单位为 Å。反向变换为 $f_i = r_i H^{-1}$ ，因此有效晶胞至少要求 H 非奇异。该行向量关系与第 4 章及冻结实现中 `scaled_positions`、`ASE cell.array` 的用法一致；不能将采用列向量约定的教科书公式直接照搬而遗漏转置。

表 2-1: 本文主要符号
Tab. 2-1: Main Symbols Used in This Thesis

符号	含义	使用说明
x_t	时间 t 的含噪扩散状态	通用扩散概念
x_0	干净结构或扩散终态	与预测量区分
$\hat{x}_0(x_t, t)$	从当前状态恢复的预测干净结构	三字段分别解析
z_t	MatterGen 完整采样器状态包含原子、位置、晶胞等内部状态	
a_t, p_t, H_t	原子种类、位置、晶胞字段对应 <code>atomic_numbers</code> 、 <code>pos</code> 、 <code>cell</code>	
f_t	位置字段在时刻 t 的分数坐标状态	第 4 章进行笛卡尔—分数坐标映射时使用
r_i, F_i	第 i 个原子的笛卡尔坐标	$r_i = f_i H$, F_i 单位为 eV/Å 与力
$s_{\text{cond}}, s_{\text{uncond}}$	条件与无条件得分	CFG 的两个预测分量
g	CFG 强度	全文统一的引导强度符号
$\Delta_a, \Delta_p, \Delta_H$	三字段条件—无条件得分残差	分别对应原子、位置、晶胞字段

2.2.2 晶胞、分数坐标与周期邻域

晶胞体积为 $V = |\det H|$ 。改变 H 会同时改变晶体的尺度、夹角、体积以及分数位移对应的实际笛卡尔距离。因此，位置字段和晶胞字段虽然可以采用不同的扩散过程，却不能在反向生成时被理解为彼此无关。MatterGen 的几何网络在当前晶胞下构造周期邻域，使跨越晶胞边界但在真实空间相邻的原子仍能交换信息 [8]。

分数坐标的周期等价关系为

$$f_i \sim f_i + n, \quad n \in \mathbb{Z}^3. \quad (2-3)$$

因此，将分数坐标逐分量映射回 $[0, 1)$ 的 wrap 操作不会改变其表示的无限周期位置。计算原子间距时也不能只用同一晶胞内的坐标差，而应考虑整数晶格平移。常用的最小镜像分数位移可写为

$$\Delta f_{ij}^{\text{mic}} = \Delta f_{ij} - \text{round}(\Delta f_{ij}), \quad \Delta r_{ij}^{\text{mic}} = \Delta f_{ij}^{\text{mic}} H, \quad (2-4)$$

其中 $\Delta f_{ij} = f_j - f_i$ 。对一般非正交晶胞，实际实现由周期邻域或结构库完成完整搜索，式 (2-4) 主要用于说明周期等价和坐标映射的基本思想，而不是替代所有晶胞几何算法。

2.2.3 结构等价性与本文所需边界

同一无限晶体可能由不同原子排序、整体整数平移或等价晶胞表示。本文的 Unique 与 Novel 因而依赖周期结构匹配器，而不是逐元素比较原始坐标数组。相反，第 3 章的“精确参考轨迹”比较的是同一实现、同一状态和同一随机数历史下的采样结果，需要原子字段、位置字段和晶胞字段精确复现；这是一种计算可复现性检查，不等同于宽容差的晶体学结构等价判断。

图 2-1 给出本文行向量坐标约定及周期复制关系。周期性说明了第 4 章为何需要先将笛卡尔原子力形成的位移映射为分数坐标修正，再执行 wrap，而不能直接把带 Å 单位的位移加到无量纲位置状态上。

2.3 扩散生成模型基础

2.3.1 前向扩散过程

扩散模型通过一个预先规定、逐步增加噪声的前向过程，把复杂数据分布变换为易采样的先验分布；神经网络学习其反向去噪过程，从先验噪声逐步恢复样本 [11]。以欧氏连续变量上的离散 DDPM 为直观示例，单步前向转移可写为




图 2-1: 晶体结构的晶胞、分数坐标与周期映射示意图
Fig. 2-1: Schematic of Crystal Cells, Fractional Coordinates, and Periodic Mapping

$$q(x_t | x_{t-1}) = \mathcal{N}(x_t; \sqrt{1 - \beta_t} x_{t-1}, \beta_t I), \quad (2-5)$$

其中 β_t 是第 t 步噪声强度。记 $\alpha_t = 1 - \beta_t$ 、 $\bar{\alpha}_t = \prod_{j=1}^t \alpha_j$ ，则可以直接从干净样本得到任意时刻状态：

$$q(x_t | x_0) = \mathcal{N}(x_t; \sqrt{\bar{\alpha}_t} x_0, (1 - \bar{\alpha}_t) I). \quad (2-6)$$

式 (2-5) 和式 (2-6) 用于建立扩散直觉，并不意味着 MatterGen 是对三个字段统一施加高斯噪声的普通 DDPM。MatterGen 根据字段几何选择不同 corruption：原子种类采用带 [MASK] 吸收态的离散扩散，周期分数坐标采用 wrapped-normal 的方差爆炸过程，晶胞采用具有原子数相关极限均值和方差的方差保持过程 [8]。三字段的前向转移可以条件独立地定义，但反向网络通过共享晶体图联合预测，它们在生成语义上仍然耦合。

2.3.2 反向生成过程

反向模型用参数化转移 $p_\theta(x_{t-1} | x_t)$ 逐步去除噪声：

$$p_\theta(x_{0:T-1} | x_T) = \prod_{t=1}^T p_\theta(x_{t-1} | x_t), \quad x_T \sim p_T. \quad (2-7)$$

采样从先验状态开始，经多个时间步得到 x_0 。在连续时间表示中，正向过程可写成随机微分方程；对应的反向时间随机微分方程由漂移项、扩散系数和时间相关 score 共同决定 [12]。数值求解时，predictor 负责沿离散化的反向动力学推进，corrector 可在当前噪声尺度上进一步校正样本。本文只在后续方法需要时区分 predictor 与 corrector，不修改其一般数值理论。




图 2-2: 扩散模型前向加噪与反向生成示意图

Fig. 2-2: Forward Noising and Reverse Generation in Diffusion Models

2.3.3 Score-based 建模

对时间 t 的扰动分布 $p_t(x_t)$, score 定义为其对数密度关于状态的梯度。时间相关网络的目标可概括为

$$s_\theta(x_t, t) \approx \nabla_{x_t} \log p_t(x_t). \quad (2-8)$$

score 指向局部对数密度增大的方向, 但它不是材料势能的负梯度, 也不是原子力。Score-SDE 的反向过程可写为

$$dx = [b(x, t) - \sigma^2(t) \nabla_x \log p_t(x)] dt + \sigma(t) d\bar{W}_t, \quad (2-9)$$

其中 $b(x, t)$ 和 $\sigma(t)$ 分别表示正向过程的漂移与扩散系数, $\bar{W}_t$ 表示反向时间的 Wiener 过程 [12]。神经网络用式 (2-8) 的估计替代未知的真实 score。后文中的条件得分、无条件得分以及位置得分修正都属于生成分布层面的量; 第 4 章的神经势原子力则来自另一套能量模型, 两者只有经过明确坐标变换和采样器系数换算后才能组合。

2.3.4 预测干净结构

给定含噪状态 x_t 和模型输出, 可以构造模型当前认为的干净结构估计 $\hat{x}_0(x_t, t)$, 本文称为“预测干净结构” (predicted clean structure)。它不是已经完成采样的 x_0 , 也不必等于最终结构; 其作用是把当前噪声状态转换为一个可由晶体评价器读取的暂态结构估计。

MatterGen 的三个字段采用不同 corruption, 因而不存在一个可无条件替换实际实现的通用 $\hat{x}_0$ 公式。按照第 4 章所用冻结代码, 设模型对三字段的输出分别为 s_t^a, s_t^f, s_t^H , 离散原子类别偏移为 o_a , 位置边缘标准差为 $\sigma_f(t)$, 晶胞均值系

数与标准差为 $\alpha_H(t), \sigma_H(t)$, 晶胞极限均值为 M_∞ , 则分别恢复为

$$\hat{a}_{0,i} = \arg \max_k s_t^a(i, k) + o_a, \quad (2-10)$$

$$\hat{f}_0 = \text{wrap}\left(f_t + \sigma_f^2(t)s_t^f\right), \quad (2-11)$$

$$\hat{H}_0 = \frac{H_t + \sigma_H^2(t)s_t^H - [1 - \alpha_H(t)]M_\infty}{\alpha_H(t)}. \quad (2-12)$$

三者共同构成可评价的 $(\hat{a}_0, \hat{f}_0, \hat{H}_0)$ 。第 4 章正是先从后期状态构造该预测干净结构, 再调用 MatterSim 计算代理原子力; 它不会把三个估计直接覆盖当前采样状态。

2.4 条件扩散与分类器无关引导

2.4.1 条件生成

无条件扩散学习总体晶体分布, 条件扩散则学习给定条件 c 时的分布。条件可以是化学体系、空间群或标量性质, 网络相应估计

$$s_\theta(x_t, t, c) \approx \nabla_{x_t} \log p_t(x_t | c). \quad (2-13)$$

MatterGen 先预训练基础 score 网络, 再通过条件适配模块利用带标签数据进行微调, 使模型能够接收性质嵌入 [8]。本文实验使用 `dft_mag_density` 作为一个具体条件实例, 但这不表示 MatterGen 只能处理磁性密度; 其原始框架还支持化学、对称性及其他标量性质条件。

2.4.2 分类器无关引导

分类器无关引导 (classifier-free guidance, CFG) 通过同一生成网络的条件预测和空条件预测构造引导得分, 不需要额外分类器 [13]。本文统一使用

$$s_{\text{CFG}}(x_t, t, c) = s_{\text{uncond}}(x_t, t) + g[s_{\text{cond}}(x_t, t, c) - s_{\text{uncond}}(x_t, t)], \quad (2-14)$$

其中 g 为 CFG 强度。当 $g = 0$ 时得到无条件预测, $g = 1$ 时得到条件预测; $g > 1$ 沿条件相对无条件的方向作外推, 从而强化条件作用。强化条件方向通常会改变条件符合度与样本分布覆盖或生成质量之间的权衡, 其影响依赖模型、样本、字段和噪声阶段, 不能仅由式 (2-14) 推断某个更大的 g 必然更优。




图 2-3: 条件与无条件得分构成 CFG 的示意图

Fig. 2-3: Construction of CFG from Conditional and Unconditional Scores

2.4.3 条件—无条件预测差异

式 (2-14) 的核心差异项可按 MatterGen 字段写为

$$\Delta_a = s_{\text{cond},a} - s_{\text{uncond},a}, \quad \Delta_p = s_{\text{cond},p} - s_{\text{uncond},p}, \quad \Delta_H = s_{\text{cond},H} - s_{\text{uncond},H}. \quad (2-15)$$

这些差异描述条件信息如何改变当前三字段预测，为第 3 章的多字段残差分析提供直接理论来源。需要区分“存在条件影响”和“该影响可被可靠控制”：残差的大小可以用作描述量，却不自动等价于终点属性收益、结构质量或安全动作。它能否作为样本级、阶段级在线控制信号，必须由独立实验检验。

标准 CFG 常在整个采样过程中使用预设强度。第 3 章在此基础上研究引导强度在样本、阶段和字段维度上的优化空间，并进一步讨论共享前缀、候选分支和精确参考轨迹。共享前缀的可比性依赖在分支点同时保存完整 z_t 与随机数生成器状态；它属于采样状态管理，而不是 CFG 公式本身的性质。本章只提供条件引导基础，不提前给出第 3 章的方法效果。

2.5 MatterGen 晶体生成模型

2.5.1 总体框架

MatterGen 是面向无机晶体逆向设计的扩散生成模型，生成过程从随机先验状态出发，逐步联合细化原子种类、周期坐标和晶胞；条件适配模块使其能够按目标化学、对称性或标量性质生成候选结构 [8]。原论文针对晶体周期性和字段几何分别设计 corruption，而不是把晶体简单栅格化为图像。本文直接采用其模型与 checkpoint 作为基础生成器，研究重点是冻结权重后的推理阶段方法。




图 2-4: MatterGen 三字段条件生成总体流程

Fig. 2-4: Overall Workflow of MatterGen Three-Field Conditional Generation

2.5.2 三字段联合生成

表 2-2: MatterGen 三类生成字段

Tab. 2-2: Three Generation Fields of MatterGen

规范名称	代码字段	数据性质	前向 corruption 与网络输出要点
原子种类字段	<code>atomic_numbers</code>	离散类别	带 [MASK] 吸收态的离散扩散；输出干净原子类别的 logits
位置字段	<code>pos</code>	周期分数坐标	wrapped-normal 方差爆炸扩散；输出与周期坐标去噪相关的 score
晶胞字段	<code>cell</code>	连续 3×3 矩阵	原子数相关极限分布的方差保持扩散；输出晶胞 score

三字段的前向 corruption 形式不同，却由同一个几何网络基于当前完整晶体联合预测。原子类型会影响局部化学环境，位置决定邻接距离和方向，晶胞又规定周期映射与空间尺度。因此，“分别输出”不等于“三个独立模型”。第 3 章可对三个字段分别设置 g_a, g_p, g_H ，是因为代码输出保留字段边界；字段解耦引导改变的是条件与无条件输出的组合系数，不改变基础网络的联合建模事实。

2.5.3 GemNetT 去噪网络

本项目配置中的核心去噪器为 **GemNetTDenoiser**，其几何主干为 **GemNetT**。**GemNet** 属于利用方向信息和多体几何关系的消息传递图神经网络 [22]；**MatterGen** 在此基础上使用适配的 **GemNet-dT** 结构，对周期晶体图中的局部环境进行建模，并输出原子类别、位置和晶胞相关预测 [8]。本地冻结配置与论文描述一致：模型通过当前分数坐标和晶胞即时构建周期邻域；位置头先产生笛卡尔等变输出，再依据当前晶胞转换为分数坐标 score ；晶胞头输出与晶胞更新有关的张量；原子头输出类别 logits。

这类网络需要满足与任务相符的几何性质：整体平移不应改变晶体语义，旋转晶体时向量输出应相应旋转，原子重新排序不应改变结构级结果。周期邻域还使位于相邻晶胞镜像中的近邻参与消息传递。上述设计解释了为什么 **MatterGen** 能够在在一个网络中耦合化学与几何字段，也解释了第 4 章只修改位置 predictor 时仍需保留原子和晶胞预测。

2.5.4 条件属性控制与采样

MatterGen 的适配模块把条件嵌入注入几何网络的消息传递层，微调后同一网络可通过真实条件嵌入给出 s_{cond} ，通过空条件嵌入给出 s_{uncond} [8]。采样器再按式 (2-14) 组合输出。由于三个字段具有不同张量形状和数值尺度，字段残差必须先在各自空间中定义，不能直接拼接后把单一范数解释为统一物理量。

本文后续将固定 CFG 强度 $g = 2.0$ 的 **MatterGen** 参考基线记为 C0。该命名只用于统一第 3 章的比较口径，不改变 **MatterGen** 是本文基础模型而非原创模型的定位。

从论文结构上看，**MatterGen** 提供了共同技术底座：第 3 章改变三字段 CFG 的推理时组织方式，第 4 章在经诊断选定的后期 predictor 事件中向位置 score 增加外部反馈。二者都不重新训练 **MatterGen** 主干，也不能被表述为“本文提出 **MatterGen**”。

2.6 神经网络原子间势与原子力

2.6.1 势能面与局部结构

对原子种类 a 、笛卡尔坐标 r 和晶胞 H ，原子体系可对应一个势能函数 $E(r, H, a)$ 。在给定晶胞和电子结构近似下，第 i 个原子的力满足

$$F_i = -\nabla_{r_i} E(r, H, a). \quad (2-16)$$

力是能量对局部坐标变化的负梯度，描述在当前势能面上降低能量的瞬时方

向。结构松弛通常迭代更新原子位置及必要的晶胞自由度，直到力或应力满足停止条件。生成结构的较大原子力说明至少部分原子在所用势能面上偏离局部平衡；较小原子力则表示该代理势下的局部一阶残差较小，但不能单独推出全局最低能、热力学稳定或实验可合成。

必须区分几个常被混用的概念。原子力是局部能量梯度；形成能比较化合物与元素参考态的能量；E-hull 比较同一化学组成相对于竞争相凸包的能量距离；热力学稳定性涉及竞争相及给定热力学条件；局部结构松弛只寻找邻近势阱中的较低能构型。第 4 章关注 MaxF、Mean Force 和松弛 RMSD 所描述的代理局部结构一致性，不把它们等同于 E-hull 或真实热力学稳定性。

2.6.2 力相关指标

对含 N 个原子的结构，本文使用

$$\text{MaxF}(\mathcal{C}) = \max_i \|F_i\|_2, \quad \text{MeanF}(\mathcal{C}) = \frac{1}{N} \sum_{i=1}^N \|F_i\|_2. \quad (2-17)$$

两者单位均为 eV/Å。Mean Force 是“各原子力范数的均值”，不是合力均值的范数；周期体系总力可能因平移对称性接近零，却仍存在较大的成对局部受力。MaxF 对最差局部环境敏感，Mean Force 则概括整体受力水平。

2.6.3 神经网络原子间势

DFT 可从电子结构近似出发计算能量、力和应力，但大量生成样本、反复松弛或在线逐步调用的计算成本较高。机器学习原子间势（machine-learning interatomic potential, MLIP）通过第一性原理数据学习从结构到能量、力和应力的映射，以较低推理成本近似目标计算层级，适用于候选筛选、结构松弛和生成过程反馈。

MLIP 的输出仍受训练数据覆盖、模型结构和参考计算设置限制。在分布外结构、异常短键或未覆盖化学环境上，预测误差可能增大；不同 MLIP 即使整体精度良好，也可能对同一结构给出不同力排序。因此，本文把 MLIP 结果称为代理评价，不将其写为 DFT 或实验真值。RC-NFGD 使用的“神经力场”特指 MLIP 给出的能量梯度力反馈。

2.7 MatterSim 与 CHGNet

2.7.1 MatterSim

MatterSim 是利用大规模第一性原理数据训练的深度学习原子模型，可原生预测能量、原子力和应力，并面向广元素、温度和压力范围的原子模拟 [19]。在




图 2-5: 神经势的结构—能量—原子力关系示意图

Fig. 2-5: Relationship among Structure, Energy, and Atomic Forces in a Neural Potential

本文冻结流程中使用 MatterSim-5M checkpoint, 但不据此假设它对任意生成中间态都同样可靠。第 4 章先利用预测干净结构进行阶段诊断, 只在后期窗口把 MatterSim 力作为位置反馈。

MatterSim 在本文有两种角色: 一是 RC-NFGD 的在线神经力场引导器, 二是终态能量、力和松弛相关指标的代理评价器。两种角色使用同一模型会带来同源代理评价风险: 方法可能更容易改善提供反馈的势函数, 而这种改善未必在另一势或 DFT 上等幅保持。因此, 第 4 章还使用未参与在线引导的 CHGNet 检查跨代理方向。

2.7.2 CHGNet

CHGNet 全称为 Crystal Hamiltonian Graph Neural Network, 是一种结合晶体图表示与磁矩信息训练的神经网络原子间势, 可预测能量、力、应力和磁矩等量 [18]。本文一方面使用冻结 CHGNet 输出构造目标磁性密度代理属性误差, 另一方面用其力预测对 RC-NFGD 终态进行独立代理评估。

“独立代理评估器”仅表示 CHGNet 不参与 RC-NFGD 的在线力反馈, 并不表示它是 DFT 真值; 其训练数据也未被视为与其他模型完全独立。CHGNet 与 MatterSim 的跨势方向一致性能降低单一评价器自洽的疑虑, 却不能替代 DFT、实验合成、声子或长时间分子动力学验证。

2.7.3 本文中的角色区别

表 2-3: MatterSim 与 CHGNet 在本文中的角色
Tab. 2-3: Roles of MatterSim and CHGNet in This Thesis

模型	主要输入/输出 本文作用	是否参与 RC-NFGD
		在线生成证据边界
MatterSim	晶体结构 → 能神经力场引导; 量、力、应力 同源代理评价	是不是 DFT, 存 在同源评价风 险
CHGNet	晶体结构 → 能属性代理; 独 量、力、应力、立代理评估器 磁矩	否独立性仅相对 在线引导, 不 是真值验证

这一角色区分贯穿第 3—5 章: Property MAE、E-hull、Stable、MaxF 等名称必须同时说明实际代理来源; 不能因为模型以 DFT 数据训练, 就把本论文的代理推理结果称为“DFT 验证”。

2.8 评价指标与统计分析

2.8.1 属性误差

设第 i 个样本的冻结属性代理预测为 $\hat{c}_i$, 目标条件为 c_i^* , 本文的 Property MAE 为

$$E_{\text{prop}} = \frac{1}{n} \sum_{i=1}^n |\hat{c}_i - c_i^*|. \quad (2-18)$$

该值越低, 表示在所用属性代理模型下, 生成结果与目标条件的平均绝对偏差越小。它不是相对于真实实验标签重新测得的通用模型 MAE。不同实验可以设置不同目标值; `dft_mag_density` 是本文的条件实例, 具体目标和代理 checkpoint 以相应冻结协议为准。

2.8.2 稳定性、有效性与分布指标

E-hull (energy above convex hull) 描述候选能量相对同一组成竞争相凸包的距离。按本文评价器的每原子口径, 可概括为

$$h(\mathcal{C}) = E_{\text{sur}}(\mathcal{C})/N - E_{\text{hull}}(\text{comp}(\mathcal{C})), \quad (2-19)$$

其中 E_{sur} 是冻结代理能量, 参考凸包由相应参考数据构建。本文报告的是 surrogate-based E-hull, 而不是本论文新执行的 DFT E-hull。冻结评价器把

$$s(\mathcal{C}) = \mathbb{I}[h(\mathcal{C}) \leq 0.1 \text{ eV/atom}] \quad (2-20)$$

定义为 Stable。该二值规则表示候选是否落在代理凸包上方 0.1 eV/atom 阈值内；它不等同于有限温度热力学稳定、动力学稳定或可合成性。

Validity 按冻结确认管线的实际实现解释。首先，结构需非空，晶胞有限且体积（行列式）大于 $0.1 \text{ \AA}^3$ ，最小周期原子间距不小于 $0.5 \text{ \AA}$ ；随后还需成功转换为结构对象，得到有限属性预测，并完成冻结质量评价。第 3 章确认代码中的 `evaluation_valid` 是结构/属性可评价与质量评价成功的合取。MatterGen 官方评价器另有基于 SMACT 的 composition validity 指标；除非章节明确报告该指标，本文的 Validity 不自动等同于 SMACT 组成有效性。

Novel 表示结构匹配器在冻结参考数据集中找不到等价结构；Unique 表示在当前生成集合的每个结构等价类中计入一个代表。两者都依赖周期结构匹配规则，不是字符串或坐标精确相等。NUS 在本文实现中是 Novel、Unique 与 Stable 的交集：

$$\text{NUS}(\mathcal{C}) = \mathbb{I}[\text{Novel}(\mathcal{C})] \mathbb{I}[\text{Unique}(\mathcal{C})] s(\mathcal{C}). \quad (2-21)$$

NUS 是集合级候选质量指标，不应被写成逐样本层面的真实物理安全证明。

2.8.3 原子力与结构偏移指标

MaxF 与 Mean Force 已由式 (2-17) 定义，数值越低表示所用 MLIP 势面上的最大或平均局部受力更小。本文 RMSD 的参照对象是同一候选的生成前结构与代理势松弛后结构。评价器在周期结构匹配、原子对应和必要的结构预处理后，以 $\text{\AA}$ 为单位计算原子位移的均方根：

$$\text{RMSD} = \sqrt{\frac{1}{N} \sum_{i=1}^N \|r_i^{\text{relaxed}} - r_i^{\text{generated}}\|_2^2}. \quad (2-22)$$

式 (2-22) 表达其物理含义；真实实现还处理周期镜像、晶胞匹配和原子对齐，不能用未经匹配的原始数组差替代。较小 RMSD 表示在当前代理松弛协议下所需几何调整较小，但仍不是 DFT 局部极小或真实热力学结论的充分条件。

表 2-4: 本文主要评价指标

Tab. 2-4: Main Evaluation Metrics Used in This Thesis

指标	冻结口径	有利方向主要边界
Property MAE	代理属性与目标条件的平均绝对误差	低依赖属性代理

指标	冻结口径	有利方向主要边界
E-hull	代理每原子能量相对参考凸包	低非本论文 DFT E-hull
Stable	E-hull 不高于 0.1 eV/atom 的比例	高代理阈值判断
Validity	几何、有限预测与完整评价成功	高不自动等同 SMACT 组成有效性
Novel	未匹配冻结参考数据	高依赖参考集和匹配器
Unique	生成集合内每个结构等价类计一个代表	高依赖集合规模和匹配器
NUS	Novel、Unique 且 Stable	高三者交集，非真实可合成率
MaxF	$\max_i \ F_i\ _2$	低代理势局部受力
Mean Force	$N^{-1} \sum_i \ F_i\ _2$	低不是平均力向量的范数
RMSD	生成结构与代理松弛结构的匹配位移	低依赖代理松弛与匹配协议

2.8.4 配对统计与 Bootstrap

第 3 章和第 4 章的核心比较采用匹配种子设计：基线与候选方法从同一随机 seed 启动，使每对结果共享初始随机因素。设第 i 对在某个“越低越好”指标上的基线值和方法值分别为 m_i^{C0} 与 m_i^{method} ，定义有利配对差为

$$d_i = m_i^{C0} - m_i^{\text{method}}. \quad (2-23)$$

$d_i > 0$ 表示方法改善， $d_i = 0$ 表示持平， $d_i < 0$ 表示损害。对于 Stable、Validity 等“越高越好”指标，应反转差值方向或直接按更高者为 Win，不能机械沿用式 (2-23)。W/T/L 分别统计配对 Win、Tie 与 Loss，并与均值效应共同揭示收益是否由少数极端样本驱动。

配对自助法 (paired bootstrap) 每次以“样本对”为单位有放回重采样，保留对内对应关系，再计算均值差或相对变化。本文第 3 章和第 4 章的确认性核心连

续指标使用 20 000 次确定性配对重采样，并报告 95% 区间；探索性或辅助分析若采用不同次数，则以对应实验协议为准。Bootstrap 区间衡量当前 cohort 下统计量的不确定性，不消除代理模型偏差，也不把有限任务上的结果自动提升为跨材料域结论。

伤害率和尾部分析与均值互补。伤害率统计逐样本不利变化的比例；分位数、经验累积分布或高风险阈值用于检查均值改善是否伴随尾部恶化。因而后续章节按照“主效应—配对区间—W/T/L—护栏—尾部—证据边界”的顺序解释结果，而不只比较两个均值。

2.9 本章小结

本章给出了后续方法所需的统一技术基础。晶体由原子种类、周期分数坐标和晶胞共同表示，本文采用行向量约定 $r_i = f_i H$ ，并通过 wrap、周期邻域和结构匹配处理周期等价。扩散模型从前向 corruption 出发学习反向生成，score 表示时间相关扰动分布的对数密度梯度；MatterGen 对三个字段使用不同扩散形式，因此预测干净结构也需分别解析。

条件扩散通过性质条件改变生成分布，CFG 将条件与无条件得分按统一强度组合。MatterGen 以适配的 GemNetT 几何网络联合去噪 `atomic_numbers`、`pos` 和 `cell`，构成本文两项推理阶段研究的基础模型。神经网络原子间势提供能量、力和应力的低成本代理；MatterSim 在本文同时承担 RC-NFGD 引导与同源代理评价，CHGNet 则承担属性代理和未参与在线力反馈的独立代理评估。二者都不构成 DFT 真值。

最后，本章统一定义了 Property MAE、E-hull、Stable、Validity、Novel、Unique、NUS、MaxF、Mean Force、RMSD、配对自助法与 W/T/L，并明确区分代理局部结构一致性与热力学稳定性。在上述理论基础上，第 3 章首先围绕 MatterGen 的条件引导机制研究目标属性生成精度的优化问题。

3 面向冻结扩散生成模型的预算约束验证选择推理增强方法

MatterGen 将晶体生成表示为原子类型、周期坐标与晶胞三个相互耦合字段上的扩散过程，并可通过属性条件实现材料逆向生成 [8]。在条件采样阶段，分类器无关引导 (classifier-free guidance, CFG) 利用条件得分与无条件得分之差增强条件响应 [13]。引导强度过低可能削弱目标属性约束，过高则可能放大模型误差并损害结构质量。然而，模型冻结后仍能增加推理计算：独立重复采样、共享前缀分支与终点验证都可能改变输出。核心问题不只是选择 CFG 数值，而是在可核算预算下如何生成候选、控制代理选择风险并保留精确参考输出。

本章以预算约束验证选择为主线。首先保留在线 Adaptive CFG、反事实 Oracle、风险校准、阶段与字段分析中的正反证据，说明单轨迹控制为何难以稳定识别有利偏离。随后定义状态、候选动作、MatterGen 转移、终点验证器、预算账本和参考回退；Fixed-K2 仅是共享前缀、固定双候选的实例。除历史 C1-128 确认与 Linear-K2 负结果外，本章还以两个独立的新 cohort 检验独立 Best-of-2 的竞争性及 $K=0-4$ 的预算—性能关系。新实验不倒写为原 C1 的方法选型依据。

需要预先说明，本章中的目标属性误差由冻结的 CHGNet 磁性密度代理模型计算 [18]，能量高于凸包值 (energy above hull, E-hull) 与稳定性主要由 MatterSim 代理评价器给出 [19]。这些结果是冻结协议下的代理模型证据，不等同于密度泛函理论 (DFT) 或实验验证；本章所有实验的 DFT_VERIFIED 均为 `false`。

3.1 冻结扩散模型的推理预算问题

3.1.1 冻结 MatterGen 与参考采样

设扩散采样第 t 步的无条件得分为 $s_{\text{uncond}}(x_t, t)$ ，给定目标条件 c 后的条件得分为 $s_{\text{cond}}(x_t, t, c)$ 。标准 CFG 按下式构造用于反向扩散的得分：

$$s_{\text{cfg}}(x_t, t, c) = s_{\text{uncond}}(x_t, t) + g[s_{\text{cond}}(x_t, t, c) - s_{\text{uncond}}(x_t, t)],$$

其中 g 为 CFG 强度。固定 CFG=2.0 的 MatterGen 参考基线记为 C0，即其在全部采样步骤中固定 $g_0 = 2.0$ 。MatterGen 的得分不是单一欧氏向量，而由三个主要字段组成：原子类型 `atomic_numbers`、周期坐标 `pos` 和晶胞 `cell`。因此，可将第 f 个字段的引导写为

$$s_{\text{cfg},f} = s_{\text{uncond},f} + g(s_{\text{cond},f} - s_{\text{uncond},f}), \quad f \in \{a, p, H\},$$

其中 a, p, H 分别表示原子类型、位置与晶胞字段, H 与第 4 章采用的晶胞矩阵记号一致。

固定 $g = 2.0$ 的优点是实现简单、计算预算稳定且便于复现, 但它对所有样本、所有反向扩散时刻以及三个字段采用同一强度。这隐含了一个较强假设: 不同样本和状态对条件信号的需求基本一致。实际采样中, 条件得分与无条件得分的差异随字段和时间明显变化, 固定引导并未利用这些在线信息。由此形成早期的单轨迹控制假设: 是否存在随样本、阶段或字段变化的更优引导? 本章最终研究问题更宽: 给定冻结生成器与预算, 参考 C0、独立采样和共享前缀候选分别带来什么, 终点选择能否在预定义代理约束下避免不利输出?

3.1.2 研究假设与评价目标

本文最初假设, 条件得分与无条件得分之间的残差可以反映当前状态下条件信息的作用强弱。若残差相对其历史水平增大, 可适当提高引导; 若残差减小, 则降低引导以避免过度放大。该假设不需要重新训练 MatterGen, 也不引入属性梯度或外部物理力, 属于推理阶段的闭环采样控制。

本章以目标磁性密度的绝对误差作为属性误差, 对样本集合取均值得到 Property MAE:

$$E_{\text{prop}} = \frac{1}{n} \sum_{i=1}^n |\hat{c}_i - c_i^*|,$$

其中 $\hat{c}_i$ 为冻结属性代理模型的预测值, c_i^* 为目标条件。同时报告 E-hull、Stable、Novel、Unique、NUS (Novel、Unique 且 Stable) 与 Validity 等质量指标。方法判断不只关注总体均值, 还使用配对差异、20 000 次自助法置信区间、伤害率和尾部退化, 以避免少数大幅改善掩盖大量轻微损害。预算至少分别记录 MatterGen score 调用、终点属性与质量验证器调用、耗时和显存; 本文可严格核算前两项, 新增方法对照的部署耗时为估算而非独立实测。C1-128、Best-of-2 与 Budget Scaling 是分离的 cohort, 只在各自 cohort 内作配对推断。

3.2 单轨迹控制探索及其失败边界

3.2.1 字段残差与共享控制量

对于每个字段 $j \in \{a, p, H\}$, V1 首先计算条件与无条件得分差的均方根残差:

$$\Delta_j(t) = \sqrt{\text{mean} \left[(s_{\text{cond},j}(t) - s_{\text{uncond},j}(t))^2 \right]}.$$

三个字段具有不同张量形状, 因而先分别降维为标量, 再进行等权平均:

$$\bar{\Delta}(t) = \frac{1}{3} [\Delta_a(t) + \Delta_p(t) + \Delta_H(t)].$$

需要强调的是, V1 虽然分别计算三个字段的残差, 但最终只输出一个全局共享 CFG, 而不是三个独立的字段引导系数。也就是说, 字段残差用于估计共同的控制信号, 得到的 g_t 仍同时作用于 `atomic_numbers`、`pos` 和 `cell`。

MatterGen 的预测器与校正器调用具有不同统计尺度。V1 因此为两个阶段分别维护指数移动平均 (exponential moving average, EMA)。记阶段 $q \in \{\text{predictor}, \text{corrector}\}$, 则

$$m_q(t) = \begin{cases} \bar{\Delta}(t), & \text{该阶段首次观测,} \\ \beta m_q(t-1) + (1-\beta)\bar{\Delta}(t), & \text{其他情况.} \end{cases}$$

在实现中先用当前残差更新 EMA, 再计算相对比值与引导强度:

$$r_t = \frac{\bar{\Delta}(t)}{m_q(t) + \varepsilon},$$

$$u_t = \text{clip}(1 + \alpha(r_t - 1), 0.25, 4),$$

$$g_t = \text{clip}(g_0 u_t, g_{\min}, g_{\max}).$$

冻结的 V1 参数为 $g_0 = 2.0$ 、 $\alpha = 0.5$ 、 $\beta = 0.95$ 、 $\varepsilon = 10^{-6}$, 最终范围为 $[0, 5]$ 。残差非法或统计量非有限时, 控制器回到基础引导。每个新样本开始时重新初始化 EMA, 不跨样本传递状态。

3.2.2 V1 实验结果与稳定性问题

V1 的历史 Formal256 在 256 对相同随机种子上表现出方向性质量改善: 平均 E-hull 从 0.143667 eV/atom 降至 0.140232 eV/atom, Stable 从 41.02% 增至 46.88%, NUS 从 22.27% 增至 25.78%。然而, 三项配对置信区间均跨越零: E-hull 差异的 95% 置信区间为 $[-0.017926, 0.011030]$, Stable 为 $[-1.56, 13.28]$ 个百分点, NUS 为 $[-2.73, 9.77]$ 个百分点。因此, 该批结果只能说明方向性改善, 不能解释为统计上稳健的普遍优势。该历史批次也没有保存可用于独立核验的目标属性预测, 不能回填 Property MAE。

随后在预先注册的 8 个新配对种子上进行组件诊断。完整 V1 的 Property MAE 从 C0 的 0.031306 降至 0.019655, 但改善区间仍跨越零; 与此同时, E-hull 从 0.043371 增至 0.085877 eV/atom, Stable 从 100% 降至 62.5%, 未复现 Formal256 的质量改善方向。由于样本量较小, 该批结果不能单独建立普遍统计结论, 但它足以否定“V1 已在跨批次条件下稳定改善质量”的表述。

上述结果暴露了关键问题：在线残差规则能够改变生成结果，且在部分批次呈现有利方向，但收益对样本集合敏感。下一步需要区分两种可能性：一是控制规则没有正确识别有利偏离；二是固定 $CFG=2.0$ 已经接近最优，根本不存在足够的样本级优化空间。为回答这一问题，本文进一步开展反事实 Oracle 实验。

3.2.3 反事实 Oracle 与引导优化空间

实验设计

反事实 Oracle V3 在 32 条新种子轨迹的 8 个预注册决策时刻上，比较三种冻结候选动作：降低引导 **DOWN** ($CFG=1.75$)、保持基准 **KEEP** ($CFG=2.0$) 和提高引导 **UP** ($CFG=2.25$)。每个候选均从相同扩散状态出发，并恢复相同的 CPU/CUDA 随机数状态，从而使差异只来自引导动作。

实验同时构造两类选择器。短视野选择器只观察候选执行 15 个反向步骤后的代理结果，代表可能在线使用的局部反馈；完整终点 Oracle 则将候选保持至采样终点，并在事后选择最终属性误差最低的动作。后者拥有部署时不可获得的未来信息，因而只表示优化空间上界，不能视为可部署算法。

在 256 个短视野状态中，完整展开其中 64 个状态，得到 192 个完整候选终点。所有完整 **KEEP** 分支与对应固定 $CFG=2.0$ 终点实现了原子类型完全一致、坐标与晶胞最大绝对误差均为 0 的配对核验。

结果与机制解释

完整终点 Oracle 将 $CFG=2.0$ 的 Property MAE 从 0.030446 降至 0.022158，相对改善 27.22%。其动作分布包含 23.44% 的 **DOWN**、62.50% 的 **KEEP** 和 14.06% 的 **UP**，说明更优动作同时依赖样本与扩散时刻，而不是统一地增大或减小 CFG 。这一结果回答了前述存在性问题：固定 $CFG=2.0$ 并非所有状态的终点最优选择，样本级引导优化空间客观存在。

但局部反馈并不能可靠识别这一空间。短视野标签与完整终点标签的一致率为 62.5%；按照短视野标签执行到终点后，冻结属性目标反而相对 $CFG=2.0$ 恶化 6.90%，未达到预注册的至少 5% 改善门槛。短视野选择还产生 15.63% 的属性伤害率。由此可见，局部候选在短时间内的有利变化并不必然延续到最终晶体，在线控制面临明显的短期代理—长期结果错配。

该实验的结论不是“没有更好的 CFG ”，而是“最终更好的 CFG 难以由当前中间状态和短视野结果稳定识别”。完整终点 Oracle 的 27.22% 改善是机制上界，不能作为部署性能。该转折使研究重点由继续调整残差公式，转向分析错误动作的风险来源及更保守的选择机制。




图 3-1: 创新点 1 的证据演化: 方框表示各阶段冻结结论, 而非单调性能曲线
Fig. 3-1: Evidence Evolution of Innovation 1: Boxes Denote Frozen Stage Conclusions Rather Than a Monotonic Performance Curve

3.2.4 在线自适应引导不稳定性机制分析

图 3-1 汇总了从 V1 到最终 Fixed-K2 的证据演化。各阶段不是相互独立的新算法, 而是围绕残差信号、风险识别、时间阶段和字段解耦四类失败假设展开的连续机制实验。

表 3-1: 在线自适应 CFG 探索与机制实验汇总
Tab. 3-1: Summary of Online Adaptive CFG Exploration and Mechanistic Experiments

实验	核心问题	数据规模主要发现	冻结状态	对下一阶段的作用
Adaptive CFG V1	多字段残差能否直接控制共享 CFG	Formal256 + 历史方向性 fresh8 改善未在新批次稳定复现	MIXED	暴露跨批次稳定性问题
Robust V2	归一化、置信回退和限速能否降低伤害	P0=32 未降低旧 V1 的三类伤害率, 属性护栏失败	FAIL	表明原始残差幅值不足以作为稳定控制信号
Counterfactual Oracle V3	更优的样本/时刻引导是否存在	32 seeds, 64 个完完整整状态有 27.22% 优化空间, 但短视野选择失效	SUP PORTED_ MECHAN ISM	将问题转化为“如何识别有利偏离”

实验	核心问题	数据规模	主要发现	冻结状态	对下一阶段的作用
Risk-Calibrated V4	风险模型能否过滤有害动作	96 trajectories	无操作点同时达到覆盖率与伤害率门槛	FAIL	转向更保守的安全选择
Safe Selection V5	显式安全校准能否保留收益	128 trajectories	验证集无操作点通过冻结门槛	FAIL	转向时间与字段归因
Stage-Calibrated CFG	有利偏离是否集中在特定阶段	calibration32	+脉冲改善属性但破坏质量，阶段特异性不成立	MIXED	支持使用有限脉冲作为候选，而非单轨控制
Field-Decoupled CFG	不同字段能否独立控制	calibration=48	属性与伤害均为多字段效应，无策略通过门槛	FAIL	为分支候选库提供字段归因

残差信号稳健性

Robust Adaptive CFG V2 针对 V1 的跨字段尺度和快速波动问题进行了预注册改造。首先使用 64 个历史 C0 样本进行确定性重放，将三个字段残差按预测器/校正器、字段以及 20 个时间区间分别转换为对数标准分数；随后以三个字段标准分数的中位数作为聚合量，并为预测器和校正器分别维护 $\beta = 0.95$ 的 EMA。控制器根据残差偏离基准死区的程度与字段一致性计算置信度，置信度为零或残差非法时精确回到 CFG=2.0。最终引导范围冻结为 [1.5, 2.5]，相邻得分调用的变化幅度不超过 0.05，且关闭阶段门控。

在 32 个全新 P0 配对样本上，V2 的稳健版本 **A_ROBUST** 相对 C0 的 E-hull、Stable 和属性伤害率分别为 43.75%、18.75% 和 53.13%，与旧 V1 在该批次上的对应伤害率完全相同，未满足“至少一类伤害率相对下降 30%”的预注册门槛。其 Property MAE 为 0.029870，高于 C0 的 0.023210，也违反了属性误差最多恶化 10% 的护栏。该结果表明，时间归一化、中位数聚合、置信回退和限速改善了控制形式，但没有解决跨样本的错误动作识别问题；原始残差的幅值及其平滑变换仍不足以构成稳定的在线控制信号。

风险校准与安全选择

Oracle 已证明有利偏离存在，因此 V4 不再直接预测最优动作，而是估计动作的收益与伤害风险，并仅在低风险区域内允许偏离。其冻结门槛要求所选操作点覆盖率不低于 15%，且被选动作的属性伤害率不高于 10%。在 96 条完整轨迹上，没有验证操作点同时满足二者，故实验在离线阶段停止，未进入新 P0 或 Formal256。

V5 进一步采用保守的候选安全选择，将收益预测与经过校准的伤害概率联合约束。数据集包含 128 条轨迹，但预注册候选网格中仍没有验证操作点同时满足覆盖率与伤害率门槛，因此测试集、P0 和 Formal256 均未运行。V4 与 V5 共同说明：误报一个“有利偏离”的代价较高，而当前手工设计的分支前特征、样本规模和安全校准方法不能稳定筛出这类偏离。该结论只约束本研究中的特征与协议，不能外推为所有自适应控制器均不可能成功。

时间阶段与字段维度分析

Stage-Calibrated CFG 研究较低引导是否只在特定扩散阶段有效。冻结候选包括全程 CFG=1.9、从第 400 步起永久降至 1.9，以及从第 400 步起持续 100 步的有界脉冲。Fresh P0 的结果见表 3-2。

表 3-2: Stage-Calibrated CFG 的 Fresh P0 结果
Tab. 3-2: Fresh P0 Results of Stage-Calibrated CFG

策略	Property MAE	E-hull	Stable ↑	NUS ↑	Validity ↑
	↓	(eV/atom) ↓			
C0, 恒定 2.0	0.043425	0.064246	75.00%	43.75%	100%
全程 1.9	0.035938	0.095755	56.25%	28.13%	100%
第 400 步 后永久 1.9	0.035973	0.170068	59.38%	46.88%	100%
第 400–499 步脉冲 1.9	0.036328	0.122792	43.75%	28.13%	100%

三种低引导策略均降低了平均属性误差，但均引入至少一项明显质量退化。脉冲相对 C0 的平均属性增益为 0.007097，而 95% 自助法区间 $[-0.003456, 0.017458]$ 跨越零；其 E-hull 几乎翻倍，Stable 降低 31.25 个百分点，NUS 降低 15.63 个百分点。脉冲与全程 1.9 的 Property MAE 基本相当，脉冲相对恒定策略的平均属性增益为 -0.000391 ，区间同样跨越零。因此，实验支持“较低 CFG 会改变属性—质

量权衡”，但不支持该收益具有明确的阶段特异性。

Field-Decoupled CFG 则将三个字段的引导分别记为 g_a, g_p, g_H 。首先进行实现等价性检查：令 $g_a = g_p = g_H = 2.0$ 时，输出原子类型完全一致，位置与晶胞的最大绝对误差均为 0，从而排除字段化实现自身引入的差异。随后在 48 个校准样本上评价单字段、双字段、全局恒定和脉冲候选。

字段归因结果显示，属性收益的正向贡献约 40.24% 来自原子类型字段、59.76% 来自位置字段，晶胞字段未产生正向贡献；质量伤害的聚合归因约 54.72% 来自位置、42.37% 来自晶胞、2.91% 来自原子类型。也就是说，属性改善不是单一原子字段效应，质量损害也不是单一晶胞字段效应。最终 12 个候选中没有策略同时通过属性保持、收益保留、物理质量和基准护栏，因而 P0 与 Formal256 均按协议停止。该结果说明，简单字段解耦不足以得到稳定增益，但它为后续候选分支的设计提供了可解释的字段级干预方式。

3.3 预算约束验证选择推理框架

3.3.1 状态、动作与预算接口


前述实验表明，在线自适应引导的主要困难不是缺少可利用的优化空间，而是在终点结果未知时提前决定何时偏离 C0。错误偏离会改变后续随机演化；仅将 CFG 恢复为 2.0 并不能恢复原始参考轨迹。因此本文把推理阶段计算抽象为一个带参考输出的验证选择问题，而非提出新的去噪器或最优 CFG 调度器。

给定参数冻结的生成器 G_θ 、目标条件 c 、预算 B 与终点验证器 V ，状态定义为 $s_t = (z_t, t, \xi_t, c; \theta, \mathcal{S})$ 。其中 z_t 包含原子种类、周期位置和晶胞， ξ_t 为 CPU/CUDA 随机数状态， $\mathcal{S}$ 是冻结的时间网格与采样调度。动作 a_k 是预注册的候选后缀策略，包括基准 C0 continuation 或 GPulse、PPulse 等分支；转移 $T_\theta(s_t, a_k)$ 由 MatterGen sampler 执行。终点验证器 $V(y_k, y_0)$ 使用冻结的 CHGNet 代理 Property MAE、MatterSim 代理 E-hull/Stable 和 Validity 决定可接受性；Novel、Unique、NUS 为集合级报告指标，并非逐样本门槛。输出在合格候选中取最低代理属性误差，否则返回精确 y_0 。

预算 $B = (N_{\text{score}}, N_{\text{property}}, N_{\text{quality}}, t_{\text{wall}}, m_{\text{peak}})$ 区分生成、验证、时间和显存，不能只用候选数代替。当前 1000 步采样每步调用得分网络两次，第 400 步分支时，固定 K 个后缀需 $800 + 1200(K + 1) = 2000 + 1200K$ 次生成 score 调用，终点属性与质量选择各需 $K + 1$ 次。 $K=2$ 因而是 4400 次 score 调用、3 个终点的固定预算实例。该公式不计 MatterSim/CHGNet 耗时，不能把 2.2 倍 score 调用写成 2.2 倍端到端时间。

最终方法包含四个组成部分：精确保留 C0、共享分支前缀、固定候选预算以及带质量约束的参考回退。其逻辑流程为：

Budget-constrained verifier-guided inference



Fixed-K2: 4,400 score calls (2.2× C0); 3 terminal evaluations. Budget is not wall time.

图 3-2: 预算约束验证选择的 Fixed-K2 实例: 共享前缀后保存采样状态与随机状态, 扩展精确 C0 和两个固定后缀, 由冻结终点验证器选择或回退。预算数字仅为 MatterGen score 调用与终点评价次数; 机制示意不构成性能证据。

Fig. 3-2: Fixed-K2 as an Instance of Budget-Constrained Verifier-Guided Inference: A Shared Prefix, Saved Sampling and RNG States, the Exact C0 and Two Frozen Suffixes, Followed by Terminal Selection or Fallback. Budgets Count MatterGen Score Calls and Terminal Evaluations Only; This Mechanism Diagram Is Not Performance Evidence.

固定 CFG=2.0 运行共享前缀

↓

第 400 步保存完整采样状态与 RNG 状态

↓

┌────────── C0 精确参考后缀
├────────── 候选分支 1
└────────── 候选分支 2

↓

属性代理评价 + 终点质量约束

↓

候选安全且属性改善 → 接受最优候选

否则 → 返回精确 C0

这种设计将不确定的在线控制转化为保守的推理时选择: 算法不必准确预测唯一最优动作, 只需在有限候选中找到一个通过预定义终点约束且优于 C0 的结果; 若没有这样的结果, 原始基准仍可直接返回。

3.3.2 精确参考保留与共享前缀

设完整采样共 $T = 1000$ 步, 分支点为 $t_b = 400$ 。将第 t_b 步的采样状态记为 z_{t_b} , 随机数生成器状态记为 ξ_{t_b} 。方法在分支点保存二者, 并对每条后缀分支执行状态克隆与 RNG 恢复:

$$y_k = F_{P_k}(z_{t_b}, \xi_{t_b}; t_b, T), \quad k \in \{0, 1, \dots, K\},$$

其中 P_0 是始终保持 CFG=2.0 的 C0 后缀, P_k 是第 k 个候选策略。所有分支在 t_b 之前具有完全相同的张量与随机历史, 在 t_b 之后也从同一 RNG 快照开始。

C1 实验还额外运行独立的全程 C0，并逐样本检查其与共享前缀 C0 的原子类型、位置和晶胞；128 个确认样本全部通过精确复现检查。运行时快照包含克隆的 batch 与 RNG，记录分支位置；历史 C1 artifact 未将条件值和数值 timestep 网格作为独立字段序列化，它们随冻结输入与采样配置恢复。上述状态定义是算法接口，不能误读为脱离版本和条件文件仍可独立重放的自包含 checkpoint。

共享前缀避免从初始噪声重复运行 $K + 1$ 条完整轨迹。C0 每个样本需要 2000 次 MatterGen 得分调用；Fixed-K2 需要前 400 步的 800 次共享调用，以及 C0 和两个候选在后 600 步的 3×1200 次调用，共 4400 次，即 C0 的 2.2 倍。该计算量是最终部署成本；Phase B 为收集全部候选监督数据产生的 3.4 倍成本不属于 Fixed-K2 部署成本。

3.3.3 有限候选后缀与 Fixed-K2 策略

只有在第 400 步之前与 C0 完全一致的策略才能合法复用共享前缀。最终候选库由表 3-3 中的四种 100 步脉冲组成。所有脉冲均在第 400–499 步将对应字段从 2.0 降至 1.9，第 500 步起恢复至 2.0。

表 3-3: 分支兼容候选策略
Tab. 3-3: Branch-Compatible Candidate Strategies

策略	g_a	g_p	g_H	作用区间	含义
GPulse	1.91	1.91	1.94	400–499	三字段全局脉冲
APulse	1.92	0.2	0.4	400–499	仅原子类型字段脉冲
PPulse	2.01	1.92	0.4	400–499	仅位置字段脉冲
CPulse	2.02	0.1	1.94	400–499	仅晶胞字段脉冲

最终 Fixed-K2 冻结选择 GPulse+PPulse，即每个样本只生成两个候选，而不是进行无上限的多样本筛选。固定 $K = 2$ 同时限制推理成本和选择自由度，使该实例可在明确的 2.2 倍生成预算下评价。它不是经新增预算扩展实验事后挑出的最优宽度。

3.3.4 终点验证器与参考回退

记 $e(y) = |\hat{c}(y) - c^*|$ 为候选的属性绝对误差， $v(y)$ 为有效性， $s(y)$ 为稳定性二值指标， $h(y)$ 为 E-hull。对分配给当前方法的候选集合 $\mathcal{P}_K$ ，冻结的逐样本可接受集合为

$$\mathcal{A} = \left\{ y_k \left| \begin{array}{l} e(y_0) - e(y_k) > 10^{-6}, \quad v(y_k) \geq v(y_0), \\ s(y_k) \geq s(y_0), \quad h(y_k) \leq h(y_0) + 0.01 \end{array} \right. \right\},$$

其中 y_0 为精确 C0，且候选与 C0 的 E-hull 均须为有限值。最终输出为

$$y^* = \begin{cases} \arg \min_{y_k \in \mathcal{A}} e(y_k), & \mathcal{A} \neq \emptyset, \\ y_0, & \mathcal{A} = \emptyset. \end{cases}$$

该逐样本规则直接约束属性改进、有效性、稳定性和 E-hull。NUS 等集合级指标用于确认阶段的整体质量护栏，但不应被误写为逐样本终点选择条件。参考回退的含义也不是“保证物理安全”，而是在当前代理评价和预定义接受条件下，不接受违反约束的候选。

3.3.5 算法描述

算法 3-1 冻结生成器的预算约束验证选择 (Fixed-K2 为 K=2 实例)

输入：冻结生成器 G；条件 c；预算 B；终点验证器 V；
基准引导 $g_0=2.0$ ；分支点 tb ；策略 P；宽度 K；约束 Q
输出：晶体 x^*

- 1: 初始化 MatterGen 采样状态 z_0 与随机数生成器
- 2: 使用 g_0 将基准轨迹推进至 tb
- 3: 保存完整状态 z_{tb} 和 RNG 状态 ξ_{tb}
- 4: 恢复 (z_{tb}, ξ_{tb}) ，使用 g_0 完成后缀，得到精确参考 x_0
- 5: 对预先分配的 K 个候选策略 P_k :
- 6: 恢复同一 (z_{tb}, ξ_{tb}) 并克隆采样状态
- 7: 在冻结区间应用 P_k ，其余步骤使用 g_0
- 8: 完成采样，得到候选 x_k
- 9: 用同一冻结验证器 V 评价 x_0 及全部 x_k
- 10: 构造同时满足属性严格改善与质量约束 Q 的候选集合 A
- 11: 若 A 非空，返回其中属性误差最小者
- 12: 否则返回精确参考 x_0

算法的实现关键是第 3、4、6 步：完整采样状态与 RNG 状态必须同时保存和恢复。若只恢复 CFG 数值而不恢复状态，候选所经历的中间更新已不可逆，不能被称为 C0 回退。

3.4 Fixed-K2 固定预算实例与独立确认

本节保留历史选型、原 C1-128 确认和 Linear-K2 负结果。GPulse 与 PPulse 并非依据新增预算曲线事后选定；新对照不更改原有种子和结论。

3.4.1 分支兼容 Oracle 与候选预算分析

分支兼容性约束

早期实验包含多种全程或更早阶段生效的策略，但它们无法从第 400 步的 C0 状态合法分叉。分支兼容性审计因此只保留 GPulse、APulse、PPulse 和 CPulse。审计检查表明，这些候选具有相同的分支点和共同前缀摘要；实现代码在第 400 步保存 RNG、克隆完整状态，并在每个分支执行前恢复 RNG。该约束保证候选比较来自同一起点，也使共享前缀的 2.2 倍计算估计成立。

Oracle 上界与 K=2 动机

在历史数据的独立测试划分 $n = 12$ 上，C0 的 Property MAE 为 0.02879873，使用 SAFE-A 终点规则的分支兼容 Oracle-All 为 0.02004107，相对改善 30.41%。Oracle-K2 恢复了 100% 的 Oracle-All 优化空间，而训练划分选出的固定 CPulse+GPulse 在测试集恢复 72.56%。结果见表 3-4。

表 3-4: 分支兼容 Oracle 的测试集结果
Tab. 3-4: Test-Set Results of the Branch-Compatible Oracle

方法	Property MAE ↓	相对 C0 改善	恢复 Oracle 优化	
			空间	估计计算量
C0	0.028799	—	0%	1.0×
Oracle-All	0.020041	30.41%	100%	3.4×
Oracle-K2	0.020041	30.41%	100%	2.2×
Fixed-K2 (Phase A)	0.022445	22.06%	72.56%	2.2×

Oracle-K2 在定义上可事后知道每个样本的最佳策略身份，因此它仍是存在性上界，而非可部署的候选分配器。其作用是说明大部分可用优化空间可由很小的候选集合覆盖，从而为 $K = 2$ 提供预算依据。

还需区分两个阶段的固定双候选分支策略：Phase A 使用历史训练划分选出 CPulse+GPulse，最终 C1 的 GPulse+PPulse 则来自后续 Phase B 的独立候选分配流程。二者使用不同样本集合和选择程序，不能相互替换。本章最终方法以 C1 冻结清单中的 GPulse+PPulse 为准。

3.4.2 Fixed-K2 的独立确认结果

确认实验设置

C1 在所有结果产生前一次性注册了 256 个与历史样本零重叠的随机种子, 其中前 128 个构成 C1, 后 128 个仅在预注册继续门槛通过时用于 C2。每个 C1 样本均生成精确 C0, 并以相同 2.2 倍部署预算比较 Fixed-K2、Random-K2 与 Linear-K2。所有 128 个样本的独立全程 C0 与共享前缀 C0 均通过精确复现检查。

终点属性由冻结 CHGNet 代理模型评价, 候选接受使用 3.3.4 节的逐样本规则; 集合级 E-hull、Stable、NUS 与 Validity 用于确认质量护栏。Fixed-K2 的主要检验使用 20 000 次确定性配对自助法, 差异定义为 C0 属性误差减去 Fixed-K2 属性误差, 正值表示 Fixed-K2 更优。

属性误差与配对统计

四种方法的 C1 结果见表 3-5 和图 3-2。Fixed-K2 将 Property MAE 从 0.034796 降至 0.026332, 绝对改善 0.008464, 相对改善 24.32%。20 000 次配对自助法得到绝对改善的 95% 置信区间为 [0.005817, 0.011391], 全区间高于零。在 128 个样本中, 53 个样本接受了属性更优且通过约束的候选, 75 个样本持平或回退 C0, 没有样本输出比 C0 更高的属性误差。

表 3-5: C1-128 最终确认结果
Tab. 3-5: Final Confirmation Results for C1-128

方法	E-hull						
	Property (eV/atom)		Stable ↑	NUS ↑	Validity ↑	计算量/C0	回退率
	MAE ↓	↓					
C0	0.034796	0.104296	58.59%	32.81%	100%	1.0×	100%
Fixed-K2	0.026332	0.081135	70.31%	37.50%	100%	2.2×	58.59%
Linear-K2	0.027522	0.090528	67.97%	39.06%	100%	2.2×	59.38%
Random-K2	0.028533	0.089172	64.84%	39.06%	100%	2.2×	66.41%

图 3-3 展示 Fixed-K2 与 C0 的逐样本属性误差, 图 3-4 给出配对增益的自助法分布。二者共同说明总体改善不是由少数单边离群值独立驱动, 但结论仍应限定在该冻结确认样本与代理评价协议内。




图 3-3: C1-128 中 C0、Fixed-K2、Linear-K2 与 Random-K2 的 Property MAE

Fig. 3-3: Property MAE of C0, Fixed-K2, Linear-K2, and Random-K2 on C1-128




图 3-4: Fixed-K2 与 C0 的逐样本属性误差

Fig. 3-4: Per-Sample Property Error of Fixed-K2 and C0




图 3-5: Fixed-K2 相对 C0 的 20 000 次配对自助法增益分布

Fig. 3-5: 20,000 Paired-Bootstrap Gain Distribution of Fixed-K2 Relative to C0




图 3-6: C1-128 的代理质量护栏结果
Fig. 3-6: Proxy Quality Guardrails on C1-128

质量护栏与计算代价

Fixed-K2 的平均 E-hull 从 0.104296 降至 0.081135 eV/atom, Stable 从 58.59% 增至 70.31%, NUS 从 32.81% 增至 37.50%, Validity 保持 100%, 没有违反冻结的代理质量护栏。图 3-5 给出主要质量指标对比。

上述“0 个属性损失”应结合算法定义解释: Fixed-K2 只有在终点属性严格改善且质量条件通过时才接受候选, 否则返回精确 C0。因此, 它证明的是终点约束选择和参考回退在该代理协议下按设计工作, 而不是证明每个候选分支本身从不失败。事实上, 回退率为 58.59%, 说明大部分样本仍保留 C0。

计算代价方面, Fixed-K2 每个样本需要 4 400 次 MatterGen 得分调用和 3 次终点评价, 对应约 2.2 倍 C0 计算量。图 3-6 区分了部署成本与 Phase B 数据构建成本。该结果不能表述为 Fixed-K2 在相同的 1.0 倍预算下优于 C0, 而应表述为在固定 2.2 倍推理预算下, 以额外计算换取终点验证和保守回退。

3.4.3 学习型 Linear-K2 分配器的负消融

Phase B 候选分配实验

Fixed-K2 对所有样本分配相同的 GPulse 与 PPulse。为检验分支点特征能否支持样本级候选分配, Phase B 使用 64 个全新种子构建数据集, 并按 32/16/16 划分训练集、验证集和测试集。每个样本在第 400 步提取 179 个无终点信息泄漏的分支前特征, 包括三个字段在预测器/校正器阶段的残差、条件与无条件得分范数、对齐度、25/50/100 步窗口统计以及分支状态的结构描述量。加入策略交互后




图 3-7: C0、Fixed-K2 及 Phase B 数据构建的计算量比较

Fig. 3-7: Computational Cost Comparison of C0, Fixed-K2, and Phase B Data Construction

形成 895 个数值设计列，再加策略独热编码共 899 个设计列。

验证集最终选择 $C = 1.0$ 、类别平衡的线性逻辑分配器 Linear-K2。它为四个候选估计“安全且有益”的概率，并生成概率最高的两个后缀。Phase B 的 16 个留出测试样本上，Linear-K2 的 Property MAE 为 0.023634，Fixed-K2 为 0.024597，方向性相对改善 3.92%；但两者配对增益的 20 000 次自助法 95% 区间为 $[-0.002618, 0.005214]$ ，跨越零，未达到预注册的分配器优势门槛。因此 Phase B 的冻结结论为 **ADAPTIVE_ALLOCATION_VALUE=NOT_SUPPORTED**，不能将该小样本方向性结果写为已验证的学习型优势。


模型重建与冻结

Phase B 当时未保存 scikit-learn 序列化模型。为进行独立确认，在注册任何新确认种子之前，使用原始训练集 32 个样本、原始冻结代码、原始 179 个特征和已确定的 $C = 1.0$ 进行了一次确定性重建。重建模型对 16 个历史测试种子的 Top-2 候选选择实现 16/16 完全一致，验证/测试指标的最大绝对误差为 1.11×10^{-16} 。通过后，模型被标记为 **RECONSTRUCTED_ARTIFACT** 并以 SHA-256 **bd3f5280957a6418e7d5275a3e7a576fc57872b3ad1bd19aee9ef7bef97d56d3a** 永久冻结。该过程只恢复缺失的序列化对象，不改变模型、特征、超参数或 Phase B 的历史负结论。

C1-128 独立确认

在 C1 的 128 个完全新种子上，Linear-K2 的 Property MAE 为 0.027522，反而高于 Fixed-K2 的 0.026332。以 $E_{\text{Fixed}} - E_{\text{Linear}}$ 定义 Linear-K2 的配对增益，其均值为 -0.001190 ，相对增益为 -4.52% ，20 000 次自助法 95% 区间为 $[-0.003148, 0.000740]$ 。逐样本胜/平/负为 31/62/35。虽然 Linear-K2 相对 C0 仍因终点约束与回退获得较低误差，但本实验的主要问题是它能否在相同 2.2 倍预算下优于 Fixed-K2；对此，方向和置信区间均不支持肯定结论。

Same terminal rule; different candidate sources and costs



Mechanism diagram only; no performance ordering is implied.

图 3-8: 独立 Best-of-2 与 Fixed-K2 的候选来源及生成预算示意。二者共享 SAFE-A 终点规则, 但前者为两个完整独立采样 (4000 次 score 调用、2 个终点), 后者共享前缀并展开两个后缀 (4400 次、3 个终点)。该图只描述机制与预算, 不暗示任一方法性能更优。

Fig. 3-8: Candidate Sources and Generator Budgets of Independent Best-of-2 and Fixed-K2. Both Use the Same SAFE-A Terminal Rule, but the Former Uses Two Full Samples (4,000 Score Calls, Two Terminals) and the Latter Uses a Shared Prefix and Two Suffixes (4,400 Calls, Three Terminals). The Diagram Shows Mechanisms and Unequal Budgets, Not a Performance Ranking.

C1 的继续门槛要求 Linear-K2 严格优于 Fixed-K2、相对改善至少 1%、不劣于 Random-K2, 并通过质量护栏。前两项失败, 故冻结结论为 FROZEN_LINEAR_K2_CONFIRMATION=NOT_SUPPORTED, C2 按协议不运行, 也未进行结果后的补救调参。该负结果说明, 在当前特征表示、训练规模和候选库下, 学习型样本分配没有独立确认优于 Fixed-K2。

3.5 推理预算与候选来源分析

本节的 Best-of-2 和 Budget Scaling 各使用独立的全新 128 种子 cohort, 均不与历史 C1-128 拼接为同一配对样本, 也不修改已冻结的 Fixed-K2、SAFE-A、候选顺序或历史选型结论。所有均值均为各 cohort 的代理 Property MAE。

3.5.1 独立 Best-of-2 与共享前缀实例

Independent Best-of-2 保留第一个完整 C0 为参考, 再以独立随机种子生成第二个完整 MatterGen 样本; Fixed-K2 则在同一参考的共享前缀后生成 GPulse、PPulse 两个候选后缀。两者使用相同的冻结 SAFE-A 终点接受与回退规则, 但前者每样本有 4000 次 MatterGen score 调用、2 个终点评价, 后者有 4400 次、3 个终点评价。因此, 这不是严格等 score 调用或等终点数的对照; 代理评价成本和端到端时间也不能视为相同。表 3-6 及图 3-9 均只使用该新 cohort。

相对同 cohort 的 C0, Best-of-2 与 Fixed-K2 的代理 MAE 配对改善分别为 0.009527 (20 000 次 bootstrap 95% 区间 [0.006439, 0.012891]) 与 0.008117

表 3-6: 独立 Best-of-2 对照的生成预算与代理结果 (全新配对种子, $n = 128$)
Tab. 3-6: Generator Budget and Proxy Outcomes in the Independent Best-of-2 Comparison (128 Fresh Paired Seeds)

方法	score 调用	终点数	Property MAE ↓	Stable ↑	NUS ↑
C0	2000	1	0.037623	51.56%	31.25%
Independent Best-of-2	4000	2	0.028097	62.50%	35.16%
Fixed-K2	4400	3	0.029506	61.72%	32.81%

([0.005533, 0.011054])。直接对比定义为 $MAE_{Best2} - MAE_{Fixed}$, 均值 -0.001410 , 配对 95% 区间 $[-0.005039, 0.002167]$, 区间跨零; 负的点估计表示独立 Best-of-2 的均值较低, 不能声称 Fixed-K2 优于它。以 Fixed-K2 相对 Best-of-2 的逐样本胜/平/负计为 41/59/28。两方法平均 E-hull 分别为 0.096393 与 0.100629 eV/atom, Validity 均为 100%; Novel 分别为 67.97% 与 68.75%, 低于 C0 的 75.78%。这些代理结果说明额外采样计算本身具有竞争力, 而参考保持与约束回退是 Fixed-K2 的机制特征, 不是已证明的采样效率优势。




图 3-9: 独立 Best-of-2 与 Fixed-K2 的代理 Property MAE 对照: 点为同一新 cohort 的方法均值, 误差棒为 20 000 次种子自助法均值 95% 区间; 直接配对差异见正文。预算标签仅计 MatterGen score 调用, 三方法分别为 1.0、2.0 和 2.2 倍 C0。

Fig. 3-9: Proxy Property MAE of Independent Best-of-2 and Fixed-K2 on the Same Fresh Cohort: Points Show Method Means and Bars Show 20,000-Resample Seed-Bootstrap 95% Intervals of Means; the Direct Paired Contrast Is Reported in the Text. Budget Labels Count MatterGen Score Calls Only (1.0, 2.0, and 2.2 Times C0).

3.5.2 K=0-4 固定候选顺序的预算扩展

另一个独立的 128 种子 cohort 按预定顺序 GPulse、PPulse、APulse、CPulse 嵌套加入后缀，保持相同的 SAFE-A 验证器。K 表示额外候选后缀数，不是独立完整采样次数；K=0 即只输出 C0。表 3-7 与图 3-10 展示实际得分调用预算及代理误差。预算为 1.0/1.6/2.2/2.8/3.4 倍 C0，K=2 不是曲线上的最低误差点。

表 3-7: 固定候选顺序下的预算扩展结果 (独立新 cohort, $n = 128$)
Tab. 3-7: Budget-Scaling Outcomes with a Fixed Candidate Order
(Separate Fresh Cohort, $n = 128$)

宽度	score 调用	Property MAE ↓	Stable ↑	NUS ↑	E-hull ↓
K=0	2000	0.035141	62.50%	36.72%	0.094254
K=1	3200	0.031636	67.97%	37.50%	0.081928
K=2	4400	0.028454	68.75%	38.28%	0.080551
K=3	5600	0.028419	68.75%	39.06%	0.080787
K=4	6800	0.024669	71.09%	40.63%	0.078960

相对 K=0 的配对 MAE 改善, K=1/2/3/4 的 20 000 次 bootstrap 95% 区间依次为 [0.002108, 0.005062]、[0.004537, 0.009102]、[0.004538, 0.009140] 和 [0.007774, 0.013398]; 对应逐样本胜/平/负为 39/89/0、59/69/0、59/69/0 和 72/56/0。K=3 相对 K=2 的边缘均值约为 0.000035，只有 1 个种子输出发生变化；K=4 继续降低均值。全部方法的 Validity 为 100%，唯 K=4 的 Unique 为 99.22%；Novel 从 K=0 的 68.75% 变化至 K=4 的 64.84%，不能说所有质量指标随预算单调改善。候选集合嵌套且 SAFE-A 只接受代理属性严格改进，因此同一样本选中代理 MAE 随 K 非增具有算法性；该曲线显示当前规则下的预算—代理误差权衡，不能被解释为独立证明普适推理扩展定律，也不能事后将 K=4 改写为历史 C1 的最优选型。




图 3-10: K=0–4 的 MatterGen score 预算与选中代理 Property MAE。五点来自同一独立新 cohort 的 128 个配对种子；误差棒为 20 000 次种子自助法方法均值 95% 区间，而非相邻 K 的配对增益区间。连线仅连接离散预算，不表示拟合的扩展定律；终点验证器调用与端到端时间未包含在横轴中。

Fig. 3-10: MatterGen Score Budget Versus Selected Proxy Property MAE at K=0–4. Points Use 128 Paired Seeds from a Separate Fresh Cohort; Bars Are 20,000-Resample Bootstrap 95% Intervals of Method Means, Not Paired Marginal Gains. The Line Connects Discrete Budgets Only; Verifier Calls and End-to-End Time Are Excluded from the Horizontal Axis.

3.6 局限性与本章小结

3.6.1 证据解释

第一，引导优化空间客观存在。V3 的完整终点 Oracle 在不同样本与时刻同时选择降低、保持和提高 CFG，并取得 27.22% 的回顾性改善；分支兼容 Oracle 在合法共享前缀条件下仍显示 30.41% 的测试集改善。这些结果排除了“固定 CFG=2.0 对所有样本均已最优”的解释。

第二，在线识别是比优化空间本身更困难的问题。V1 的残差反馈缺乏跨批次稳定性；经过时间归一化、中位数聚合、置信回退和限速的 V2 仍未降低伤害率；V4/V5 的风险与安全模型不能同时满足覆盖率和伤害门槛；V3 的短视野标签也不能预测完整终点结果。这些相互独立的证据指向同一问题：中间状态中易于构造的局部统计量，与最终属性—质量结果之间存在不足以支持可靠控制的代理错配。

第三，在原 C1 的同预算候选分配比较中，简单固定预算分支比当前 Linear-K2 更稳健。Fixed-K2 不需要由分支前特征决定候选身份，而是始终展开 GPulse 与

PPulse, 再利用终点评价作出选择。它在全新 C1-128 上得到正的配对改善区间, 并通过冻结质量护栏; Linear-K2 则未在相同预算下确认优于 Fixed-K2。这并不否定未来使用更强状态表征或更多训练数据的可能性, 但说明当前没有必要以更复杂的学习型分配器替代固定策略。

第四, 独立 Best-of-2 对照表明, 额外完整采样同样能够改善代理属性误差; 其均值低于 Fixed-K2, 直接配对区间跨零。Fixed-K2 的贡献因此不能表述为超越 Best-of-N, 而应限定为预算明确的参考保持、约束选择与回退。K=0-4 曲线进一步显示 K=2 是成本折中, 非最低误差点。

第五, 参考轨迹保留将不确定控制转化为保守选择。只要 C0 被精确保留, 候选失败就不必被写入最终输出; 终点选择能够利用完整结果, 而不依赖短视野代理。该设计的实质贡献不在于宣称找到了普适最优 CFG, 而在于改变风险承担方式: 从单轨迹上的不可逆在线动作, 转化为有限候选中的终点约束决策。

3.6.2 局限性

本章方法仍存在以下边界。

1. Fixed-K2 的 MatterGen 得分调用约为 C0 的 2.2 倍, 并额外需要候选终点评价。它以计算换取选择可靠性, 不是推理加速方法。
2. 方法依赖终点属性与质量评价器。若代理模型存在系统偏差, 接受规则也可能继承该偏差。尤其 CHGNet 属性代理既参与终点选择又定义主要 Property MAE, 存在选择器复用与 verifier hacking 风险; 当前代理收益不等于独立 DFT 物性收益。
3. Fixed-K2 不是纯在线、单轨迹的 Adaptive CFG。它需要保存状态、复制后缀并在生成完成后选择。
4. 学习型样本级候选分配未得到支持。Linear-K2 的 Phase B 方向性结果没有通过门槛, C1 独立确认也未优于 Fixed-K2。
5. 当前属性、E-hull、稳定性及相关质量判断主要依赖 CHGNet 与 MatterSim 代理模型, 没有进行 DFT 或实验验证, 不能据此证明材料的真实物理稳定性或可合成性。
6. 本研究已设置独立 Best-of-2 对照, 其均值数值上优于 Fixed-K2, 直接配对区间跨零; 二者为 2.0 倍/2 终点与 2.2 倍/3 终点, 尚缺严格等 score 调用、等候选数和等验证器成本的比较。因此没有证据证明 Fixed-K2 优于通用 Best-of-N。
7. 候选库、分支点和终点阈值均在当前 MatterGen 单属性条件任务上冻结, 跨属性、跨材料域和跨生成模型的迁移性仍需独立研究; K=0-4 的嵌套选择结果也不构成跨任务或独立物理验证。

上述边界也限定了本章的创新表述: 本文提出并验证的是面向当前 MatterGen

条件任务的参考轨迹保留、固定预算、终点约束选择框架，而不主张首次提出多分支扩散或验证器引导晶体生成，也不作普适最优或物理安全保证。

3.6.3 本章小结

本章从固定 CFG 的局限出发，首先提出多字段残差驱动的在线自适应引导。历史 Formal256 呈现方向性质量改善，但新样本没有稳定复现，说明直接残差控制存在跨批次稳定性问题。反事实 Oracle 随后证明，更优的样本级与时刻级引导客观存在；然而，短视野标签、稳健残差变换、风险校准、安全选择、阶段门控和字段解耦均未形成可靠的在线识别策略。

基于这些证据，本文将研究问题由“提前预测最优引导”转化为“在有限预算内保留参考轨迹并验证少量候选”，形成预算约束验证选择推理框架，并以 Fixed-K2 作为当前已确认的固定预算实例。该实例在第 400 步保存完整采样与 RNG 状态，保留精确 C0，并以固定预算展开 GPulse 和 PPulse 两个候选；只有候选同时实现属性改进并满足预定义质量约束时才被接受，否则执行参考回退并返回 C0。

在 128 个完全独立确认样本上，Fixed-K2 将 Property MAE 从 0.034796 降至 0.026332，相对改善 24.32%，20 000 次配对自助法的绝对改善区间为 [0.005817, 0.011391]，同时满足冻结的代理质量护栏。进一步的 Linear-K2 实验未能在相同预算下独立确认优于 Fixed-K2，因此历史 C1 继续保留固定双候选策略作为本框架的已确认实例。新增 Best-of-2 对照提示独立采样同样有效，Fixed-K2 不具备已证实的相对优势；新增预算扩展显示 $K=2$ 是成本折中而非最优宽度。完整证据支持“有限预算的参考保留与终点选择有效”，但不支持“在线 Adaptive CFG 已被稳定验证”或“学习型候选分配具有额外价值”。本章主要解决条件属性控制问题；属性条件满足并不等价于生成结构处于低受力状态，因此第 4 章进一步研究后期神经力场反馈对局部结构一致性的影响。

4 面向冻结材料扩散模型的神经力场反馈引导方法

MatterGen 通过联合去噪原子类型、周期分数坐标和晶胞，实现无机晶体的条件生成 [8]。第 3 章主要从条件引导角度改善目标属性生成精度，但属性条件满足并不等价于局部结构处于低受力状态。生成模型学习的是训练数据分布及条件属性之间的统计关系，其逆扩散更新并不显式要求当前结构沿局部势能下降方向移动，因此最终结构仍可能出现较大的代理原子力或较长的代理松弛位移。针对这一问题，本章提出基于阶段可靠性校准的后期神经力场引导扩散方法 (Reliability-Calibrated Late-stage Neural Force-Guided Diffusion, RC-NFGD)。该方法先通过阶段诊断确定预测干净结构 (predicted clean x_0) 可以可靠预示最终受力排序的时间区间，再在逆扩散后期调用 MatterSim 神经势模型，将其给出的笛卡尔原子力变换为有界的周期分数坐标修正，并通过预测器的实际 score 系数注入位置更新。

本章最终结论为 **INNOVATION2_FINAL_STATUS = SUPPORTED**，但这一结论严格限定在冻结模型、配对样本和代理评价协议之内。正式的 256 对样本实验表明，RC-NFGD 将 MatterSim 预测的最大原子力、平均原子力和松弛 RMSD 分别降低 29.81%、29.72% 和 14.17%；CHGNet 独立代理评估器也给出方向一致的均值改善。与此同时，目标 Property MAE 轻微恶化 1.14%，部分 CHGNet 高分位尾部指标没有改善，等预算生成后修正的 MatterSim MaxF 更低。本章没有执行 DFT 计算，故 **DFT_VERIFIED = false**，不能将代理力改善表述为真实势能面或物理稳定性已经得到证明。

4.1 问题定义与研究动机

4.1.1 条件扩散生成中的局部结构问题

扩散模型通过正向加噪构造易采样的先验分布，再学习反向去噪过程 [11]；从连续时间观点看，反向随机微分方程由扰动分布的时间相关 score 决定，并可由预测器—校正器数值求解 [12]。MatterGen 将该思想扩展到晶体结构，采样状态可记为

$$z_t = (a_t, f_t, H_t),$$

其中 a_t 表示原子类型字段， $f_t \in [0, 1)^{N \times 3}$ 表示周期分数坐标， $H_t \in \mathbb{R}^{3 \times 3}$ 表示以行向量为约定的晶胞矩阵。模型输出相应的原子、位置和晶胞预测量。固定 CFG=2.0 的 MatterGen 参考基线记为 C0；在本章中，C0 还固定目标磁性密度为 0.2、扩散步数为 1 000，并在每步执行一次 corrector。




图 4-1: RC-NFGD 在线引导流程

Fig. 4-1: Online Guidance Workflow of RC-NFGD

条件生成目标主要约束样本分布与目标属性，并不等价于逐步最小化某一原子势能。对于生成结构 $C = (a, f, H)$ ，若神经势给出第 i 个原子的笛卡尔力 F_i ，本章关注两个预松弛代理指标：

$$\text{MaxF}(C) = \max_i \|F_i\|_2, \quad \text{MeanF}(C) = \frac{1}{N} \sum_{i=1}^N \|F_i\|_2.$$

较大的代理力说明该结构在所用机器学习势的能量面上偏离局部平衡，但它不是 DFT 力，也不能单独证明结构不稳定或不可合成。常见处理方式是在生成结束后进行结构松弛；本章研究的是另一问题：能否在生成尚未结束时，把外部神经势提供的局部几何反馈直接嵌入逆扩散轨迹，使模型在保持原条件生成过程的同时减少终态代理受力？

4.1.2 直接力引导的困难

直接对所有时间步施加力反馈存在两类困难。第一，早期 z_t 含有较强噪声，原子类型、坐标和晶胞尚未形成一致晶体，神经势在此类状态上的输出缺乏明确解释。第二，MatterSim 返回笛卡尔坐标中的原子力，而 MatterGen 的位置状态是周期分数坐标，且预测器通过 score 项而非直接坐标加法完成更新；若忽略坐标系和更新系数，力方向、位移尺度和周期边界都可能被错误处理。

因此，本章把方法设计分解为三个问题：其一，何时预测干净结构足够可靠；其二，如何把神经势的笛卡尔方向映射到周期位置状态；其三，如何控制单次修正并在异常情况下执行安全回退。RC-NFGD 的核心不是让 MatterSim 取代 MatterGen，而是在经诊断选定的后期窗口内，为原位置预测器增加一个可审计的、仅作用于坐标字段的外部反馈。整体流程如图 4-1 所示。

4.1.3 研究假设与验证原则

本章的核心假设不是“神经势能够在任意噪声阶段提供正确答案”，而是一个范围更窄、可被实验否证的命题：当预测干净结构与最终结构的代理受力已经

具有足够高的排序一致性时，沿中心化神经势力方向施加小幅位置反馈，可以在不改动 MatterGen 权重和条件机制的前提下，降低最终结构的代理受力。该假设包含阶段可靠性、方向有效性和质量代价三个部分，分别由阶段诊断、方向消融和正式配对实验检验。

验证过程遵循由小到大的冻结流程。阶段诊断只决定时间窗口和参考尺度；P0 检查可行性与安全护栏；Formal32 检查独立复现；Formal256 承担正式主结论。每一阶段使用新的配对种子，候选通过后才进入下一阶段，并保持采样器、阈值与主指标不变。最终证据同时报告配对胜负、均值效应、20 000 次 bootstrap 区间和质量护栏，而不以单个均值作为充分依据。由于主力评价器参与引导，另用 CHGNet 检查跨势方向；由于在线方法可能并不优于终态修正，再设置等调用预算的生成后修正比较。这样的验证结构使“方法有效”与“方法在所有替代方案中最优”成为两个明确分离的问题。

4.2 后期结构可靠性分析

4.2.1 诊断协议

神经势模型需要完整晶体作为输入，但当前扩散状态 z_t 本身包含噪声。为避免直接评价含噪状态 x_t ，本研究从 MatterGen 的当前状态和模型输出解析恢复预测干净结构 $\hat{z}_0(t)$ ，并在 32 个冻结诊断种子上保存 $t = 0.10, 0.05, 0.02, 0.01$ 四个非终态时间点及最终参考状态。诊断样本划分为 16 个 calibration seeds 和 16 个 validation seeds；阶段门槛使用预注册的 32 样本整体 Spearman 相关性。每个时间点均调用 MatterSim-5M 计算预测干净结构的 MaxF，再与同一轨迹最终结构的 MaxF 比较。

归档中标为“requested_t_norm=0.00”的一行实际上是采样器在 ϵ 处、“model_t=0.001”的最后一次 predictor 之后的状态，并非数学意义上的 $t = 0$ 模型求值。因此，阶段选择明确排除这一终态行，只在 $t \leq 0.05$ 的非终态点中选择。诊断还检查有限值、明显 OOD、最小周期距离和体积范围；160 次阶段评价全部有限且有效，明显 OOD 比例为 0。

4.2.2 阶段相关性结果

表 4-1 给出预测干净结构的 MaxF 与最终 MaxF 的主要诊断结果。 $t = 0.02$ 的 Spearman 相关系数达到 0.925587 ($n = 32, p = 3.422 \times 10^{-14}$)，为预注册非终态候选中的最高值；此时有限/有效率为 100%，预测干净结构的 MaxF 与最终 MaxF 的中位绝对差为 0.012049 eV/Å。验证子集在该点的 Spearman 相关系数为 0.982353，说明排序一致性并非仅来自 calibration 子集。相比之下，同一时间点的预测干净结构能量/原子与最终 E-hull 的 Spearman 相关系数仅为 0.269428，没有

达到 0.30 的辅助支持门槛。本研究据此只把阶段诊断用于“MaxF 信号可用于后期引导”的判断，不把它扩展为能量或稳定性的普遍可靠性结论。

表 4-1: 后期预测干净结构的阶段可靠性诊断
Tab. 4-1: Stage Reliability Diagnosis for Predicted Clean Structures at Late Timesteps

t	样本数	有限/有效率	MaxF-最终		
			MaxF Spearman	MaxF 中位绝对差 p 值	MaxF 中位绝对差 (eV/Å)
0.10	32	100%	0.812683	1.609×10^{-8}	0.0376410
0.05	32	100%	0.707845	5.863×10^{-6}	0.0302772
0.02	32	100%	0.925587	3.422×10^{-14}	0.0120487
0.01	32	100%	0.912757	3.409×10^{-13}	0.0125316

上述结果支持的命题是：在当前模型、条件和神经势下，后期 $t \leq 0.02$ 的预测干净结构所给 MaxF 与最终 MaxF 具有较强排序一致性。它不意味着早期力一定错误，也不意味着后期力在物理上精确。RC-NFGD 中的“Reliability-Calibrated”正是指引导窗口由这一冻结诊断确定，而不是在正式结果出现后选择有利时间步。

这里选择 Spearman 相关而非只比较阶段均值，是因为引导需要识别哪些轨迹具有更大的局部受力风险。即使阶段 MaxF 与终态 MaxF 存在线性尺度偏差，只要排序稳定，后期信号仍可作为相对风险反馈；反之，阶段均值接近终态但逐样本排序混乱，并不能支持闭环介入。诊断中 $t = 0.02$ 的 Pearson 相关系数也达到 0.984905，但阶段门槛预先指定的是对异常值和非线性尺度更稳健的 Spearman 指标，故正式选择不以后验更有利的 Pearson 结果替代。

此外， $t = 0.10$ 的相关系数已经为正，但其 MaxF 中位绝对差约为 $t = 0.02$ 的三倍； $t = 0.05$ 的排序相关性又低于 0.02。这说明“越接近终点越可靠”在当前有限网格上并非严格单调定律。冻结窗口应理解为诊断得到的任务特定工作区间，而不是关于所有扩散模型的普遍时间规律。后续实验只验证这一选定窗口的总体方法，不再根据 P0 或 Formal 结果重新挑选时间点。

4.3 RC-NFGD 方法设计

4.3.1 预测干净结构的解析恢复

记 MatterGen 在时间 t 的三个输出为 s_t^a, s_t^f, s_t^H 。实际代码对三个字段采用不同的预测干净结构估计，而非人为规定一个统一公式。对离散原子类型，取原子类别输出的最大分量，并加上离散 corruption 的类别偏移 o_a ：

$$\hat{a}_{0,i} = \arg \max_k s_t^a(i, k) + o_a.$$

对周期位置，设位置 SDE 在当前时间的边缘标准差为 $\sigma_f(t)$ ，则实现中的预测干净结构估计为

$$\hat{f}_0 = \text{wrap}\left(f_t + \sigma_f^2(t)s_t^f\right),$$

其中 wrap 将分数坐标映射回周期基本单元。对晶胞字段，设 $\alpha_H(t)$ 和 $\sigma_H(t)$ 分别为 cell SDE 的均值系数和标准差， M_∞ 为其极限均值，则

$$\hat{H}_0 = \frac{H_t + \sigma_H^2(t)s_t^H - [1 - \alpha_H(t)]M_\infty}{\alpha_H(t)}.$$

由 $(\hat{a}_0, \hat{f}_0, \hat{H}_0)$ 构造带周期边界的完整预测干净晶体，供神经势评价。该过程只为计算反馈创建评价结构，并未把三个预测干净结构估计直接替换进采样状态。

4.3.2 神经力场原子力估计

本研究使用冻结的 MatterSim-5M 神经势模型（机器学习原子间势，MLIP）作为引导器。机器学习原子间势以晶体结构为输入，近似势能及其导数；在经典关系下，第 i 个原子的力写为

$$F_i = -\nabla_{r_i} E_{\text{MS}}(\hat{a}_0, \hat{f}_0, \hat{H}_0),$$

其中 $r_i = \hat{f}_{0,i}\hat{H}_0$ 为笛卡尔坐标， E_{MS} 表示 MatterSim 预测能量 [19]。工程实现通过 MatterSim inference 接口直接获得 energy 和 forces，并没有在本研究中执行 DFT 梯度计算。为消除整体平移分量，先对力做中心化：

$$\tilde{F}_i = F_i - \frac{1}{N} \sum_{j=1}^N F_j.$$

中心化后所有原子修正之和为零，使反馈关注内部相对几何，而不人为平移整个周期晶胞。

4.3.3 周期坐标与力方向映射

MatterSim 力和拟议位移位于笛卡尔坐标系，MatterGen 的位置状态则为分数坐标。按照代码中的行向量约定，笛卡尔坐标与分数坐标满足

$$r = fH.$$

因此，在冻结的预测干净晶胞 $\hat{H}_0$ 下，笛卡尔位移 δr 的分数坐标表示为

$$\delta f = \delta r \hat{H}_0^{-1}.$$

候选位置通过 $\text{wrap}(\hat{f}_0 + \delta f)$ 施加周期边界。该映射避免把具有 Å 单位的笛卡尔量直接加到无量纲分数坐标上，也保留非正交晶胞中的几何方向。若预测干净晶胞含非有限值或行列式非正，方法立即执行安全回退，继续使用原始 MatterGen score。

4.3.4 有界位置修正与安全回退

设冻结参考力为 $F_{\text{ref}} = 0.0779514922 \text{ eV/\AA}$ ，名义步长为 $\eta = 0.005 \text{ \AA}$ ，硬上限为 $\delta_{\text{max}} = 0.01 \text{ \AA}$ 。实现先计算 $q = \max_i \|\tilde{F}_i\|_2$ ，再得到

$$\gamma = \frac{\eta}{\max(q, F_{\text{ref}})}, \quad \delta r_i^{(0)} = \gamma \tilde{F}_i.$$

若 $m = \max_i \|\delta r_i^{(0)}\|_2 > \delta_{\text{max}}$ ，则统一缩放为

$$\delta r_i = \frac{\delta_{\text{max}}}{m} \delta r_i^{(0)};$$

否则 $\delta r_i = \delta r_i^{(0)}$ 。由于当前冻结缩放已经把事件内最大位移限制在不超过名义 $0.005 \text{ \AA}$ ， $0.01 \text{ \AA}$ 硬上限在正式运行中没有成为主要约束；P0 和 Formal32 的最大观测修正均为 $0.005 \text{ \AA}$ 。故本文将其称为“有界修正”，作用定位为显式步长控制与异常防护，而不是经过实验确认的性能核心。

映射到分数坐标后，算法在预测干净晶体上预演候选位置。只有当最小周期原子间距有限且不小于 $0.5 \text{ \AA}$ 时才接受修正；任何神经势异常、非有限数、无效晶胞、过小 score 系数或距离违规都会触发安全回退，继续使用未修改的 MatterGen score。该规则保证异常反馈不会替换原预测器，但并不构成对真实物理安全性的保证。

4.3.5 生成过程中的后期力引导

RC-NFGD 不直接把 δf 加到当前状态，而是利用祖先 predictor 的实际 score 系数实现等价注入。设位置 predictor 在当前步的更新可抽象为

$$f_{t-\Delta t} = A_t(f_t) + c_t^f s_t^f + \xi_t,$$

其中 A_t 汇集不依赖当前位置 score 的确定性项， c_t^f 是代码通过 predictor coefficient 接口得到的精确 score coefficient， ξ_t 表示该 predictor 的随机项。算法定义

$$\Delta s_t^f = \frac{\delta f}{c_t^f}, \quad \tilde{s}_t^f = s_t^f + \Delta s_t^f.$$

于是 guided predictor 的 score 贡献为

$$c_t^f \tilde{s}_t^f = c_t^f s_t^f + \delta f,$$

恰好把期望的分数坐标位移加入本次 predictor 更新。引导只在 predictor 阶段且 $t \leq 0.02$ 时启用；atomic、cell、stress 和 energy guidance 全部关闭，corrector 也保持官方更新。1 000 步采样中实际触发 20 次，对应模型时间 0.020, 0.019, ..., 0.001。图 4-1 中的“构造预测干净晶体—评价力—坐标映射—score 注入”即为这一闭环。

算法 4-1 基于阶段可靠性校准的后期神经力场引导扩散 (RC-NFGD)

输入：条件 c ，初始噪声 z_1 ，MatterGen predictor-corrector，

Matter Sim 力模型，可靠阶段阈值 $t_{\text{rel}}=0.02$ ，

F_{ref} , η , δ_{max} ，最小周期距离 d_{min}

输出：最终晶体 z_0

```

1: 初始化  $z \leftarrow z_1$ ；固定  $\text{CFG}=2.0$ 
2: for  $t$  从 1 递减至采样器  $\epsilon$  do
3:     计算 MatterGen 条件/无条件输出并组成原始 score  $s_t$ 
4:     if 当前阶段不是 predictor 或  $t > t_{\text{rel}}$  then
5:         使用原始  $s_t$  完成官方 predictor/corrector 更新
6:         continue
7:     end if
8:     按各字段真实 SDE 公式恢复  $(\hat{a}_t, \hat{f}_t, \hat{H}_t)$ 
9:     用 Matter Sim 在该预测干净晶体上计算  $E$  和笛卡尔力  $F$ 
10:    去除  $F$  的整体平移分量，并按  $F_{\text{ref}}$ 、 $\eta$  和  $\delta_{\text{max}}$  构造  $\delta r$ 
11:    计算  $\delta f \leftarrow \delta r \cdot \hat{H}_t^{(-1)}$ ，并在周期边界下预演候选结构
12:    if 输出有限、晶胞有效且候选最小周期距离  $\geq d_{\text{min}}$  then
13:        从 predictor 取得实际位置 score 系数  $c_t^f$ 
14:         $s_t^f \leftarrow s_t^f + \delta f / c_t^f$ 
15:    else
16:        保留原始 score (安全回退)
17:    end if
18:    完成该步官方 predictor；atomic/cell score
    与 corrector 不变
19: end for
20: 返回最终晶体  $z_0$ 
    
```

4.4 阶段可靠性校准与方法冻结

RC-NFGD 的所有关键量在确认性样本生成前冻结。阶段阈值来自 4.2 节的诊断； F_{ref} 取 calibration seeds 710000–710015 在 $t = 0.02$ 的 MaxF 中位数；位置修正乘子固定为 1.0，没有执行 lambda sweep、时间步 sweep 或位移上限 sweep。表 4-2 汇总最终配置。

表 4-2: RC-NFGD 冻结配置
Tab. 4-2: Frozen Configuration of RC-NFGD

配置项	冻结值作用
目标磁性密度	0.2条件任务
CFG	固定 2.0与 C0 保持一致
扩散步/每步 corrector	1 000 / 1官方采样预算
可靠阶段	predictor 且 $t \leq 0.02$ 共 20 次力反馈
预测干净结构评价	开启不在含噪状态 x_t 上评价力
引导字段	position onlyatomic/cell/stress/energy 均关闭
F_{ref}	0.0779514922 eV/Å低力区尺度基准
名义步长 η	0.005 Å单事件修正尺度
硬上限 δ_{max}	0.01 Å防止异常大位移
最小周期距离	0.5 Å候选安全检查
安全回退	原始 MatterGen score异常时不施加修正

图 4-1 给出流程，阶段诊断则给出“为何从 $t = 0.02$ 开始”的依据。二者共同限定“可靠性校准”的含义：这里的校准是一次性、冻结的阶段选择和尺度确定，不是采样时根据正式结果自适应调参。P0、Formal32 和 Formal256 均沿用同一实现；Formal256 的实现锁记录了源文件哈希，所有注册种子均保留，不因结果好坏替换。

阶段诊断与效果确认在协议上承担不同职责。诊断集合可以用于确定 t_{rel} 和 F_{ref} ，但不能用于估计正式改善；P0、Formal32 与 Formal256 的配对 seed 则不参与这些量的选择。参考力使用 calibration 半集在 $t = 0.02$ 的 MaxF 中位数，主要避免低力样本因直接除以很小的最大力而得到不稳定比例。对 $q \geq F_{\text{ref}}$ 的事件，事件内最大位移被缩放到 0.005 Å；对 $q < F_{\text{ref}}$ 的事件，最大位移随受力减小而继续缩小。因此，它兼具高力区归一化和低力区衰减，而不是对每次事件强制施加相同幅度。

复现性还依赖确定性配对设计。每个实验臂从相同 seed 启动，基础模型权重冻结，C0 和 F0 的主网络 score 调用数相同；Formal256 配置、源代码哈希和 256 个种子均在运行前登记。20 次 MatterSim 调用是 RC-NFGD 的组成部分，不包括最终统一评价所需的离线评价调用。这样可以把配对差异主要归因于在线位置反馈，同时保留神经势自身误差、硬件运行波动和不同代理模型之间偏差等不能消除的外部不确定性。

4.5 小规模验证与方法冻结

4.5.1 P0 可行性验证

P0 使用 16 个全新配对种子比较官方基准 B0 与 RC-NFGD F0。320 次符合条件的力引导全部被接受，安全回退次数为 0。Mean MaxF 从 0.304028 降至 0.253392 eV/Å，相对降低 16.66%，配对胜/平/负为 15/0/1，20 000 次配对 bootstrap 的相对改善 95% CI 为 [10.17%, 31.24%]。平均原子力从 0.148469 降至 0.123007 eV/Å，RMSD 从 0.116299 降至 0.114453 Å。

质量侧没有出现 P0 门槛规定的明显退化：Stable 均为 75.00%，NUS 均为 31.25%，Validity 均为 100%；Property MAE 从 0.009940 略降至 0.009889，E-hull 则增加 0.000809 eV/atom。端到端生成时间比为 0.9998。由于 P0 仅承担先导筛选作用，其 GO 不能替代更大独立 cohort 的确认。

4.5.2 Formal32 独立复现

方法在 P0 之后保持不变，并在 32 个新配对种子上进行 Formal32。MaxF 从 0.183472 降至 0.134728 eV/Å，相对降低 26.57%；32 个样本全部改善，20 000 次 bootstrap 的相对改善 CI 为 [14.27%, 52.86%]。平均原子力从 0.073237 降至 0.048879 eV/Å，RMSD 从 0.052132 降至 0.048991 Å，相对约降低 6.03%。Stable、Novel、Unique、NUS 和 Validity 均保持不变；Property MAE 从 0.006128 轻微增至 0.006148，E-hull 增加 0.000180 eV/atom，均在冻结护栏内。F0/C0 端到端运行时间比为 1.00336。

表 4-3: P0 与 Formal32 的效应复现
Tab. 4-3: Effect Reproduction on P0 and Formal32

实验	C0/B0 RC-NFGD					
cohort	<i>n</i>	MaxF	MaxF	相对降低	95% CI	W/T/L判定
P0	16	0.304028	0.253392	16.66%	[10.17%, 31.24%]	15/0/1GO
Formal 32	32	0.183472	0.134728	26.57%	[14.27%, 52.86%]	32/0/0STRONG_ CONFIR MED

P0 与 Formal32 的作用是验证方法可运行且改善方向能在新 cohort 上复现。图 4-4 将这两个阶段与 Formal256 的效应量并列显示。不同 cohort 的绝对 MaxF 受组成和样本难度影响，不能把三组绝对均值解释为随样本规模单调变化；可比较的是冻结方法在三组新种子上都得到正向相对效应。

4.6 Formal256 正式实验

4.6.1 实验设计与主结果

Formal256 使用 256 个注册配对种子，C0 与 RC-NFGD 从相同 seed 生成，各方法均完成 256/256，没有丢弃或替换样本。主统计量定义为 cohort 均值的相对降低

$$R_m = \frac{\bar{y}_{C0} - \bar{y}_{RC}}{\bar{y}_{C0}},$$

其中对“越低越好”的连续指标， $R_m > 0$ 表示改善。置信区间由冻结随机种子下 20 000 次配对 bootstrap 获得。表 4-4 完整报告主力指标与质量护栏，不隐藏不利的属性变化。

表 4-4: Formal256 主结果（相对变化和 CI 均按 C0—RC-NFGD 的有利方向定义）

Tab. 4-4: Formal256 Main Results (relative changes and CIs use the favorable C0 minus RC-NFGD direction)

指标	队列均值		效应与区间		配对方向
Metric	Means		Effect + CI		Paired
指标	C0	RC-NFGD有利相对变化		95% CI	W/T/L
MatterSim	0.226408	0.158911	29.81% 改善	[21.42%, 40.88%]	254/0/2
MaxF					
(eV/Å)					
MatterSim	0.098702	0.069373	29.72% 改善	[24.01%, 36.96%]	255/0/1
Mean					
Force					
(eV/Å)					
RMSD (Å)	0.051137	0.043893	14.17% 改善	[4.54%, 25.95%]	216/21/19
Property	0.009757	0.009868	1.14% 恶化	[−2.46%, −0.22%]	95/0/161
MAE					
(μ _B /Å ³)					
Stable	80.86%	80.86%	0	[0, 0]	0/256/0
Validity	100%	100%	0	[0, 0]	0/256/0




图 4-2: Formal256 主要代理结构指标

Fig. 4-2: Main Proxy Structural Metrics on Formal256

MaxF 的绝对改善为 $0.067497 \text{ eV/\AA}$, 绝对改善 CI 为 $[0.046627, 0.105057] \text{ eV/\AA}$, 单侧配对胜率检验 $p = 2.84 \times 10^{-73}$ 。Mean Force 的绝对改善为 $0.029330 \text{ eV/\AA}$, RMSD 的绝对改善为 $0.007244 \text{ \AA}$ 。三项相对改善区间均严格大于零, 且 MaxF 有 254/256 个配对样本改善, 说明主结论并非由少数均值离群点单独驱动。图 4-2 展示三项主要均值, 图 4-3 展示逐样本改善分布。

配对统计对本实验尤其重要。C0 与 RC-NFGD 在同一 seed 上共享初始随机条件, 逐 seed 差值能够消除一部分由组成和采样难度造成的样本间变异。均值相对改善回答 cohort 总体尺度变化, W/T/L 回答方向覆盖率, bootstrap 区间则给出有限样本下效应不确定性; 三者不能相互替代。MaxF 的 254 次改善和 2 次恶化说明方向高度一致, 但仍不能声称每个样本都改善。RMSD 有 216 次改善、21 次持平和 19 次恶化, 其覆盖率弱于两项受力指标, 也提示“受力降低”与“所有松弛几何量逐样本同步降低”并非同一命题。

Property MAE 的报告采用同样符号约定: 表中的正相对变化代表对“越低越好”指标的改善, 因此 -1.14% 明确表示恶化, 而非数值减少。其区间完全为负且损失数高于胜率, 不能用“变化很小”将方向抹去。正式判定仍为 SUPPORTED, 是因为预注册主终点为 MatterSim MaxF, Property MAE 属于带容忍范围的护栏; 这意味着方法通过了既定判据, 不意味着属性代价不存在。




图 4-3: Formal256 配对改善分布

Fig. 4-3: Paired Improvement Distribution on Formal256




图 4-4: P0、Formal32 与 Formal256 效应方向一致性

Fig. 4-4: Consistency of Effect Direction across P0, Formal32, and Formal256

4.6.2 效应一致性、尾部与质量护栏

图 4-4 给出 P0、Formal32 和 Formal256 的 MaxF 相对效应及区间。三个完全分离的 cohort 上，效应由 16.66% 到 26.57% 再到 29.81%，置信区间均为正。这种跨规模的方向保持是 RC-NFGD 可复现性的主要证据；它不表示效应量必然随样本规模增加，也不允许跨 cohort 直接比较绝对难度。

MatterSim 分布尾部在 Formal256 上也总体下降：MaxF 的 P90 从 0.390303 降至 0.329501 eV/Å，P95 从 0.744050 降至 0.677620 eV/Å，最大值从 5.375634 降至 3.429568 eV/Å；MaxF 大于 0.2 eV/Å 的比例从 22.27% 降至 18.36%。这些是 cohort 描述统计，不单独作为预注册主检验。

质量侧呈现清晰的“力改善—属性轻微代价”边界。Stable 保持 80.86%，Validity 保持 100%，NUS 从 21.09% 增至 21.48%；E-hull 均值由 0.091298 增至 0.091767 eV/atom，即增加 0.000469 eV/atom。Property MAE 则从 0.009757 增至 0.009868，其不利变化的相对 CI 为 [-2.46%, -0.22%]，因此不能宣称目标属性得




图 4-5: RC-NFGD 在 Formal256 上的质量护栏

Fig. 4-5: Quality Guardrails of RC-NFGD on Formal256

到改善。图 4-5 同时显示这些质量护栏，防止只选择有利指标进行报告。

4.6.3 计算开销

C0 与 RC-NFGD 每个样本都进行 2 000 次 MatterGen score 调用。RC-NFGD 额外进行 20 次 MatterSim 调用，但没有增加 MatterGen 主网络调用；其平均端到端时间为 92.663 s，C0 为 92.849 s，记录的比值为 0.9980。该差异落在运行波动内，不能解释为加速。更稳妥的结论是：在当前硬件和串行 batch-size-1 配置下，20 次后期神经势调用没有造成可辨识的总体时间增长。RC-NFGD 的最大记录显存约 0.463 GiB，C0 约 0.359 GiB；跨设备部署仍应重新测量实际开销。

4.7 CHGNet 独立代理评估

4.7.1 跨神经势评估动机与结果

MatterSim 同时参与 RC-NFGD 的力引导和 Formal256 的主要力评价，存在评价器自洽风险：方法可能特别适配 MatterSim 的局部能量面，而不一定在其他模型下保持改善。为降低这一风险，本研究在同一 256 对最终结构上使用 CHGNet 0.3.0 重新计算原子力 [18]。CHGNet 不参与 RC-NFGD 的力反馈，因此称为独立代理评估器；但它同时用于项目中的磁性属性护栏，而且不能排除与其他模型的




图 4-6: MatterSim 与 CHGNet 的逐样本改善比较

Fig. 4-6: Per-Sample Improvement Comparison between MatterSim and CHGNet

训练数据重叠，故这里的“独立”不是完全盲测或 DFT 独立验证。

表 4-5: CHGNet 在 Formal256 上的独立代理评估

Tab. 4-5: Independent CHGNet Proxy Evaluation on Formal256

指标	C0	RC-NFGD	相对改善	相对改善 95%	
				CI	W/T/L
CHGNet MaxF (eV/Å)	0.193891	0.166057	14.36%	[4.32%, 27.73%]	172/0/84
CHGNet Mean Force (eV/Å)	0.087976	0.079541	9.59%	[3.08%, 19.10%]	169/0/87

CHGNet MaxF 的绝对改善为 0.027833 eV/Å，绝对 95% CI 为 [0.007052, 0.064868]; Mean Force 的绝对改善为 0.008435 eV/Å，绝对 CI 为 [0.002384, 0.019148]。两个均值终点的区间均排除零，方向与 MatterSim 一致，但效应量更小、逐样本损失数更多。图 4-6 展示两个神经势模型在逐 seed 改善上的对应关系；散点关系只能说明两个代理评估器的结果可比较，不能作为 DFT 一致性或因果验证。

4.7.2 尾部结果的限制

CHGNet 的均值改善并没有覆盖所有分位数。MaxF P90 从 0.405853 增至 0.425399 eV/Å，P95 从 0.661234 增至 0.696249 eV/Å；相反，样本最大值从 5.072047 降至 1.814435 eV/Å。结构级 Mean Force 的中位数也从 0.046336 增至 0.048166

eV/Å, 而 P90 和 P95 分别从 0.220622、0.284405 降至 0.213307、0.276406 eV/Å。这种混合形态说明 RC-NFGD 的跨势证据应表述为“预先指定的均值与配对力指标方向一致改善”, 不能表述为“每个样本、每个分位数或全部尾部风险均得到改善”。

4.8 消融实验与边界分析

4.8.1 力方向消融

为区分“真实力方向有效”与“任何同尺度坐标扰动都有效”, 冻结消融在 32 个新种子上设置五个分支: G0 为无力引导; G1 为真实 MatterSim 方向; G2 使用与配对 G1 每原子位移范数集合相同、零净平移的随机方向; G3 打乱 G1 修正在原子间的对应; G4 反转配对 G1 轨迹的修正方向。G2/G3/G4 重放的是配对 G1 轨迹上的位移尺度, 而不是各自轨迹上重新闭环计算的当前力, 特别是 G4 不能解释为沿自身势能梯度上升。

表 4-6: 力方向消融 ($n = 32$)
Tab. 4-6: Force-Direction Ablation (n=32)

分支方向定义	MatterSim Mean MaxF (eV/Å)	P95 (eV/Å)
G0 无位置力反馈	0.141690	0.376479
G1 真实 MatterSim 力方向	0.098500	0.304940
G2 匹配范数的随机零和平移方向	0.153744	0.379922
G3 原子间打乱的配对 G1 修正	0.151428	0.386740
G4 反向配对 G1 修正	0.188137	0.439113

G1 相对 G0 的 Mean MaxF 降低 30.48%, 95% CI 为 [24.66%, 38.87%], W/T/L 为 31/0/1; CHGNet 独立代理评估器给出的 MaxF 也从 0.128627 降至 0.118331, 方向改善 8.00%, 相对 CI 为 [1.64%, 13.60%]。真实方向优于随机、打乱和反向控制的描述性次序, 支持“力方向携带有用的局部结构信息”。但由于控制方向重放 G1 的轨迹幅度而非在各自轨迹上闭环重算, 不能据此证明力是理论最优更新方向, 也不能完全分离路径依赖。

4.8.2 有界位置修正消融

有界修正消融比较 T0 (无引导)、T1 (冻结 RC-NFGD) 与 T2 (去除范数相关饱和和 0.01 Å 硬 cap, 但保留阶段、真实力方向、score 映射和 0.5 Å 几何安全检查)。T0、T1、T2 的 MatterSim Mean MaxF 分别为 0.277138、0.231502 和 0.060834

eV/Å; T2 相对 T1 的均值更低。T2 的冻结质量护栏在该 $n = 32$ cohort 上也通过, 尽管其 Property MAE 恶化 2.37%。CHGNet 上 T2 并未稳定优于 T1: 独立 MaxF 为 0.148970 对 0.141334 eV/Å, 二者差异区间跨零。

因此, 实验不支持“显式 bound 是性能收益的必要原因”或“bounded 优于 unbounded”。同时, T2 一次性移除了归一化饱和与硬 cap, 无法单独归因二者。本文保留 bound 的理由是它使单事件幅度可解释、可审计, 并限制异常力造成的大位移; 这是保守的数值设计选择, 而不是已由消融证明的性能核心。为避免概念夸大, 正文不把它称为经过验证的 trust-region optimizer。

4.8.3 在线引导与等预算生成后修正

等预算实验在 32 个新种子上比较 C0、在线 F0 和生成后 POST。POST 从 C0 最终结构出发, 最多使用与配对 F0 实际调用数相同的 20 次 MatterSim 力评价, 并重复同一有界下降与安全检查。三者 Mean MaxF 分别为 0.214179、0.163650 和 0.043275 eV/Å; POST 的 P95 为 0.207183 eV/Å, 也低于 F0 的 0.673935 eV/Å。F0 相对 POST 在全部 32 个配对样本上均更差, 故不能主张在线 RC-NFGD 优于等预算生成后松弛。

这一负结果不否定本章主命题, 因为两种方法回答不同问题: POST 明确修改已经生成的终态, RC-NFGD 验证的是神经势反馈可以进入扩散轨迹且在 Formal256 上降低终态代理受力。公平的结论是, 当前实验支持“在线引导可行且有可复现收益”, 但在同一 MatterSim 指标上, 所测生成后修正更强。若实际应用只追求最低代理力, POST 是必须保留的竞争基线; 若研究目标是分析生成轨迹内的物理反馈, RC-NFGD 提供了不同的算法接口。

4.8.4 与 Adaptive CFG 的兼容性

兼容性实验在 64 个配对种子上比较 C0、Adaptive CFG (A0)、单独力引导 (B0) 和组合方法 (AB)。Mean MaxF 分别为 0.218922、0.239629、0.171833 和 0.192794 eV/Å。组合 AB 保留 Adaptive CFG 属性改善的比例约为 0.9745, 但只保留单独力引导 MaxF 改善的约 0.5549, 低于冻结的 0.7 双保持阈值, 最终状态为 FAIL。因而本论文将创新点 1 与创新点 2 作为独立贡献报告, 不宣称存在稳定协同, 也不把 AB 作为最终模型。

4.9 属性——代理受力的 Pareto 权衡

为避免仅报告单一受力指标, 本节在历史 A6 同一组 32 对结构上, 以冻结属性代理的 Property MAE 和预松弛 MatterSim MaxF 构造二维方法均值比较; 两项指标均以越低为好。该分析只重用已保存的 C0、RC-NFGD 与等 20 次力调用的

表 4-7: 历史 A6 配对 cohort 的属性—代理受力权衡 ($n = 32$, 均值 $\pm$ 样本标准差)

Tab. 4-7: Property–Surrogate-Force Trade-off in the Historical A6 Paired Cohort ($n = 32$; Mean $\pm$ Sample Standard Deviation)

方法	Property MAE	MatterSim MaxF (eV/Å)
C0	0.007900 $\pm$ 0.006690	0.214179 $\pm$ 0.239536
RC-NFGD	0.007886 $\pm$ 0.006537	0.163650 $\pm$ 0.230165
POST	0.007933 $\pm$ 0.006363	0.043275 $\pm$ 0.138975

表 4-8: 力反馈注入阶段消融: 32 对新种子的均值 $\pm$ 样本标准差; 耗时为端到端 wall time

Tab. 4-8: Force-Feedback Timing Ablation: Mean $\pm$ Sample Standard Deviation over 32 Fresh Paired Seeds; Time Is End-to-End Wall Time

方法	力调用/样本	Wall time (s)	MaxF (eV/Å)	Property MAE
C0	0.0 $\pm$ 0.0	86.7 $\pm$ 1.5	0.18986 $\pm$ 0.25256	0.01515 $\pm$ 0.02150
Early	931.5 $\pm$ 26.0	258.5 $\pm$ 192.0	0.16860 $\pm$ 0.27755	0.00838 $\pm$ 0.00894
Middle	500.0 $\pm$ 0.2	106.5 $\pm$ 3.0	0.14072 $\pm$ 0.17955	0.01120 $\pm$ 0.01044
Late	20.0 $\pm$ 0.0	88.3 $\pm$ 2.6	0.13864 $\pm$ 0.21623	0.01522 $\pm$ 0.02151

POST 结果, 不引入新的选择规则。表 4-7 与图 4-7 只比较 A6 同 cohort 的方法均值, 不将 Formal256 或后述 Timing 样本混入同一个前沿。

在方法均值点估计上, RC-NFGD 与 POST 均位于描述性 Pareto 前沿: 前者的属性代理误差略低, 后者的同势 MaxF 明显更低。然而, RC-NFGD 减 POST 的 Property MAE 配对差为 -0.000048 , 20 000 次配对自助法 95% 区间为 $[-0.000349, 0.000212]$, 跨越零; 不可把极小的点估计差异写成统计确认的属性优势。RC-NFGD 减 POST 的 MaxF 均值差为 0.120375 eV/Å, 95% 区间为 $[0.076924, 0.171350]$, 表明在该 A6 协议中 POST 的终态代理受力更低。Formal256 的 Property MAE 则由 C0 的 0.009757 增至 RC-NFGD 的 0.009868 , 方向与 A6 点估计不同; 两组样本应分别解释。本节前沿只是属性—代理力权衡的描述, 既不证明统计支配, 也不是 DFT 物理结论。

4.10 力反馈注入阶段的影响 (Influence of Force Feedback Injection Stage)

在 ALM 环境通过历史种子复现门槛后, Timing Ablation 使用与历史 A6 和 Formal256 均不重合的 32 个全新配对种子 (750000–750031)。四臂保持冻结的 MatterGen、MatterSim、引导公式、阈值、采样器和评价协议, 只把力反馈开始时间设为无力 C0、Early ($t \leq 1.0$)、Middle ($t \leq 0.5$) 与 Late (原始 RC-NFGD, $t \leq 0.02$)。各臂均需每样本 2000 次 MatterGen score 调用; 但开始时间同时改变了累计 MatterSim 力调用, 因此这不是等力计算预算下的纯时间因果对照。




图 4-7: 历史 A6 同组 32 对结构的 Property MAE–MatterSim MaxF 方法均值及种子自助法 95% 区间。虚线仅连接方法均值的描述性非支配点，不表示统计显著性或跨 cohort 前沿；POST 的终态代理力更低。

Fig. 4-7: Property MAE–MatterSim MaxF Method Means and Seed-Bootstrap 95% Intervals for the Same 32 Paired A6 Structures. The Dashed Line Connects Descriptive Nondominated Mean Points Only; It Does Not Indicate Statistical Significance or a Cross-Cohort Frontier. POST Has Lower Terminal Surrogate Force.

表 4-9: Timing Ablation 的次要代理质量指标 ($n = 32$; 力和 E-hull 为均值 $\pm$ 样本标准差)

Tab. 4-9: Secondary Surrogate-Quality Metrics in the Timing Ablation ($n = 32$; Force and E-hull Are Mean $\pm$ Sample Standard Deviation)

方法	Mean Force (eV/Å)	Validity	Stable	E-hull (eV/atom)	NUS
C0	0.08450 $\pm$ 0.09846	100%	78.13%	0.06549 $\pm$ 0.06896	31.25%
Early	0.07294 $\pm$ 0.09224	100%	75.00%	0.07125 $\pm$ 0.06907	15.63%
Middle	0.05816 $\pm$ 0.05968	100%	78.13%	0.07429 $\pm$ 0.06711	40.63%
Late	0.06051 $\pm$ 0.08720	100%	78.13%	0.06548 $\pm$ 0.06895	31.25%




图 4-8: Timing Ablation 的配对 MatterSim MaxF 差 (候选减 C0), 点为 32 对种子的均值差, 横线为 20 000 次配对百分位自助法 95% 区间。负值表示较低代理力; Early 和 Middle 区间跨零。各臂力调用预算不同, 不构成等预算时机最优证据。

Fig. 4-8: Paired MatterSim MaxF Differences in the Timing Ablation (Candidate Minus C0): Points Are Mean Differences over 32 Paired Seeds and Horizontal Bars Are 20,000-Resample Paired Percentile-Bootstrap 95% Intervals. Negative Values Indicate Lower Surrogate Force; Force-Call Budgets Differ and Do Not Establish an Equal-Budget Optimal Stage.

Late 相对同 cohort C0 的 MaxF 配对差为 $-0.05123 \text{ eV/\AA}$, 95% 区间 $[-0.06834, -0.03770]$, 32/32 对方向有利; Mean Force 配对差为 $-0.02399 \text{ eV/\AA}$, 区间 $[-0.02983, -0.01879]$ 。但 Late 的 Property MAE 亦高出 0.000066, 其配对区间 $[0.000010, 0.000149]$ 位于不利方向。Early 的属性 MAE 均值较低, NUS 点估计却更低且耗时更长; Middle 的受力均值下降, 但 MaxF 的配对区间跨零。Late 减 Early 与 Late 减 Middle 的 MaxF 配对区间分别为 $[-0.13136, 0.06633]$ 、 $[-0.06685, 0.07727]$, 均跨零; 这些未作多重比较校正的探索性结果不支持“Late 唯一最优”。不同阶段呈现代理力、属性保持与力调用成本的不同折中。CUDA event 记录包含 CPU 等待, 不能解释为活跃 GPU 计算时间。

4.11 方法讨论与局限

4.11.1 方法贡献与适用范围

RC-NFGD 的主要贡献可以概括为三个相互连接的环节。第一, 在介入生成轨迹前进行阶段诊断, 用预测干净结构与最终 MaxF 的排序一致性确定可用后期窗口, 避免凭经验从高噪声阶段直接调用神经势。第二, 按真实 SDE 和 predictor 实现完成预测干净结构恢复、笛卡尔—分数坐标映射与 score 系数补偿, 使外部位移与 MatterGen 的周期状态和数值更新一致。第三, 用固定位置步长、最小距离检查和原 score 安全回退形成可审计的在线接口, 并在 P0、Formal32、Formal256

三个独立 cohort 上保持 MaxF 改善方向。

Formal256 与 CHGNet 结果共同支持的最强表述是：在当前磁性密度条件任务和冻结采样配置下，后期 MatterSim 力反馈能够降低两个神经势代理下的平均受力指标，并降低 MatterSim 松弛 RMSD，同时保持 Stable 与 Validity。结果不支持“RC-NFGD 改善所有质量指标”“优于所有生成后方法”或“与自适应 CFG 协同”。

从算法角色看，RC-NFGD 位于“完全依赖生成模型”与“生成后单独松弛”之间。它保留 MatterGen 对原子类型、晶胞与条件分布的主导权，只在预测干净结构已具有可用几何含义时修改位置 predictor；因此，它更接近受约束的采样期反馈，而不是把逆扩散改写成结构优化。该接口的价值在于可以记录每次力调用、修正幅度、距离检查与安全回退，使外部物理代理对采样轨迹的影响可追溯。

另一方面，等预算 POST 的更低 MaxF 表明：若评价目标仅是终态在同一 MatterSim 能量面上的局部受力，那么在终态连续执行下降修正具有明显优势。在线反馈仍要经过后续随机 predictor/corrector，部分修正可能被扩散动力学抵消，也可能为了保留生成分布而不能采用过大的步长。未来工作可以把两者设计为明确的两阶段系统，即用 RC-NFGD 改善生成轨迹的初始几何，再用独立预算的终态松弛满足部署要求；但本章没有验证该组合，不能提前宣称互补收益。

4.11.2 局限性

本方法和实验至少存在以下边界。

1. **没有 DFT 验证。**本章所有能量、力、E-hull 和松弛指标来自机器学习代理模型，`DFT_VERIFIED = false`。代理 MaxF 降低不能等价于真实 DFT 力、热力学稳定性或可合成性已经改善。
2. **MatterSim 存在自洽风险。**MatterSim 同时产生引导信号并承担主要 MaxF/Mean Force 评价，可能高估对其自身能量面的收益。Formal256 的 MatterSim 结论应始终带有 surrogate 限定。
3. **CHGNet 仍不是真实物理基准。**CHGNet 没有参与生成期力引导，因而作为独立代理评估器提供有价值的跨势方向证据，但它仍是 MLIP，不是 DFT 或实验评价；CHGNet 也参与项目的磁性属性护栏，且训练数据可能重叠，不能称为完全盲测。
4. **尾部结果混合。**MatterSim 尾部总体下降，但 CHGNet MaxF P90/P95 上升，Mean Force 中位数也略升。现有证据支持均值和配对方向，不支持所有高分位风险一致改善。
5. **属性控制有轻微代价。**Formal256 Property MAE 从 0.009757 增至 0.009868，恶化约 1.14%，且相对变化区间完全位于不利方向。Stable 与 Validity 不变不能掩盖这一属性退化。

6. **生成后修正更强。**在等 20 次 MatterSim 调用的 $n = 32$ 实验中, POST 的 Mean MaxF 明显低于在线 F0。RC-NFGD 的贡献是生成期力反馈及其可复现实证, 而不是证明在线方式优于生成后松弛。
7. **有界机制未被独立支持为性能核心。**去除饱和和 cap 的 T2 在 MatterSim 上更强, 并通过所测护栏。bound 应被理解为保守的幅度与异常控制, 不能声称其本身显著提升性能; 当前消融也无法分开归因归一化饱和与硬上限。
8. **没有确认与创新点 1 的协同。**Adaptive CFG 与力引导的组合未达到双保持门槛, 最终建议仍是独立使用 F0。两个创新点可共同构成论文的两类推理策略, 但不能写成经验证的联合算法。
9. **任务与模型迁移性未知。**阶段阈值、参考力、步长和安全距离都在当前 MatterGen checkpoint、目标磁性密度 0.2、MatterSim-5M 和 batch-size-1 配置下冻结。跨属性、跨模型、跨晶体规模及其他 MLIP 的最佳阶段与尺度需重新校准。
10. **诊断不等于因果分解。**阶段相关性支持在后期使用预测干净结构, 但没有独立的含噪状态 x_t 确认性对照; 方向消融也具有轨迹重放限制。因此, 本章不主张预测干净结构或真实力方向在理论上唯一最优。

这些边界并不削弱 Formal256 的冻结主结论, 而是限定它的科学范围: RC-NFGD 对代理局部结构一致性的改善得到支持; 关于真实物理稳定性、普适最优性和联合增益的更强命题仍需新的 DFT 与跨任务实验。

4.12 本章小结

本章针对 MatterGen 缺少显式局部力学反馈、而早期噪声结构又不适合直接接受神经势引导的问题, 提出 RC-NFGD。方法首先在 32 个冻结诊断样本上分析预测干净结构的阶段可靠性, 确定 $t = 0.02$ 时预测干净结构的 MaxF 与最终 MaxF 的 Spearman 相关系数为 0.925587; 随后仅在 $t = 0.020 \dots 0.001$ 的 20 个 predictor 事件中调用 MatterSim, 把去平移、缩放并有界的笛卡尔力位移映射为分数坐标, 再通过 predictor 的实际 score coefficient 注入位置更新。原子类型、晶胞、stress 与 corrector 均保持不变, 异常时执行安全回退并使用官方 score。

冻结方法在 P0、Formal32 和 Formal256 上分别得到 16.66%、26.57% 和 29.81% 的 MatterSim MaxF 相对降低。Formal256 中, Mean Force 和 RMSD 分别降低 29.72% 和 14.17%, Stable 保持 80.86%, Validity 保持 100%; 但 Property MAE 恶化约 1.14%。CHGNet 对同一 256 对结构给出 MaxF 14.36% 和 Mean Force 9.59% 的均值改善, 为跨神经势方向一致性提供支持, 同时其部分尾部指标仍然混合。

消融进一步表明, 真实力方向优于匹配尺度的随机、打乱和反向控制; 但有界修正不是已被证明的性能核心, 等预算生成后修正在所测 MatterSim MaxF 上更强, Adaptive CFG 与 RC-NFGD 的协同也未得到支持。因此, 本章最终支持的

创新点是“由阶段可靠性诊断约束的在线后期神经力场反馈”，而不是对 DFT 物理正确性、所有指标改善或相对所有替代方案最优的主张。前两章分别针对条件属性控制和局部结构一致性提出推理阶段方法，第 5 章将在统一评价体系下比较其效果、代价和适用边界。

5 实验结果与综合分析

第3章和第4章分别给出了面向冻结生成器的预算约束验证选择推理框架及其 Fixed-K2 实例，以及基于阶段可靠性校准的后期神经力场引导扩散方法 (Reliability-Calibrated Late-stage Neural Force-Guided Diffusion, RC-NFGD)。本章不再重复算法推导，而是从统一实验口径出发，对两项创新的确认性结果、负结果、机制证据、计算代价和适用边界进行综合分析。全文以冻结发布包中的表格、配对统计和图件为唯一数值来源，不使用新的实验，也不依据结果重新选择样本、指标或阈值。

从统一主线看，两项独立方法均属于“冻结材料生成模型的可信推理增强”：前者使额外生成计算与终点选择可核算、可回退，后者使外部神经势反馈的注入时机、幅度和代理局限可追溯。这里的统一是问题和审计协议的统一，不是已验证的串联增益。

本章的核心结论有两点。第一，在条件属性生成方面，固定双候选分支策略 (Fixed-K2) 在 128 个全新配对种子上将 Property MAE 从 0.034796 降至 0.026332，相对改善 24.32%，20 000 次配对 bootstrap 的绝对改善 95% 置信区间为 [0.005817, 0.011391]；同时，学习型 Linear-K2 未能在相同 2.2 倍预算下独立确认优于 Fixed-K2。新增独立 Best-of-2 在另一组全新配对种子上的均值为 0.028097，数值低于 Fixed-K2 的 0.029506；直接配对差异区间跨零，不能据此声称 Fixed-K2 优于通用多样本筛选。另一个独立 K=0-4 cohort 呈现随候选加入而降低的选中代理误差，但 K=2 不是最低误差点。第二，在局部结构一致性方面，RC-NFGD 在 256 个正式配对种子上将 MatterSim MaxF、Mean Force 和松弛 RMSD 分别降低 29.81%、29.72% 和 14.17%，并在 CHGNet 独立代理评估器上得到方向一致但幅度较小的均值改善。两项创新分别解决“条件控制的保守选择”和“生成期局部力学反馈”问题；现有兼容性实验不支持二者具有稳定协同，因此不能合并写成已经验证的联合模型。

5.1 实验设置与评价协议

5.1.1 证据层级与实验角色

为避免把探索结果、机制诊断和正式确认混为一谈，本研究按实验用途划分证据层级。探索性实验用于暴露失败模式和收缩研究空间；机制实验用于判断某一信息源或设计环节是否具有可利用价值；模型选择实验允许在训练集和验证集上确定候选，但必须由留出测试或后续新种子复核；确认实验则使用冻结方法、冻结主指标和全新种子承担最终结论。小规模 P0 只决定是否进入下一阶段，不

替代正式证据。各关键实验的角色见表 5-1。

表 5-1: 关键实验、样本规模与证据类型
Tab. 5-1: Key Experiments, Sample Sizes, and Evidence Types

创新点	实验	数据规模	证据类型	冻结结论	在本章中的作用
创新点 1	Adaptive CFG V1/V2/V4/V5、阶段与字段变体	依实验而异探索/机制		MIXED 或 FAIL	说明在线局部统计难以稳定预测终点收益
创新点 1	Branch-Compatible Oracle	历史 48, 测试 12探索性机制上界		SUP PORTED_MECHANISM	证明合法分支预算内在可利用空间, 不代表可部署选择器
创新点 1	Phase B Linear-K2	64 (32/16/16)模型选择与留出测试		NOT_SUP PORTED	检验学习型候选分配是否优于固定分配
创新点 1	C1 Fixed-K2	128 对确认实验		SUP PORTED	支撑最终 Fixed-K2 主结论
创新点 1	C1 Linear-K2	128 对负确认实验		NOT_SUP PORTED	否定当前学习型分配器的额外价值
创新点 1	Independent Best-of-2 对照	独立 128 对冻结方法强基线		竞争性成立	不支持 Fixed-K2 超越独立采样; 预算不完全匹配
创新点 1	K=0-4 Budget Scaling	另一独立 128 对固定顺序预算诊断		不均匀收益	K=2 为成本折中, 非最低误差点

创新点	实验	数据规模证据类型	冻结结论	在本章中的作用
创新点 2	阶段可靠性 诊断	32机制/校准	SUP PORTED	冻结后期介入窗口，不用于估计正式效应
创新点 2	RC-NFGD P0	16 对先导实验	PASS	允许进入 Formal32
创新点 2	RC-NFGD Formal32	32 对独立复现	PASS	确认小样本效应方向可复现
创新点 2	RC-NFGD Formal256	256 对正式确认	SUP PORTED	支撑 RC-NFGD 的主要效果结论
创新点 2	CHGNet Formal256	同一 256 对独立代理评估	POSITIVE	降低只适配 MatterSim 的解释风险，但不是 DFT
创新点 2	方向、边界、 等预算与兼容性消融	32 或 64 对机制与边界	SUPPORTED/ NOT_SUP PORTED/ FAIL	限定因果解释、替代方案与联合使用边界

所有核心比较均采用 matched-seed 设计，即同一比较中的基准与方法从相同随机种子启动。创新点 1 的 C1 在历史实验之外注册全新种子，新增 Best-of-2 与 Budget Scaling 又分别使用与 C1、彼此均不重合的新 cohort；创新点 2 的 P0、Formal32 与 Formal256 使用彼此分离的新 cohort。每个阶段均保留全部预注册样本，不因结果异常或方向不利而替换。这样的设计不能消除代理模型偏差，却能显著减少随机初态差异对方法比较的干扰。

5.1.2 指标与统计口径

条件属性控制以 Property MAE 为主要指标，数值越低表示生成结构的代理属性越接近目标条件。E-hull 越低、Stable 比例越高通常代表代理热力学质量更好；Validity 衡量结构能否通过基本有效性检查；Novel、Unique 和 NUS 分别反映

新颖性、唯一性及其交集。创新点 1 还报告候选接受率和回退率，用于区分“候选分支本身有效”与“终点选择加回退后输出有效”。

局部结构一致性以神经势预测的最大原子力 MaxF、平均原子力 Mean Force 以及代理松弛前后的 RMSD 为主要指标，三者均为越低越好。创新点 2 同时检查 Property MAE、Stable、Validity、E-hull、Novel、Unique 和 NUS，以识别力指标改善是否伴随条件控制或分布质量退化。MatterSim 指标属于与引导器同源的代理评价；CHGNet 不参与力反馈，作为独立代理评估器提供跨势评价。两者的证据强度和解释范围不同。

主要连续指标采用 20 000 次确定性配对 bootstrap。对于“越低越好”的指标，改善定义为基准值减去方法值，因此正值表示有利；报告相对改善时也沿用这一符号。胜/平/负 (W/T/L) 按逐样本配对结果统计。置信区间完全高于零时，可认为该冻结 cohort 对有利方向提供统计支持；区间跨零时，只报告点估计方向而不宣称优势成立。Stable、Validity 等比例型护栏主要用于预注册判定和描述，不在缺少相应区间时扩展为显著性结论。

5.1.3 代理评价边界

本研究没有执行 DFT 计算，`DFT_VERIFIED = false`。CHGNet 在创新点 1 中承担属性评价，并被终点选择器与主要 Property MAE 重复使用；MatterSim 在创新点 1 中承担 E-hull 与 Stable 等代理质量评价，在创新点 2 中既产生在线力反馈，又承担主要力学指标评价，因此存在评价器自洽风险。CHGNet Formal256 没有参与 RC-NFGD 的力反馈，可用于检验方向是否跨神经势保持，但 CHGNet 仍是机器学习原子间势，并且不能排除训练数据关系或共享任务偏差。因而本章所称“物理一致性改善”均指代理局部结构指标改善，不等价于真实 DFT 力降低、材料稳定性证明或实验可合成性验证。

5.2 条件属性生成结果的综合分析

5.2.1 C1-128 主结果

表 5-2 汇总 C1-128 的四臂结果。Fixed-K2 的 Property MAE 为 0.026332，低于 C0 的 0.034796、Random-K2 的 0.028533 和 Linear-K2 的 0.027522，形成 **Fixed-K2 < Linear-K2 < Random-K2 < C0** 的均值次序。Fixed-K2 相对 C0 的绝对改善为 0.008464，相对改善 24.32%，20 000 次配对 bootstrap 的 95% 置信区间为 [0.005817, 0.011391]，全区间高于零。逐样本共有 53 个改善、75 个持平或回退、0 个最终损失。




图 5-1: C1-128 四种方法的 Property MAE

Fig. 5-1: Property MAE of Four Methods on C1-128

表 5-2: 创新点 1 C1-128 最终确认结果

Tab. 5-2: Final Confirmation Results for Innovation 1 on C1-128

方法	目标与能量				质量护栏			回退与成本	
Method	Target				Guardrails			Fallback + cost	
	Property				Unique	Validity			计算
方法	MAE ↓	E-hull ↓	Stable ↑	Novel ↑	↑	NUS ↑	↑	回退率	量/C0
C0	0.034796	0.104296	58.59%	71.09%	99.22%	32.81%	100%	100%	1.0×
Fixed-K2	0.026332	0.081135	70.31%	65.63%	100%	37.50%	100%	58.59%	2.2×
Linear-K2	0.027522	0.090528	67.97%	67.97%	100%	39.06%	100%	59.38%	2.2×
Random-K2	0.028533	0.089172	64.84%	71.88%	99.22%	39.06%	100%	66.41%	2.2×

图 5-1 直观呈现四种方法的总体误差，但均值排序本身不足以说明确认性成立。Fixed-K2 的关键证据是配对改善区间完全高于零，而且确认种子与历史选型数据零重叠。相比之下，Linear-K2 虽然也低于 C0，却没有在同预算下超过 Fixed-K2。Random-K2 的结果说明“任意展开两个分支并终点筛选”已经可能借助回退优于 C0，但冻结的候选组合仍取得最低 MAE；因此，结果同时支持终点保守选择的普遍价值与候选库设计的具体价值。

5.2.2 属性收益与质量护栏的关系

Fixed-K2 的 E-hull 从 0.104296 降至 0.081135 eV/atom, Stable 从 58.59% 提高到 70.31%, NUS 从 32.81% 提高到 37.50%, Validity 保持 100%。MaxF 从 0.385927 降至 0.358976 eV/Å, 松弛 RMSD 从 0.075983 降至 0.067294 Å。上述结果说明在冻结代理协议下, 属性改善没有通过牺牲这些已注册质量护栏获得。

但“所有质量指标均改善”并不成立。Fixed-K2 的 Novel 从 71.09% 降至 65.63%, 低于 C0; 其 NUS 上升是 Novel、Unique 与 Stable 联合后的结果, 不能用 NUS 的提高掩盖单独 Novel 指标的下降。表 5-2 保留这一差异, 是因为条件准确性、稳定性和生成分布覆盖之间并非天然同向。最终结论应是“冻结护栏通过且若干代理质量指标改善”, 而不是“生成质量全面提高”。

53/75/0 的配对结果也需要结合方法定义解释。Fixed-K2 保留精确 C0 后缀, 并且只有在候选终点属性更优且质量条件通过时才接受候选, 否则返回 C0。0 个最终损失主要验证了终点约束选择与参考回退按设计工作, 并不证明 GPulse 和 PPulse 两条候选分支从不产生坏样本。58.59% 的回退率意味着 128 个样本中有 75 个没有用候选替换参考输出; 方法收益集中在能够通过终点验证的剩余样本上。这种稀疏接受模式正是其稳定性来源, 也是 2.2 倍预算未对所有样本转化为输出变化的原因。

5.2.3 结果的科学含义

创新点 1 的确认结果支持一种保守的计算换可靠性策略: 在精确保留基准轨迹的前提下, 只对后缀展开少量候选, 并把不可逆的在线决策转化为可回退的终点决策。它没有证明某个动态 CFG 规则可以在单轨迹中持续做出正确动作, 也没有证明 Fixed-K2 在每一种属性任务或每一种 2.2 倍预算方法中最优。其最强可辩护表述是: 在当前 MatterGen 磁性密度条件任务、冻结候选集合和 CHGNet 代理评价下, 预算约束验证选择的 Fixed-K2 实例在全新 C1-128 上提高了条件属性准确性, 并通过预注册代理质量护栏; 此结论并不包含相对独立 Best-of-N 的优越性。

5.2.4 独立采样对照与预算扩展的新增边界

第 3 章表 3-6 报告新的 128 种子配对对照: 同 cohort 的 C0、Independent Best-of-2 与 Fixed-K2 的 Property MAE 为 0.037623、0.028097 和 0.029506。Best-of-2 使用 4000 次 MatterGen score 调用与 2 次终点评价, Fixed-K2 使用 4400 次与 3 次, 二者均采用同一冻结 SAFE-A 选择/回退规则。Best-of-2 减 Fixed-K2 的配对差均值为 -0.001410、95% 区间为 [-0.005039, 0.002167]; 数值方向对 Fixed-K2 不利, 而区间跨零。故不能写成 Fixed-K2 在同预算下优于独立采样, 也不能把历史 C1 与




图 5-2: 创新点 1 从在线自适应探索到最终确认的证据演进

Fig. 5-2: Evidence Evolution of Innovation 1 from Online Adaptive Exploration to Final Confirmation

本 cohort 的均值直接配对。

另一组新 128 种子用于 $K=0-4$ 预算诊断。score 预算从 1.0 倍增至 3.4 倍，选中代理 Property MAE 依次为 0.035141、0.031636、0.028454、0.028419 和 0.024669，见第 3 章表 3-7 与图 3-10。 $K=3$ 的边际变化很小， $K=4$ 数值最低； $K=2$ 是原有 C1 确认所采用的成本折中，不是新曲线证明的最优宽度。嵌套候选与同源 SAFE-A 验证规则会按定义保证选中代理误差不增，故这一曲线不能单独证明独立物理性质随预算改善，也不能掩盖 Novel 的下降或验证器偏差。

5.3 参考保持与候选分配的证据边界

5.3.1 从在线控制失败到分支上界

创新点 1 并非由单次正实验直接得到。早期 Adaptive CFG V1 在历史 Formal256 上呈现混合结果，后续新批次未稳定复现；加入时间归一化、中位数聚合、置信回退和限速的 Robust V2 在新 P0 上失败；风险校准 V4、安全选择 V5、阶段门控和字段解耦也没有通过各自冻结门槛。这些相互独立的负结果表明，局部残差、短视野标签或简化风险分数不足以稳定预测完整终点的属性—质量结果。

与此同时，反事实和分支兼容 Oracle 显示优化空间确实存在。Branch-Compatible Oracle 在历史独立测试划分 12 个样本上将 Property MAE 从 0.028799 降至 0.020041，相对改善 30.41%；Oracle-K2 在该小样本上恢复了 Oracle-All 的全部观察到的优化空间。由于 Oracle 使用事后终点信息，这一结果只能证明“有限候选中存在更好选择”，不能作为可部署性能。它的研究价值在于把失败原因从“没有可改善空间”定位为“在线识别不可靠”，从而合理引出参考轨迹保留与终点验证。

图 5-2 中的状态不是简单的迭代分数，也不意味着后出现的方法必然优于前一方法。它记录的是研究假设如何被证据逐步收缩：在线自适应的宽泛命题没有被支持；Oracle 支持“选择空间存在”；最终 C1 支持的是更窄的“固定候选、参考

保留、终点约束选择”命题。负结果因此不是被最终正结果覆盖，而是决定了最终创新主张的边界。

5.3.2 Phase B 学习型分配器

Phase B 使用 64 个全新样本，按 32/16/16 划分训练、验证和测试集合。Linear-K2 基于分支前 179 个原始特征学习每个样本的候选优先级。留出测试上，Linear-K2 的 Property MAE 为 0.023634，Fixed-K2 为 0.024597，点估计方向相当于 3.92% 的相对改善；然而 Linear-K2 相对 Fixed-K2 的绝对配对增益 95% 置信区间为 $[-0.002618, 0.005214]$ ，跨越零，未通过预注册分配器优势门槛。因此 Phase B 的冻结结论是 `ADAPTIVE_ALLOCATION_VALUE = NOT_SUPPORTED`。

由于当时缺失序列化模型，后续在注册任何确认种子之前，使用原训练 32 样本、原代码、179 个特征和已确定的 $C = 1.0$ 做了一次确定性重建。重建模型对历史 16 个测试样本的 Top-2 选择实现 16/16 完全一致，验证/测试指标最大绝对误差为 1.11×10^{-16} ，随后以 `RECONSTRUCTED_ARTIFACT` 和 SHA-256 哈希冻结。该过程只恢复历史对象，不改变 Phase B 的负结论，也不构成结果后的重新训练。

5.3.3 C1 中的直接检验

在全新 C1-128 上，Linear-K2 的 MAE 为 0.027522，高于 Fixed-K2 的 0.026332。若把 Linear 相对 Fixed 的有利差定义为 $E_{\text{Fixed}} - E_{\text{Linear}}$ ，平均值为 -0.001190，相对值为 -4.52%，20 000 次配对 bootstrap 区间为 $[-0.003148, 0.000740]$ ，W/T/L 为 31/62/35。方向没有优于 Fixed，区间又跨零；C1 的继续门槛因此失败，预留的 C2 按协议不运行，也没有进行补救调参。

Linear-K2 相对 C0 仍有改善，原因是它与 Fixed-K2 共用终点约束选择和精确回退框架。由此可以分离两类贡献：参考保留、有限分支和终点回退得到 C1 支持；当前特征、样本规模与线性模型实现的学习型样本分配没有得到额外支持。最终采用 Fixed-K2 不是因为“简单模型原则”先验压倒了学习方法，而是在匹配预算和独立样本上，复杂分配器没有提供可确认的增益。

5.4 RC-NFGD 的物理一致性改善

5.4.1 Formal256 主结果

Formal256 使用 256 个注册配对种子，C0 与 RC-NFGD 均完成 256/256。表 5-3 给出冻结主结果。MatterSim MaxF 从 0.226408 降至 0.158911 eV/Å，相对降低 29.81%，相对改善 95% 置信区间为 $[21.42\%, 40.88\%]$ ，W/T/L 为 254/0/2。Mean Force 从 0.098702 降至 0.069373 eV/Å，相对降低 29.72%，区间为 $[24.01\%, 36.96\%]$ 。松弛 RMSD 从 0.051137 降至 0.043893 Å，相对降低 14.17%，区间为 $[4.54\%, 25.95\%]$ 。

三项区间均位于有利方向。

表 5-3: RC-NFGD Formal256 正式结果
Tab. 5-3: RC-NFGD Formal256 Results

指标	队列均值		效应与区间		配对方向	解释
Metric	Means		Effect + CI		Paired	Interpretation
有利相对变						
指标	C0	RC-NFGD	化	95% CI	W/T/L解释	
Matter Sim MaxF (eV/Å) ↓	0.226408	0.158911	29.81%	[21.42%, 40.88%]	254/0/2预注册主 终点，支 持	
Matter Sim Mean Force (eV/Å) ↓	0.098702	0.069373	29.72%	[24.01%, 36.96%]	255/0/1支持	
松弛 RMSD (Å) ↓	0.051137	0.043893	14.17%	[4.54%, 25.95%]	216/21/19支持	
Property MAE ↓	0.009757	0.009868	-1.14%	[-2.46%, -0.22%]	95/0/161轻微但方 向明确的 恶化	
Stable ↑	80.86%	80.86%	0	[0, 0]	0/256/0保持	
Validity ↑	100%	100%	0	[0, 0]	0/256/0保持	

MaxF 与 Mean Force 的胜负高度偏向 RC-NFGD，说明均值改善不是由极少数样本独立驱动。RMSD 的损失数更多、效应更小，符合“生成期力反馈主要改善代理局部受力，但对松弛位移的映射并非一一对应”的预期。MatterSim MaxF 的 P90 从 0.390303 降至 0.329501 eV/Å，P95 从 0.744050 降至 0.677620 eV/Å，最大值从 5.375634 降至 3.429568 eV/Å；这些尾部描述支持同一方向，但不是替代预注册均值主检验的额外主终点。




图 5-3: Formal256 配对改善分布

Fig. 5-3: Paired Improvement Distribution on Formal256




图 5-4: P0、Formal32 与 Formal256 的 MaxF 效应一致性

Fig. 5-4: Consistency of MaxF Effects across P0, Formal32, and Formal256

5.4.2 跨 cohort 可复现性

在方法冻结的三阶段证据链中，P0、Formal32 和 Formal256 的 MatterSim MaxF 相对降低分别为 16.66%、26.57% 和 29.81%，相应区间分别为 [10.17%, 31.24%]、[14.27%, 52.86%] 和 [21.42%, 40.88%]。三个 cohort 的样本规模、种子和绝对难度不同，不能把效应量递增解释为随样本规模增长的性能曲线；可以确认的是，三个相互分离的样本集合均保持正向区间，且方法在阶段间没有根据结果改动。

这种分阶段复现比单次 Formal256 均值更能回答稳定性问题。P0 负责排除明显不可行方案，Formal32 检查初始信号是否能在新种子上重现，Formal256 则缩小不确定性并承担正式结论。不同 cohort 均给出有利方向，使 RC-NFGD 的证据强度高于仅在单个探索批次上观察到的效果；但它仍只覆盖当前 checkpoint、目标磁性密度、采样配置和代理模型。

5.4.3 条件属性与结构指标的权衡

RC-NFGD 没有实现所有指标同时改善。Property MAE 从 0.009757 增至 0.009868，按有利方向计算为-1.14%，区间 [-2.46%, -0.22%] 完全位于不利方向，W/T/L 为 95/0/161。Stable 保持 80.86%，Validity 保持 100%，因而方法通过了预注册护栏，但这不能抵消属性误差的轻微恶化。更准确的判断是：RC-NFGD 在冻结容忍范围内，以小幅条件属性代价换取较大的代理力和松弛指标改善。

这一权衡也解释了为什么创新点 1 和创新点 2 应分别评价。Fixed-K2 的主目标是属性准确性，并通过终点回退控制质量风险；RC-NFGD 的主目标是局部受力，允许在护栏范围内出现小幅属性变化。若把所有指标压缩为未经注册的单一综合分数，既会掩盖两种方法的任务差异，也可能在看到结果后人为改变结论。

5.5 MatterSim 与 CHGNet 跨代理对比

MatterSim 同时参与 RC-NFGD 引导与主要评价，因而仅凭 MatterSim 结果无法排除方法适配其自身能量面的可能。为此，对 Formal256 的同一 256 对最终结构使用 CHGNet 0.3.0 重新计算力。表 5-4 显示，CHGNet MaxF 从 0.193891 降至 0.166057 eV/Å，相对改善 14.36%，绝对改善区间为 [0.007052, 0.064868]；Mean Force 从 0.087976 降至 0.079541 eV/Å，相对改善 9.59%，绝对区间为 [0.002384, 0.019148]。两个绝对区间均高于零，均值方向与 MatterSim 一致。




图 5-5: MatterSim 与 CHGNet 的逐样本改善比较

Fig. 5-5: Per-Sample Improvement Comparison between MatterSim and CHGNet

表 5-4: Formal256 的 MatterSim 与 CHGNet 跨代理结果

Tab. 5-4: Cross-Proxy Results of MatterSim and CHGNet on Formal256

评价对象		队列均值		效应与区间		证据
Evaluator + metric		Means		Effect + CI		Evidence
评价器	指标	C0	RC-NFGD	相对改善	绝对改善 95% CI	证据定 W/T/L位
Matter Sim	MaxF	0.226408	0.158911	29.81%	— (相对 CI 见表 5-3)	254/0/2同源主 评价
Matter Sim	Mean Force	0.098702	0.069373	29.72%	— (相对 CI 见表 5-3)	255/0/1同源次 要评价
CHGNet	MaxF	0.193891	0.166057	14.36%	[0.007052, 0.064868]	172/0/84跨势均 值支持
CHGNet	Mean Force	0.087976	0.079541	9.59%	[0.002384, 0.019148]	169/0/87跨势均 值支持

注：MatterSim 行报告冻结的相对置信区间（见表 5-3），CHGNet 发布表报告绝对改善置信区间，两类区间不直接比较数值大小。

跨势结果并非完全一致。CHGNet 的效应幅度小于 MatterSim，且损失样本明显增多。CHGNet MaxF 的 P90 从 0.405853 升至 0.425399 eV/Å，P95 从 0.661234 升至 0.696249 eV/Å；Mean Force 中位数从 0.046336 升至 0.048166 eV/Å，而其

P90/P95 又略有下降。这种混合尾部意味着“均值方向跨势保持”得到支持，但“每个样本、每个分位数或全部尾部风险均改善”不成立。

CHGNet 的独立性也必须准确限定。它没有向 RC-NFGD 提供在线力，因此相对于生成期引导信号是独立代理评估器；但它仍参与项目中的磁性属性和质量评价，而且 MatterSim 与 CHGNet 都是 MLIP，不能等同于不同实验室的盲测，更不能替代 DFT。两者方向一致降低了单一评价器自洽的解释风险，却没有消除代理误差。

5.6 消融结果与机制分析

表 5-5 把两项创新的关键机制实验统一到“支持什么、不能支持什么”的口径。消融的作用不是为最终方法的每个组件寻找正结果，而是分离必要信息、保守工程设计和未获支持的复杂化。

表 5-5: 关键消融、机制证据与解释边界
Tab. 5-5: Key Ablations, Mechanistic Evidence, and Interpretation Boundaries

对象	实验与规模	关键结果	状态	支持的解释	不支持的解释
创新点 1	Branch Oracle, 测试 $n = 12$	MAE 0.028799 → 0.020041, 改善 30.41%	SUPPORTED — MECHANISM	有限合法分支中存在终点优化空间	Oracle 部署或可泛化
创新点 1	Phase B Linear-K2, 测试 $n = 16$	相对 Fixed 点估计 +3.92% CI 跨零	NOT_SUPPORTED	可作为方向性探索	学习分配器已优于 Fixed
创新点 1	C1 Linear-K2, $n = 128$	0.027522 vs Fixed 0.026332; CI 跨零	NOT_SUPPORTED	回退框架仍可优于 C0	当前学习分配具有额外价值
创新点 2	阶段可靠性, $t = 0.02$ $n = 32$	Spearman=0.925587	SUPPORTED	预测干净结构的后期排序可用于冻结介入窗口	相关性证明因果最优阶段
创新点 2	Force direction, $n = 32$	G1 MaxF 0.098500 vs G0 0.141690; 改善 30.48%, CI[24.66%, 38.87%]	SUPPORTED	真实力方向携带有效局部信息	力方向是理论唯一最优更新
创新点 2	Bounded, $n = 32$	T1 0.231502, unbounded T2 0.060834	NOT_SUPPORTED	bound 可作保守幅度控制	bound 是性能收益的必要核心
创新点 2	等 20 次 MatterSim 调用, $n = 32$	online 0.163650, POST 0.043275	在线优越性 NOT_SUPPORTED	在线反馈可行且改善 C0	在线方式对终态松弛的支配性

对象	实验与规模	关键结果	状态	支持的解释	不支持的解释
两创新	A5 兼容性, $n = 64$	组合仅保留 55.49% 的单 独力改善, 低 于 70% 门槛	FAIL	两种贡献应 独立报告	已验证协同 或联合最优

5.6.1 真实力方向的作用

方向消融把无引导 G0、真实力方向 G1、同尺度随机方向 G2、原子间打乱方向 G3 和反向方向 G4 放在同一 32 种子协议中。MatterSim Mean MaxF 分别为 0.141690、0.098500、0.153744、0.151428 和 0.188137 eV/Å。G1 相对 G0 改善 30.48%，区间完全为正；CHGNet 也得到 8.00% 的方向性改善及 [1.64%, 13.60%] 的相对区间。这比“加入任意小扰动即可改善”的解释更符合数据。

但 G2/G3/G4 重放的是配对 G1 轨迹上的位移尺度，而不是在各自新轨迹上闭环重新计算力；特别是 G4 不是沿自身势能面执行反梯度下降。扩散采样具有路径依赖，因此该消融支持真实力方向包含有用信息，却不足以证明其理论最优性或完全分离闭环状态变化。

5.6.2 有界位置修正的保守角色

去除归一化饱和和 0.01 Å 硬上限的 T2 在 MatterSim 上比冻结 T1 更强，并在该 32 样本 cohort 上通过所测护栏；CHGNet 上 T2 并未稳定优于 T1。由此不能把“有界”描述成已经验证的性能来源。最终保留 bound 的原因是它让单事件位移可解释、限制异常力的直接影响，并便于审计和跨样本控制。它属于风险偏好明确的工程约束，而不是经消融证明的最优 trust-region 算法。

5.6.3 在线引导与生成后修正

等预算实验对 RC-NFGD 提供了重要反例。在同为 20 次 MatterSim 调用时，POST 从生成终态开始连续修正，其 Mean MaxF 为 0.043275，低于在线 F0 的 0.163650；全部 32 个配对样本上，F0 相对 POST 均更差。该结果不推翻 Formal256 中“在线反馈能改善 C0”的主结论，但否定了“在线方式是获得最低代理力的最佳方式”。在线修正在后续 predictor/corrector 中可能被部分冲淡，而终态 POST 可以把全部预算直接用于当前结构的局部下降。

两者对应不同研究问题。RC-NFGD 证明神经势反馈可以可靠接入生成轨迹，POST 则是部署时若只追求同一势下低力必须保留的强基线。本研究没有验证

“RC-NFGD 后再 POST”的两阶段组合，因此不能预先宣称互补收益。

5.6.4 属性—受力权衡与注入阶段的补充证据

第 4 章的历史 A6 Pareto 分析使用同一组 32 对 C0、RC-NFGD 和 POST 结构。三者的 (Property MAE, MatterSim MaxF) 方法均值分别为 (0.007900, 0.214179)、(0.007886, 0.163650) 和 (0.007933, 0.043275)。RC-NFGD 与 POST 在方法均值上形成描述性非支配点，但二者属性差异的配对 95% 区间跨零；不能把该前沿理解为统计支配。POST 的代理 MaxF 明显更低，强化了“在线引导研究生成轨迹、POST 优先解决终态同势低力”的任务区别。Formal256 的属性误差方向对 RC-NFGD 不利，不能用 A6 的微小点估计差异覆盖这一主结果。

另一个独立的新 32 对种子 Timing Ablation 只改变力反馈开始时间，但同时改变累计力调用。Early、Middle、原始 Late 的 MaxF 均值为 0.16860、0.14072、0.13864 eV/Å，C0 为 0.18986 eV/Å；对应平均力调用约为 931.5、500.0、20.0 和 0 次/样本。Late 相对配对 C0 的 MaxF 差为 -0.05123 eV/Å，95% 区间 $[-0.06834, -0.03770]$ ；Late 与 Early、Middle 的直接配对区间均跨零，因而没有证据确认唯一最优开始阶段。Late 的属性 MAE 还轻微增加，Early 的 NUS 点估计下降且 wall time 较长。此消融支持把注入时机、属性保持和额外物理计算预算作为共同的设计约束，而不支持以最低单一均值事后重选原方法。

5.6.5 复杂模型不必然优于冻结简单策略

创新点 1 的 Linear-K2 与创新点 2 的 unbounded/POST 消融共同说明，复杂度与最终科学价值并非单调关系。Linear-K2 增加特征工程和训练过程，却没有在新 C1 上超过固定策略；相反，POST 算法上更简单，却在同势同调用次数下取得更低 MaxF。最终方法选择应由预注册问题决定：创新点 1 的 C1 支持 Fixed-K2 对 C0 的代理属性改善，但新增 Best-of-2 说明独立采样至少具有竞争力，因此不能将 Fixed-K2 称为采样效率最优；创新点 2 研究生成期物理反馈，因此保留 RC-NFGD，同时承认 POST 在纯终态力目标上更强。

5.7 计算代价与工程可行性

表 5-6 汇总部署与数据构建成本。C0 每个样本需要 2 000 次 MatterGen score 调用。Fixed-K2 在前 400 步共享参考状态和随机数状态，之后分别继续 C0、GPulse 与 PPulse 三个后缀，总计 4 400 次 score 调用，并需 3 次终点评价，部署计算量约为 C0 的 2.2 倍。Linear-K2 使用相同 2.2 倍预算，因此它与 Fixed-K2 的比较不存在主网络计算量差异。Phase B 完整候选采集约 3.4 倍 C0，但这是构建训练数据的离线成本，不是最终 Fixed-K2 的部署成本。新增 Independent Best-of-2

用 4000 次 score 调用与 2 次终点评价 (2.0 倍 C0), Fixed-K2 比它多 10% 的 score 调用且多 1 个终点。K=4 预算实验使用 6800 次与 5 个终点 (3.4 倍 C0), 属于另一 cohort 的诊断, 不能与 Phase B 离线采集混为一谈。

RC-NFGD 与 C0 均使用 2 000 次 MatterGen score 调用, 差别是后期增加 20 次 MatterSim 力调用。Formal256 记录的平均端到端时间分别为 92.663 s 和 92.849 s, 比值 0.9980; 该微小反向差异属于硬件与运行波动, 不能宣称 RC-NFGD 加速。更稳妥的结论是, 在当前硬件、batch-size-1 和实现条件下, 额外 20 次神经势调用未形成可辨识的平均总时延增长。跨 GPU、批量大小或更大结构时仍需重新测量。

表 5-6: 计算代价与部署条件
Tab. 5-6: Computational Cost and Deployment Conditions

方法/阶段	角色	MatterGen		神经势调相对 C0 计算量或时间比	回退率工程解释
		score 调用/样本	用/样本		
创新点 1 C0	基准部署	2 000	1 次终点评价	1.0×	100%精确参考
Fixed-K2	最终部署	4 400	3 次终点评价	2.2×	58.59%以额外后缀计算换取终点选择
Best-of-2	新强基线	4 000	2 次终点评价	2.0×	—独立完整采样; 与 Fixed 非等预算
K=4	新预算诊断	6 800	5 次终点评价	3.4×	—独立 cohort; 不是 C1 方法
Linear-K2	负确认	4 400	3 次终点评价	2.2×	59.38%与 Fixed 匹配预算, 未确认额外收益




图 5-6: C0、Fixed-K2 与 Phase B 数据构建的计算量比较

Fig. 5-6: Computational Cost Comparison of C0, Fixed-K2, and Phase B Data Construction

MatterGen					
方法/阶段	角色	score 调用/样本	神经势调用/样本	相对 C0 计算量或时间比	回退率工程解释
Phase B	离线数据全候选采集	—	—	约 3.4×	—不应写作部署开销
创新点 2 C0	Formal256 基准	2 000	0 次在线 MatterSim	1.0×	0 与 RC-NFGD 匹配主网络调用
RC-NFGD	最终部署	2 000	20 次在线 MatterSim	时间比 0.9980	0 主网络调用不增加；无加速主张

从部署选择看，两项创新具有不同成本结构。Fixed-K2 需要保存中间采样器与 RNG 状态、克隆后缀并缓存多个候选，适合可以接受约 2.2 倍生成预算、且终点评价器可用的离线筛选任务。RC-NFGD 不增加 MatterGen score 次数，但引入 MatterSim 依赖、周期坐标转换和 20 次在线调用，更适合对生成轨迹中的局部几何一致性有明确需求的场景。二者都不是训练阶段的参数微调，也不需要修改基础 MatterGen 权重。

5.8 两项创新的关系与联合实验结论

两项创新共享三个研究原则：使用冻结的 MatterGen 基础模型；用配对种子隔离随机性；在方法失败时保留精确基准或原 score 回退。但它们作用于不同层

面。Fixed-K2 是轨迹级候选管理方法，主要通过多后缀生成和终点选择改善条件属性；RC-NFGD 是步级坐标反馈方法，在可靠后期窗口内改变 position predictor，主要改善代理受力。前者把风险延迟到终点决策，后者在采样过程中主动介入。

兼容性 A5 在 64 个配对种子上比较 C0、Adaptive CFG A0、单独力引导 B0 与组合 AB。Mean MaxF 分别为 0.218922、0.239629、0.171833 和 0.192794 eV/Å。组合方法保留约 97.45% 的 Adaptive CFG 属性改善，但只保留约 55.49% 的单独力引导改善，低于预注册 70% 双保持门槛，最终状态为 FAIL。该实验测试的是历史 Adaptive CFG 与力引导的组合，而不是最终 Fixed-K2 的完整笛卡尔积组合；它足以否定“现有证据已证明两项创新协同”，却不足以断言任何未来组合都不可能有效。

因此，论文应把二者组织为同一材料逆向生成问题下的两类互补研究视角，而不是一个已经验证的联合算法。创新点 1 回答“如何在有限候选预算内保留可回退的条件控制参考”；创新点 2 回答“何时以及如何把神经势局部反馈接入生成轨迹”。共同使用时可能产生预算、选择器自治和属性—力权衡的新问题，必须经过单独预注册与全新种子确认。本论文不把这种尚未完成的工作计入创新贡献。

5.9 适用范围、威胁与局限性

5.9.1 内部有效性

配对种子、方法冻结、阶段门控和完整样本保留增强了内部有效性。创新点 1 通过重建审计恢复并哈希固定 Linear-K2，且重建发生在 C1 种子注册前；创新点 2 通过实现锁、独立 cohort 和逐级 GO 规则防止在看到 Formal256 后修改方法。20 000 次配对 bootstrap 与 W/T/L 同时报告，避免只依赖单一均值。新 Best-of-2 和 Budget Scaling 的两组 cohort 均不并入历史 C1 确认，其结果只用于强基线与预算边界分析。

内部有效性仍受代理选择影响。Fixed-K2 只有在 CHGNet 终点评价下才执行接受或回退，且 CHGNet 又定义主要 Property MAE，因而 0 损失与该评价规则存在算法性联系；这也带来选择器复用和 verifier hacking 风险；RC-NFGD 由 MatterSim 产生力又用 MatterSim 评价，主效应可能包含同源优势。CHGNet 跨势评价降低但未消除这一风险。部分消融样本量为 32，适合机制定位，不应拥有与 Formal256 等同的外推权重。

5.9.2 外部有效性与应用边界

实验集中在当前 MatterGen checkpoint 与既定采样设置，但两项创新的目标条件不同：创新点 1 的 C1、Best-of-2 和预算扩展使用磁性密度目标 0.1，创新点 2 的 RC-NFGD 使用目标 0.2。两个任务的绝对 MAE 不能直接比较或汇总为联合

效应。Fixed-K2 的分支点、GPulse/PPulse 候选和终点阈值不保证迁移到其他属性；RC-NFGD 的 $t = 0.02$ 可靠阶段、参考力、 $0.005 \text{ \AA}$ 名义位移、 $0.01 \text{ \AA}$ 硬上限和 $0.5 \text{ \AA}$ 最小距离也不保证适用于其他元素分布、晶体规模、扩散模型或神经势。跨任务使用时，至少需要重新做阶段诊断、候选校准和全新确认，而不能直接复用当前效应量。

本研究没有 DFT、声子、长时间分子动力学或湿实验验证。E-hull、Stable、MaxF 和 RMSD 均是代理量，不能充分覆盖动力学稳定性、合成可行性、缺陷效应和温压条件。Novel 与 Unique 依赖所用参考库和结构匹配规则，也不能直接等价于具有实验价值的新材料。

5.9.3 结论强度与未解决问题

表 5-7 给出论文最终 Claim–Evidence 映射。该表区分“得到确认的效果”“有助于解释的机制”和“被实验否定或尚未验证的更强命题”，用于约束摘要、结论和答辩表述。

表 5-7: 最终 Claim–Evidence 对照
Tab. 5-7: Final Claim–Evidence Mapping

Claim	主要证据	证据类型	状态	允许的结论	主要限制
合法分支预算内存在属性改善空间	Branch Oracle 测试 $n = 12$, 上界 30.41% headroom	探索性机制	SUPPORTED _MECHANISM	多分支设计 有机制依据	Oracle 使用 事后信息且 样本小
Fixed-K2 优于 C0	C1-128, MAE 改善 24.32%, CI[0.005817, 0.011391]	确认	SUPPORTED	冻结任务与 代理协议下 属性控制改 善	2.2× 预算; 不保证跨任 务
Fixed-K2 通过质量护栏	E-hull、Stable、NUS 改善, Validity 不变	确认护栏	SUPPORTED	已注册代理 护栏未被破 坏	Novel 单项下 降; 无 DFT
Fixed-K2 与 Independent Best-of-2 对照	新 128 对; 2.2×/3 终点 2.0×/2 终 点; 直接 CI 跨零	竞争基线	NOT_SUP PORTED	独立采样具 有竞争力	非严格等预 算; 同代理选 择与报告

Claim	主要证据	证据类型	状态	允许的结论	主要限制
K=2 为最优搜索宽度	独立 K0-4; K4 代理 MAE 最低	预算诊断	NOT_SUP PORTED	K2 是历史实例的成本折中	嵌套选择; 边际分析探索性
Linear-K2 优于 Fixed-K2	Phase B CI 跨零; C1 均值更差且 CI 跨零	负确认	NOT_SUP PORTED	当前学习分配无确认增益	不否定未来更强数据/模型
在线 Adaptive CFG 稳定有效	V1 混合, V2/V4/V5/Field 失败, Stage 混合	多轮探索	NOT_SUP PORTED	其失败推动参考保留框架	不能写作最终已验证方法
RC-NFGD 降低 MatterSim 力与 RMSD	Formal256 指标区间均为正	三 正式确认	SUPPORTED	代理局部结构一致性改善	MatterSim 同源评价风险
RC-NFGD 跨势方向保持	CHGNet MaxF 与 Mean Force 绝对 CI 均高于零	独立代理评估	SUPPORTED	均值力指标跨 MLIP 同向	效应较小、尾部混合、非 DFT
RC-NFGD 改善目标属性	Property MAE 恶化 1.14%, 不利区间不跨零	正式护栏	NOT_SUP PORTED	可报告小幅属性代价	不能用 Stable/Validity 掩盖
bound 是性能核心	unbounded T2 的 Matter Sim 均值更低	消融	NOT_SUP PORTED	bound 是保守控制	非最优性证明; 组件未单独拆分
RC-NFGD 与 POST 等预算对照	Mean POSTMaxF 0.043275, online 0.163650	等预算消融	NOT_SUP PORTED	在线反馈可行但不是最低力方案	仅当前势、预算与小样本

Claim	主要证据	证据类型	状态	允许的结论	主要限制
A6 Pareto	同组 32 对; POST MaxF 更低	描述性	MIXED	属性与代理力折中	属性 CI 跨零; 仅点估计前沿
Timing, 32 对	Late-C0 MaxF 差 -0.05123	机制消融	MIXED	Late 对 C0 降代理力	跨时机 CI 跨零; 力调用不等
两项创新的联合协同检验	A5 力收益保留 55.49% < 70% 门槛	兼容性	FAIL	两项创新独立报告	未直接验证 Fixed-K2×RC-NFGD
DFT/实验物理论验证状态	发布包无 DFT 或实验	证据缺失	FALSE	只作 surrogate-only 表述	DFT_VERIFIED=false

从表 5-7 可以看出，本论文的贡献并非“所有尝试均成功”。创新点 1 的价值来自对在线 Adaptive CFG 不稳定性的系统定位，以及最终把宽泛自适应命题收缩为可确认的预算约束验证选择框架及其实例；创新点 2 的价值来自对生成期神经力反馈的可复现验证，同时通过方向、边界、POST 和跨势实验排除过强解释。保留负结果使最终主张更窄，但也使其可审计、可复现并更适合作为硕士论文的工程与科学贡献。

5.9.4 对研究问题的逐项回答

综合全部冻结证据，可以对本论文实验部分的研究问题作出四项明确回答。第一，固定强度的条件引导并非对全部样本都达到可观察的最优点；反事实与分支兼容 Oracle 均显示剩余空间，但仅凭中间残差提前判断该空间并不可靠。第二，在当前样本规模和特征表示下，相对 C0 的确认性收益来自“保留精确参考、展开少量候选、终点验证并回退”，而不是学习器对候选身份的逐样本预测。Fixed-K2 的确认性正结果与 Linear-K2 的负确认共同支撑这一回答；新增独立 Best-of-2 进一步限定其相对竞争优势并未得到证明。

第三，神经势可以作为生成期局部反馈接入 MatterGen，但应在预测干净结构与终点受力具有较强排序一致性的后期窗口使用。三组独立 cohort 的同向效应、真实方向消融和 CHGNet 跨势均值结果共同表明，RC-NFGD 的收益不宜仅解释为单批随机波动或任意坐标噪声；同源评价和控制分支的路径依赖仍使“真实物理最优”超出证据范围。第四，条件属性准确性与低代理受力不是天然一致

的目标。创新点 1 在额外分支预算下优化前者，创新点 2 在基本不增加主网络调用的条件下改善后者，却产生小幅属性代价；兼容性失败进一步说明，分别有效的模块不能未经确认直接组合为更强系统。

由此，本研究给出的不是一个覆盖全部目标的单一最优采样器，而是一套有明确适用条件的决策依据：若任务优先级是当前冻结协议下的条件属性准确性且允许增加生成预算，Fixed-K2 是已确认的可回退选项，但独立 Best-of-2 在新增对照中具有竞争力，应同时比较；若重点是研究生成轨迹内的代理力反馈，可采用 RC-NFGD；若唯一目标是同一 MatterSim 势下的最低终态受力，当前等预算证据反而要求把 POST 作为更强基线。对于同时要求属性、局部力学和计算预算的应用，应先定义可接受的权衡与门槛，再开展新的联合确认，不能从本章单项结果直接推导部署最优解。

基于上述统一证据和边界，第 6 章将进一步总结全文研究成果，归纳两个研究问题的回答，并集中讨论代理评价、计算预算、跨任务迁移、联合协同和 DFT 验证等尚未解决的问题。

5.10 本章小结

本章在统一评价口径下综合分析了两项创新。创新点 1 中，Fixed-K2 在全新 C1-128 上把 Property MAE 从 0.034796 降至 0.026332，相对改善 24.32%，配对改善区间完全高于零，并通过冻结的 E-hull、Stable、NUS 和 Validity 护栏；其代价是约 2.2 倍 MatterGen score 调用，且 Novel 单项下降。参考回退带来的 53/75/0 结果证明的是终点保守选择有效，而不是候选分支从不失败。学习型 Linear-K2 在 Phase B 和 C1 中都没有确认优于 Fixed-K2，因此最终贡献是预算约束验证选择框架及其固定双分支实例，不是学习型候选分配或优于 Best-of-N 的采样效率。新增 Best-of-2 的均值对 Fixed-K2 不利且直接配对区间跨零；K=0-4 曲线表明 K2 非最低误差点。两组新实验均与 C1 独立，不改变历史 C1 确认。

创新点 2 中，RC-NFGD 在 Formal256 上将 MatterSim MaxF、Mean Force 和 RMSD 分别降低 29.81%、29.72% 和 14.17%，并在 P0、Formal32 和 Formal256 三个独立 cohort 上保持正向效应。CHGNet 对同一 256 对结构给出 MaxF 14.36% 和 Mean Force 9.59% 的均值改善，为跨神经势方向一致性提供支持。然而，Property MAE 恶化 1.14%，CHGNet 部分尾部指标变差，unbounded 消融不支持 bound 是性能核心，等预算 POST 的代理力更低。因此 RC-NFGD 应被表述为得到确认的在线代理力反馈方法，而非真实物理验证或所有替代方法中的最优方案。

两项创新可以共同支撑“条件准确性与局部结构一致性需要分别建模和验证”的论文主线，但当前联合兼容实验失败，不能宣称协同。最终冻结状态为：INNOVATION1_FIXED_K2 = SUPPORTED, LINEAR_K2 = NOT_SUPPORTED, INNOVATION2_RC_NFGD = SUPPORTED, JOINT_SYNERGY = NOT_SUPPORTED

PORTED, DFT_VERIFIED = false。本章没有新增外部文献事实，方法背景和代理模型文献沿用第 3 章、第 4 章，故 CITATION_NEEDED_COUNT = 0。

6 总结与展望

6.1 全文工作总结

本文围绕无机晶体逆向生成中的两个推理阶段问题展开研究。第一个问题是：冻结 MatterGen 后，如何核算并利用有限额外推理预算，同时通过验证选择与参考回退控制代理属性和质量风险。第二个问题是：如何在晶体扩散生成过程中引入局部物理反馈，改善生成结构在原子力层面的代理物理一致性。两个问题分别对应条件属性控制和局部结构物理一致性，不能由单一指标或单一推理机制代替。

因此，全文的统一主题是“冻结材料生成模型的可信推理增强”。本文所称可信是有限预算、反馈路径、异常回退和证据边界的可审计性；它不等于 DFT 真实性保证，也不表示两类方法已经联合取得增益。

全文以冻结的 MatterGen 作为共同基础，不重新训练主干权重，也不改变原有三字段生成定义。研究路线先从 C0 基线出发，分别分析条件得分残差和预测干净结构的阶段可靠性；随后形成两条相互独立的推理增强路线；最后使用匹配种子、冻结代理指标、配对统计和跨代理评价进行统一分析。整体技术路线可概括为：冻结 MatterGen → 预算约束候选验证选择与后期物理反馈两类独立推理增强 → 各自配对确认、竞争基线和证据边界审计。两条路线共享实验设计原则，但不是串联模块，也没有被验证为一个联合最优模型。

第一条路线的研究过程并非直接假定多分支有效。研究先考察固定 CFG 和多字段残差驱动的在线 Adaptive CFG，再用反事实 Oracle 判断是否存在可利用的引导空间，并通过风险、字段和时间阶段实验定位在线选择的不稳定来源。由于当前中间状态特征不能可靠判断何时应当偏离 C0，研究问题被重新表述为：保存一条可精确恢复的参考轨迹，在有限预算内展开少量候选，并使用终点属性和质量约束作出选择。由此形成预算约束验证选择推理框架，并以共享前缀、固定双候选的 Fixed-K2 作为已确认实例，而非普适最优搜索器。

第二条路线针对属性条件满足但结构仍可能具有较高代理受力的问题。研究先在独立诊断样本上比较预测干净结构与终态 MaxF 的阶段排序一致性，再选择后期窗口调用 MatterSim，将笛卡尔力映射到周期分数坐标，并通过 position predictor 的实际 score 系数注入有界位置修正。该方法不改动原子类型和晶胞的 MatterGen 更新，也不把神经势当作替代生成器；异常时保留原始 score 并执行安全回退。最终形成基于阶段可靠性校准的后期神经力场引导扩散方法 RC-NFGD。

因此，本文的主要贡献不是把所有探索路径都归纳为正结果，而是把两个不同层面的推理控制问题转化为可复现、可比较和可审计的算法接口。第 3 章回答条件属性控制问题，第 4 章回答局部代理受力反馈问题，第 5 章进一步区分确认

结果、机制结果、负结果和证据边界。

6.2 主要研究成果

6.2.1 条件属性生成方面的研究成果

本文提出面向冻结扩散生成模型的预算约束验证选择推理框架 (Budget-Constrained Verifier-Guided Inference Framework)。方法在共享前缀后保存精确 C0 参考状态和随机数状态，固定展开两个候选后缀，并在终点依据属性改善和冻结质量条件决定接受或参考回退。其核心是将难以提前预测的偏离动作转化为有限候选的终点验证，同时明确控制候选数量、额外 score 调用与代理评价次数。Fixed-K2 是固定预算实例，不是对全部采样方法的支配性改进。

在 C1-128 完全独立配对种子上，Fixed-K2 将 Property MAE 从 0.034796 降至 0.026332，相对降低 24.32%，并保持冻结的 E-hull、Stable、NUS 和 Validity 代理护栏。该结果支持以下范围内的结论：在当前 MatterGen checkpoint、目标属性、候选库和终点评价协议下，参考轨迹保留、固定双候选和安全回退可以改善代理属性误差。该实例约使用 C0 的 2.2 倍 MatterGen score 调用，因而属于 inference-time compute-quality trade-off，而不是推理加速。20 000 次配对 bootstrap 的 C0 减 Fixed-K2 绝对改善 95% 区间为 [0.005817, 0.011391]。

学习型 Linear-K2 的结果必须与上述正结果同时报告。Phase B 留出测试只有区间跨零的方向性结果，C1-128 中 Linear-K2 的 Property MAE 为 0.027522，高于 Fixed-K2 的 0.026332，未达到预注册的候选分配优势门槛。因此，当前证据支持固定候选组合和终点回退，不支持“基于当前分支前特征的学习型样本级候选分配优于 Fixed-K2”。这一负结果限定了方法结论，也说明更复杂的在线控制并不会因为增加模型形式而自动获得稳定收益。

综合创新点 1 的证据，可以得到四点认识：MatterGen 条件生成中存在可利用的 guidance headroom；仅凭当前中间残差和短视野信号难以稳定识别有利偏离；参考保留、多分支验证和终点回退能按预定义代理规则限制输出风险；在当前数据和候选库下，Linear-K2 没有确认优于 Fixed-K2。新增独立 Best-of-2 在另一组 128 种子上达到 0.028097，数值低于 Fixed-K2 的 0.029506，直接配对差异区间跨零且预算不等，故不能宣称 Fixed-K2 优于独立采样。再一组独立 K=0-4 实验显示最低代理 MAE 位于 K=4 (0.024669) 而非 K=2，K=2 仅是既有成本折中。上述结论不应写作在线 Adaptive CFG 已得到稳定正向验证，也不外推到其他属性、材料体系或生成模型。

6.2.2 局部结构物理一致性方面的研究成果

本文提出基于阶段可靠性校准的后期神经力场引导扩散方法 (Reliability-Calibrated Late-stage Neural Force-Guided Diffusion, RC-NFGD)。方法先用预测干净结构的 MaxF 与最终 MaxF 排序相关性确定后期介入窗口, 再通过周期坐标映射和 score 系数补偿把 MatterSim 力反馈送入 position predictor, 并使用有界修正和异常回退控制数值幅度。阶段诊断在当前任务中选择 ($t=0.02$), 其 Spearman 相关系数为 0.925587; 这只是当前模型和任务的可靠性依据, 不是所有扩散阶段的普遍规律。

Formal256 的冻结结果显示, RC-NFGD 使 MatterSim MaxF、Mean Force 和 RMSD 分别降低 29.81%、29.72% 和 14.17%, 同时 Stable 保持 80.86%, Validity 保持 100%。P0、Formal32 和 Formal256 三个分离 cohort 的 MaxF 方向一致, 说明后期代理力反馈在当前实验设置下具有可复现性。CHGNet 未参与在线力引导, 在同一 256 对结构上观察到 MaxF 降低 14.36%、Mean Force 降低 9.59%, 为跨神经势的均值方向提供了额外支持。

该结果必须与不利指标一并解释。Formal256 Property MAE 从 0.009757 增至 0.009868, 约恶化 1.14%; CHGNet 的部分高分位尾部指标呈混合结果; 等预算生成后 POST 在所测 MatterSim 终态受力指标上更低。因此, RC-NFGD 的正式结论是: 在当前冻结任务和机器学习势代理协议下, 后期在线神经力反馈改善了若干代理局部结构一致性指标, 并得到 CHGNet 均值方向支持。它不是 DFT 物理验证, 也不是对生成后松弛的支配性结论。

补充的 A6 属性—代理力分析进一步表明, RC-NFGD 与 POST 在方法均值上只是描述性权衡, 属性差异区间跨零, 而 POST 的同势 MaxF 更低。独立的 32 对 Timing Ablation 中, 原始 Late 相对 C0 降低 MaxF, 但与 Early、Middle 的直接配对比较均不能排除零差异; Early/Middle/Late 的力调用预算不同, 且属性与 NUS 结果并非同向。因而第 4 章支持“后期方案在冻结设置下有效”, 不支持“后期时机普遍最优”或“单一方法同时改善全部目标”。

创新点 2 还保留了两个重要的机制边界。真实力方向相对于匹配尺度的随机、打乱和反向控制具有更好的受力结果, 说明方向信息具有实用价值, 但消融路径仍有重放限制; 去除有界修正后 MatterSim 指标更低, 故 bound 的定位是保守的步长和异常控制机制, 而不是已被证明的性能核心。由此, RC-NFGD 应被理解为一个可审计的后期采样反馈接口, 而不是完整的结构优化器。

6.2.3 两项成果的关系与总体回答

两项创新分别回答两个研究问题。问题 1 的回答是: 在允许约 2.2 倍 MatterGen score 预算时, 保存精确 C0、展开固定双候选并进行终点约束选择,

可在 C1-128 上改善代理属性误差；当前 Linear-K2 没有显示额外优势，独立 Best-of-2 具有竞争力，K=2 也并非最低误差宽度。问题 2 的回答是：在阶段可靠性诊断支持的后期窗口内，MatterSim 力反馈可以接入 MatterGen 逆扩散，并在 Formal256 上改善代理 MaxF、Mean Force 和 RMSD；这一改善伴随轻微属性代价，且仍局限于代理评价。

联合兼容性实验的状态为 `JOINT_SYNERGY = NOT_SUPPORTED`。因此，本文将两条路线作为相互独立的推理阶段增强方法，而不是写成“创新点 1 之后接创新点 2”的统一模型。当前研究更适合表达为：条件属性准确性和局部结构一致性是相关但不等价的目标，需要分别建模、分别设定预算和分别验证。

6.3 研究局限

第一，证据仍停留在机器学习势和属性代理层面。MatterSim 同时参与 RC-NFGD 的力反馈和主要力评价，存在同源代理自洽风险；CHGNet 提供了不参与在线力引导的交叉评价，但仍然是机器学习势，且其尾部指标并非全部同向改善。全文没有进行 DFT 单点力、DFT 能量、声子、长时间分子动力学或实验合成验证，`DFT_VERIFIED = false`。因此，代理受力下降不能被改写为真实热力学稳定性、动力学稳定性或可合成性已经得到证明。

第二，创新点 1 的计算代价和选择依赖需要明确。Fixed-K2 约使用 C0 的 2.2 倍 MatterGen score 调用，并依赖终点评价器、冻结候选库和接受规则。其零属性损失来自终点选择与参考回退设计，不表示每个候选分支都成功；新增独立 Best-of-2 的均值更低，但与 Fixed-K2 的直接配对区间跨零且预算不等；当前实验没有证明它优于通用 Best-of-N 策略。换言之，Fixed-K2 是有明确成本的质量—计算权衡，而不是无额外代价的普适改进。

第三，Linear-K2 的失败只约束当前的特征、训练规模、候选库和线性分配模型。179 个分支前特征及其线性交互没有支持稳定的跨 cohort 候选分配，但这不能推出任何学习型分配器都不可能有效。类似地，Fixed-K2 的候选身份、分支点和终点阈值来自当前 MatterGen 与当前目标属性，不能直接外推到其他 checkpoint、属性、组成范围或晶体生成模型。

第四，RC-NFGD 存在目标之间的权衡和竞争基线边界。Formal256 的 Property MAE 轻微恶化，说明低代理受力并不自动带来更好的条件属性；CHGNet 尾部混合结果说明均值改善不能代表极端样本风险全部下降；等预算 POST 在所测终态受力上更强，因而不能写成在线方法优于生成后修正。有界修正的必要性也没有被消融确立，其作用应限定为保守的数值控制。

第五，两项创新的联合效果和更广泛迁移性仍未解决。当前 Adaptive CFG 与力反馈的兼容性实验未达到双保持门槛，且没有直接确认 Fixed-K2 与 RC-NFGD 的完整笛卡尔积组合。方法还依赖当前的阶段窗口、神经势、目标属性、采样步

数和结构规模；跨任务使用时必须重新进行阶段诊断、候选校准、预算设计和确认实验，不能从本文结果直接推导部署最优策略。

此外，配对种子设计提高了方法间比较的内部可比性，但不等同于对整个材料分布的无偏抽样。C1-128 和 Formal256 的确认结果分别服务于两个冻结任务，机制消融和兼容性实验的样本量更小，因而不同证据层级不能简单合并为一个总体效应。20 000 次配对 bootstrap 描述的是给定 cohort 和指标下的抽样不确定性，并不替代跨数据集、跨 checkpoint 或跨实验条件的复现。后续研究还需要报告结构规模、元素分布、属性难度和计算预算的分层结果，以判断平均改善是否由特定子群驱动，并检查回退率、尾部风险和属性代价在不同子群中是否保持同一方向。

6.4 未来工作展望

6.4.1 以配对 DFT 单点力验证代理结论

最优先的工作是对 Formal256 中冻结的 C0 与 RC-NFGD 配对结构进行随机或分层随机抽样，开展配对 DFT single-point force validation。第一阶段应优先比较 DFT 原子力的 MaxF 和 Mean Force，并沿用相同 seed 的配对统计；在计算资源允许时，再补充 single-point energy。形成能和 E-hull 还需要参考相、竞争相和一致的计算泛函，实施复杂度更高，不应在没有实际测量的情况下预先承诺成本或效果。只有建立了 DFT 层面的配对证据，才能判断代理力改善在更高精度势能面上是否保持。

6.4.2 研究更可靠的候选分配与更低成本分支

对于创新点 1，后续可在独立 calibration set 上预注册难度估计，将简单样本直接输出 C0、困难样本启动 Fixed-K2，再用全新 confirmation set 检验动态预算；这只是未来研究设计，尚未实现或验证。也可研究具有更强跨 cohort 泛化能力的状态表征与置信度估计，而不是简单增加 Linear-K2 的复杂度。候选分支还可以探索共享计算、早期剪枝、分层预算和低成本终点评价，以降低 Fixed-K2 的 2.2 倍开销；这些方向需要新的预注册协议下验证，不能视为当前结果的自然延伸。

6.4.3 扩展属性、材料体系和生成模型

未来可在多个属性、冲突目标和不同组成范围下测试参考保留框架，例如将属性误差、稳定性代理和结构质量写成明确的多目标门槛或 Pareto 选择问题。同时，应在其他 MatterGen checkpoint、其他晶体扩散模型及更大或更小结构规模上重新校准分支点与终点评价，以判断方法的迁移性。扩展实验的重点是检验适用范围，而不是预设当前效应量会保持不变。

6.4.4 发展多物理量反馈和在线—后处理组合

对于创新点 2，可以研究能量、力和应力的多物理量反馈，但应先建立各信号在不同扩散阶段的可靠性和冲突处理规则。鉴于当前 POST 在终态代理力上更强，合理的后续问题是比较“后期在线反馈 + 轻量终态松弛”的预算组合，并明确区分生成分布保持、终态受力和属性准确性三个目标。任何组合策略都需要独立的预算、配对种子和预注册判据。

6.4.5 面向实验可验证性的候选筛选

在完成高精度计算验证后，可进一步把生成候选送入缺陷、温压条件和合成可行性筛选，再选择少量结构进行实验合成与表征。该阶段的重点应是建立从生成、代理筛选、高精度计算到实验反馈的可追溯链路，而不是把当前代理结果直接解释为实验候选已经确定。对于硕士论文后续工作，优先级仍应放在 DFT 配对验证和跨任务复现，实验路线可作为更长期的延伸。

6.5 本章小结

本文围绕冻结 MatterGen 形成两类独立推理增强机制：预算约束验证选择回答如何使用额外计算，阶段可靠性校准的物理反馈回答如何将神经力信息接入扩散。创新点 1 以参考轨迹保留、Fixed-K2 实例、终点约束和回退改善 C1-128 上的代理 Property MAE；学习型 Linear-K2 的额外优势未得到支持。创新点 2 以阶段可靠性校准、后期 MatterSim 力反馈和周期坐标映射改善 Formal256 上的代理 MaxF、Mean Force 和 RMSD；CHGNet 对均值力指标给出方向一致支持，但 Property MAE 存在轻微代价。

全文同时保留了关键边界：两项创新没有得到已验证的联合协同，等预算 POST 在所测终态受力上更强，有界修正不是已确认的性能核心，且没有 DFT 或实验验证。由此，本文形成的最终结论是：预算约束验证选择框架的 Fixed-K2 实例在冻结代理属性协议下相对 C0 得到支持，但不具有已证实的 Best-of-N 优势；RC-NFGD 在冻结代理局部结构协议下得到支持；更强的真实物理、普适迁移和联合最优命题仍需新的预注册研究。后续工作的首要任务是配对 DFT 单点力验证，其次是降低分支成本、改进候选分配并扩大跨任务评估。

参考文献

- [1] Noura A, Sokolovska N, Crivello J. CrystalGAN: Learning to Discover Crystallographic Structures with Generative Adversarial Networks[EB/OL]. arXiv:1810.11203, 2018.
- [2] Xie T, Fu X, Ganea O E, et al. Crystal Diffusion Variational Autoencoder for Periodic Material Generation[C]//International Conference on Learning Representations. 2022. arXiv:2110.06197.
- [3] Jiao R, Huang W, Lin P, et al. Crystal Structure Prediction by Joint Equivariant Diffusion[C]//Advances in Neural Information Processing Systems 36. 2023. arXiv:2309.04475.
- [4] Jiao R, Huang W, Liu Y, et al. Space Group Constrained Crystal Generation[C]//International Conference on Learning Representations. 2024. arXiv:2402.03992.
- [5] Yang S, Cho K, Merchant A, et al. Scalable Diffusion for Materials Generation[C]//International Conference on Learning Representations. 2024. arXiv:2311.09235.
- [6] Xiao H, Li R, Shi X, et al. An Invertible, Invariant Crystal Representation for Inverse Design of Solid-State Materials Using Generative Deep Learning[J]. Nature Communications, 2023, 14: 7027. DOI: 10.1038/s41467-023-42870-7.
- [7] Antunes L M, Butler K T, Grau-Crespo R. Crystal Structure Generation with Autoregressive Large Language Modeling[J]. Nature Communications, 2024, 15: 10570. DOI: 10.1038/s41467-024-54639-7.
- [8] Zeni C, Pinsler R, Zügner D, et al. A Generative Model for Inorganic Materials Design[J]. Nature, 2025, 639: 624–632. DOI: 10.1038/s41586-025-08628-5.
- [9] Okabe R, Cheng M, Chotrattanapituk A, et al. Structural Constraint Integration in a Generative Model for the Discovery of Quantum Materials[J]. Nature Materials, 2025. DOI: 10.1038/s41563-025-02355-y.
- [10] Ye C, Wang Y, Xie X, et al. Materials Discovery Acceleration by Using Conditional Generative Methodology[J]. npj Computational Materials, 2026, 12: 63. DOI: 10.1038/s41524-025-01930-w.
- [11] Ho J, Jain A, Abbeel P. Denoising Diffusion Probabilistic Models[C]//Advances in Neural Information Processing Systems 33. 2020: 6840–6851.
- [12] Song Y, Sohl-Dickstein J, Kingma D P, et al. Score-Based Generative Modeling through Stochastic Differential Equations[C]//International Conference on Learning Representations. 2021. arXiv:2011.13456.

- [13] Ho J, Salimans T. Classifier-Free Diffusion Guidance[EB/OL]. arXiv:2207.12598, 2022.
- [14] Merchant A, Batzner S, Schoenholz S S, et al. Scaling Deep Learning for Materials Discovery[J]. Nature, 2023, 624: 80–85. DOI: 10.1038/s41586-023-06735-9.
- [15] Chen C, Ong S P. A Universal Graph Deep Learning Interatomic Potential for the Periodic Table[J]. Nature Computational Science, 2022, 2: 718–728. DOI: 10.1038/s43588-022-00349-3.
- [16] Batzner S, Musaelian A, Sun L, et al. E(3)-Equivariant Graph Neural Networks for Data-Efficient and Accurate Interatomic Potentials[J]. Nature Communications, 2022, 13: 2453. arXiv:2101.03164.
- [17] Batatia I, Kovacs D P, Simm G, et al. MACE: Higher Order Equivariant Message Passing Neural Networks for Fast and Accurate Force Fields[C]//Advances in Neural Information Processing Systems 35. 2022. arXiv:2206.07697.
- [18] Deng B, Zhong P, Jun K, et al. CHGNet as a Pretrained Universal Neural Network Potential for Charge-Informed Atomistic Modelling[J]. Nature Machine Intelligence, 2023, 5: 1031–1041. DOI: 10.1038/s42256-023-00716-3.
- [19] Yang H, Hu C, Zhou Y, et al. MatterSim: A Deep Learning Atomistic Model across Elements, Temperatures and Pressures[EB/OL]. arXiv:2405.04967, 2024.
- [20] Wang Y, Wang L, Shen Y, et al. Protein Conformation Generation via Force-Guided SE(3) Diffusion Models[EB/OL]. arXiv:2403.14088, 2024.
- [21] Long T, Zhang Y, Zhang H. Generative Deep Learning for the Inverse Design of Materials[EB/OL]. arXiv:2409.19124, 2024.
- [22] Gastegger J, Becker F, Günnemann S. GemNet: Universal Directional Graph Neural Networks for Molecules[C]//Advances in Neural Information Processing Systems 34. 2021.

致 谢

本页为学校模板预览，正式提交前将根据实际指导、协作和资助情况补充致谢内容。

作者简历及在学研究成果

作者教育经历、科研项目、奖励和论文发表信息待根据正式提交材料补充。

独创性声明

本人声明所呈交的论文是我个人在导师指导下进行的研究工作及取得的研究成果。尽我所知，除了文中特别加以标注和致谢的地方外，论文中不包含其他人已经发表或撰写过的研究成果，也不包含为获得北京科技大学或其它教育机构的学位或证书而使用过的材料。与我一同工作的同志对本研究所做的任何贡献均已在论文中作了明确的说明并表示了谢意。

作者签名：_____ 日期：_____ 年_____ 月_____ 日

备注：提交时须有作者亲笔签名！

关于论文使用授权的说明

本人完全了解北京科技大学有关保留、使用学位论文的规定，即：学校有权保留送交论文的复印件，允许论文被查阅和借阅；学校可以公布论文的全部或部分内容，可以采用影印、缩印或其他复制手段保存论文。

(保密的论文在解密后应遵循此规定)

签名：_____ 导师签名：_____ 日期：_____

学位论文数据集

关键词 *	密级 *	中图分类号 *	UDC	论文资助
学位授予单位名称 *		学位授予单位代码 *	学位类别 *	学位级别 *
北京科技大学		10008		
论文题名 *		并列题名		论文语种 *
作者姓名 *			学号 *	
培养单位名称 *		培养单位代码 *	培养单位地址	邮编
北京科技大学		10008	北京市海淀区学院路 30 号	100083
学科专业 *		研究方向 *	学制 *	学位授予年 *
论文提交日期 *				
导师姓名 *			职称 *	
评阅人	答辩委员会主席 *	答辩委员会成员		
电子版论文提交格式文本 () 图像 () 视频 () 音频 () 多媒体 () 其他 ()				
推荐格式: application/msword; application/pdf				
电子论文出版 (发布) 者		电子论文出版 (发布) 地		权限声明
论文总页数 *				
共 33 项, 其中带 * 为必填数据, 为 22 项。				